大模型开源生态与硬件选型

彭靖田

Google Developer Experts
LangChain Developer

目录

大模型时代的 Github: Hugging Face

Hugging News #0821: Hugging Face 完成2.35 亿美元D 轮融资

Aug 28, 2023 — 每一周，我们的同事都会向社区的成员们发布一些关于Hugging Face 相关的更新， ... 我们以45 亿美元的估值完成了2.35 亿美元的D 轮融资 :tada: ...

澎湃新闻

https://m.thepaper.cn › newsDetail_...

从草根社区到20亿美金估值，Hugging Face为什么敢开源?

Jul 10, 2023 — HuggingFace是一家估值20亿美元的AI独角兽，有24个投资人，包括LuxCapital，红杉资本等。 在大模型领域，我们已经看多了巨额融资，例如OpenAI获得微软的百 ...

DoNews

https://www.donews.com › detail

AI模型初创公司Hugging Face获得40亿美元估值

Jul 19, 2023 — DoNews7月19日消息，多个消息来源称，AI模型初创公司Hugging Face在接下来的D轮融资中有望筹集至少2亿美元。这家高速发展的公司是以40亿美元估值进行 ...

Google Trends: Hugging Face vs Stability AI

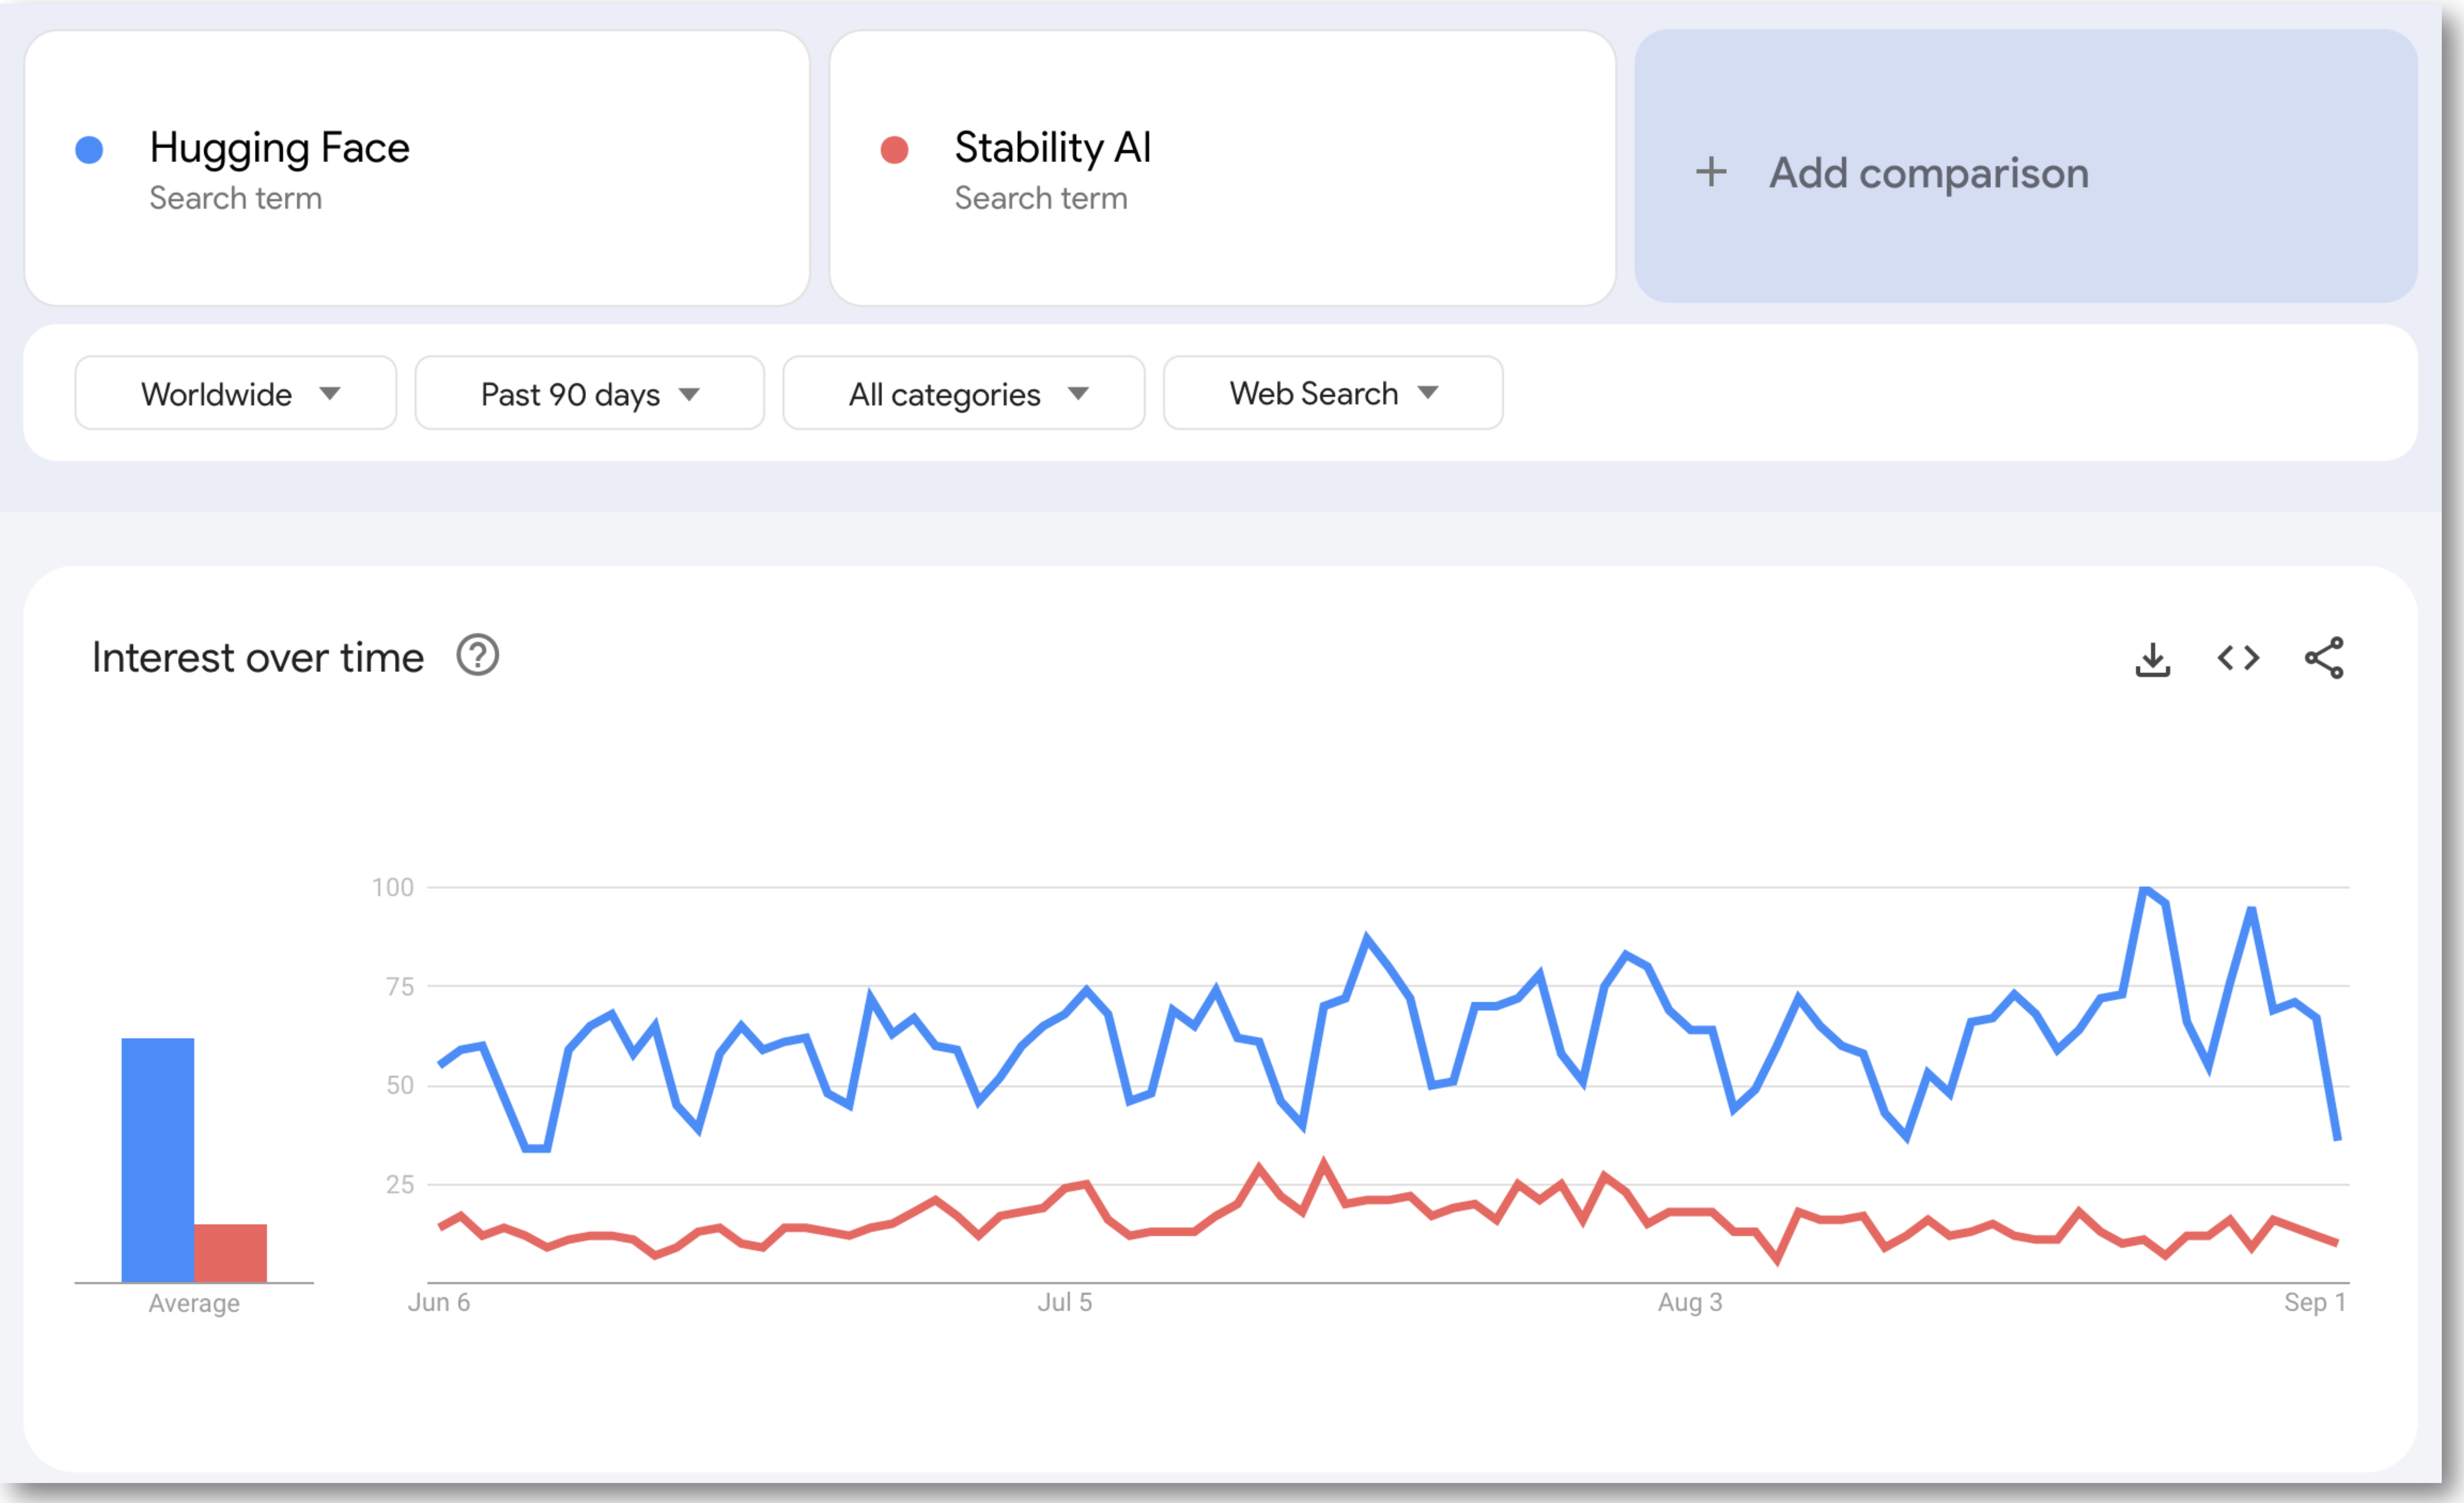

Hugging Face

拥抱 AI 全生态

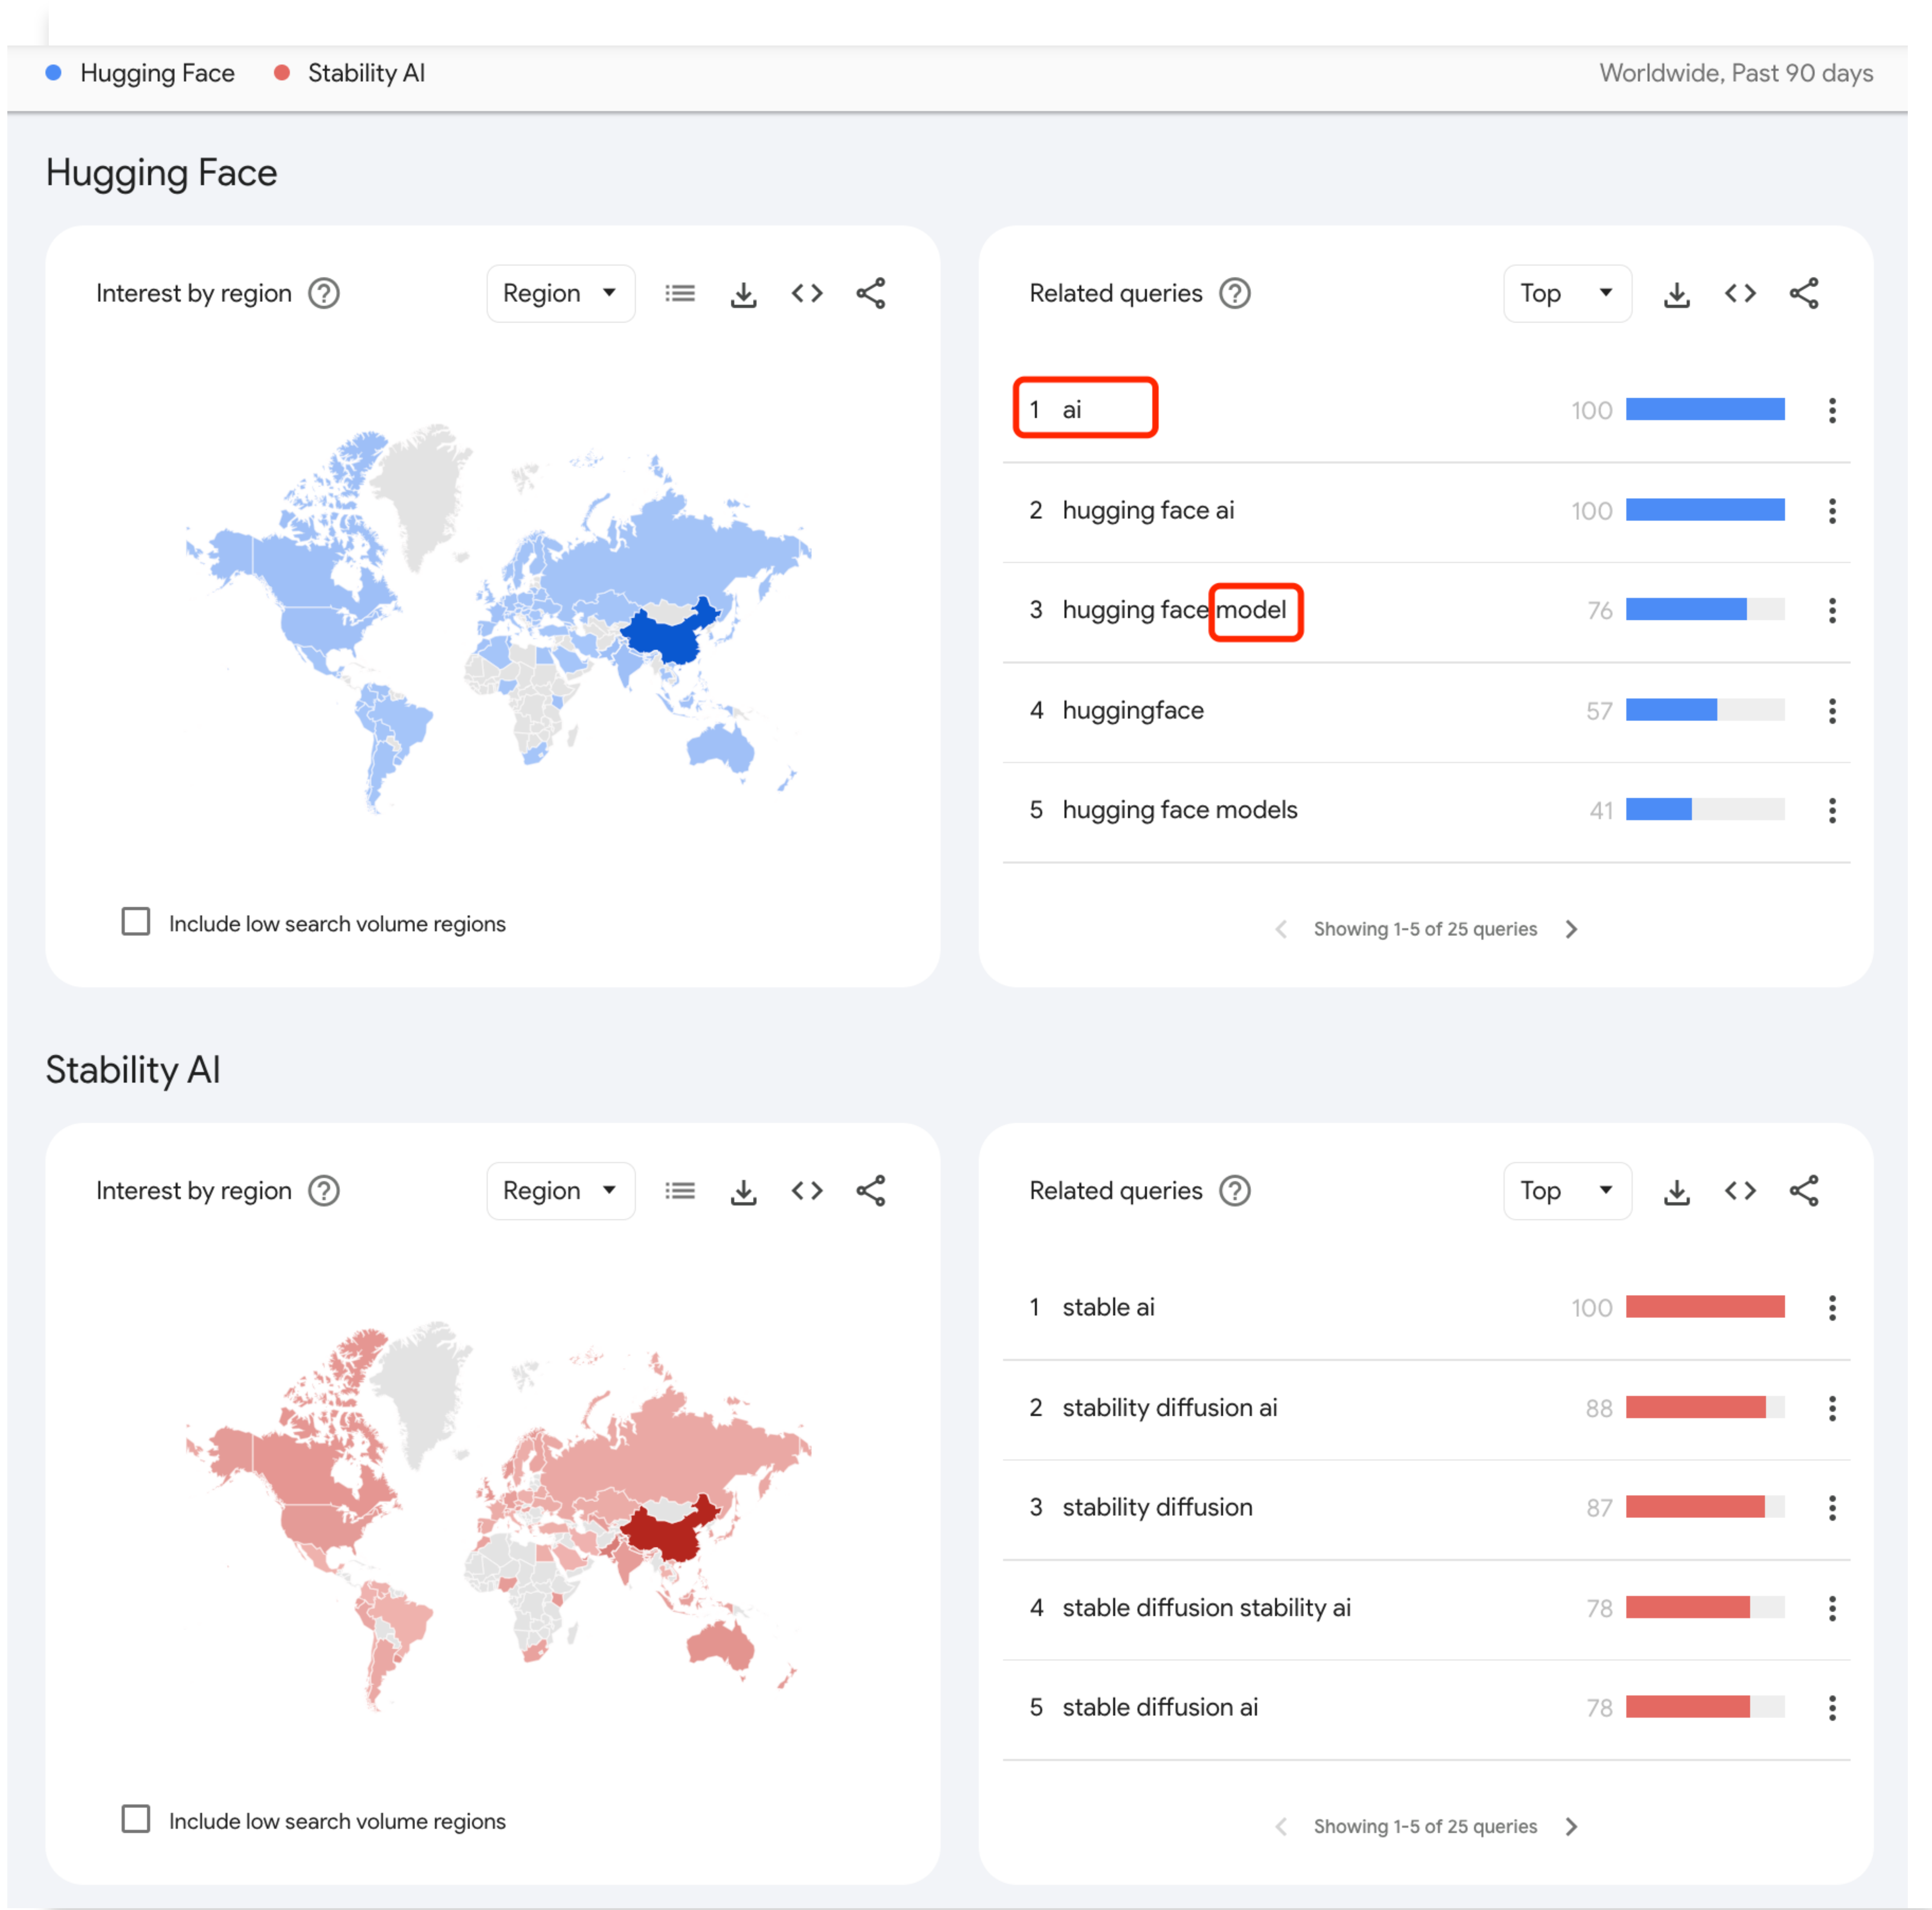

Hugging Face 是什么？

Hugging Face 是一家**2016年**成立的总部位于纽约的 **AI** 初创公司。

最早是一家开发聊天机器人的企业。他们的目标是使用聊天机器人为无聊的年轻人解闷。当然，这样的创意虽然看起来很好，但显然并没有做得很大。

HuggingFace 转型契机：主要来源于它在**NLP**领域的贡献。在**Bert**发布不久之后，他们贡献了一个基于**Pytorch**的**Bert**预训练模型，即**pytorch-pretrained-bert**。

Hugging Face

https://huggingface.co

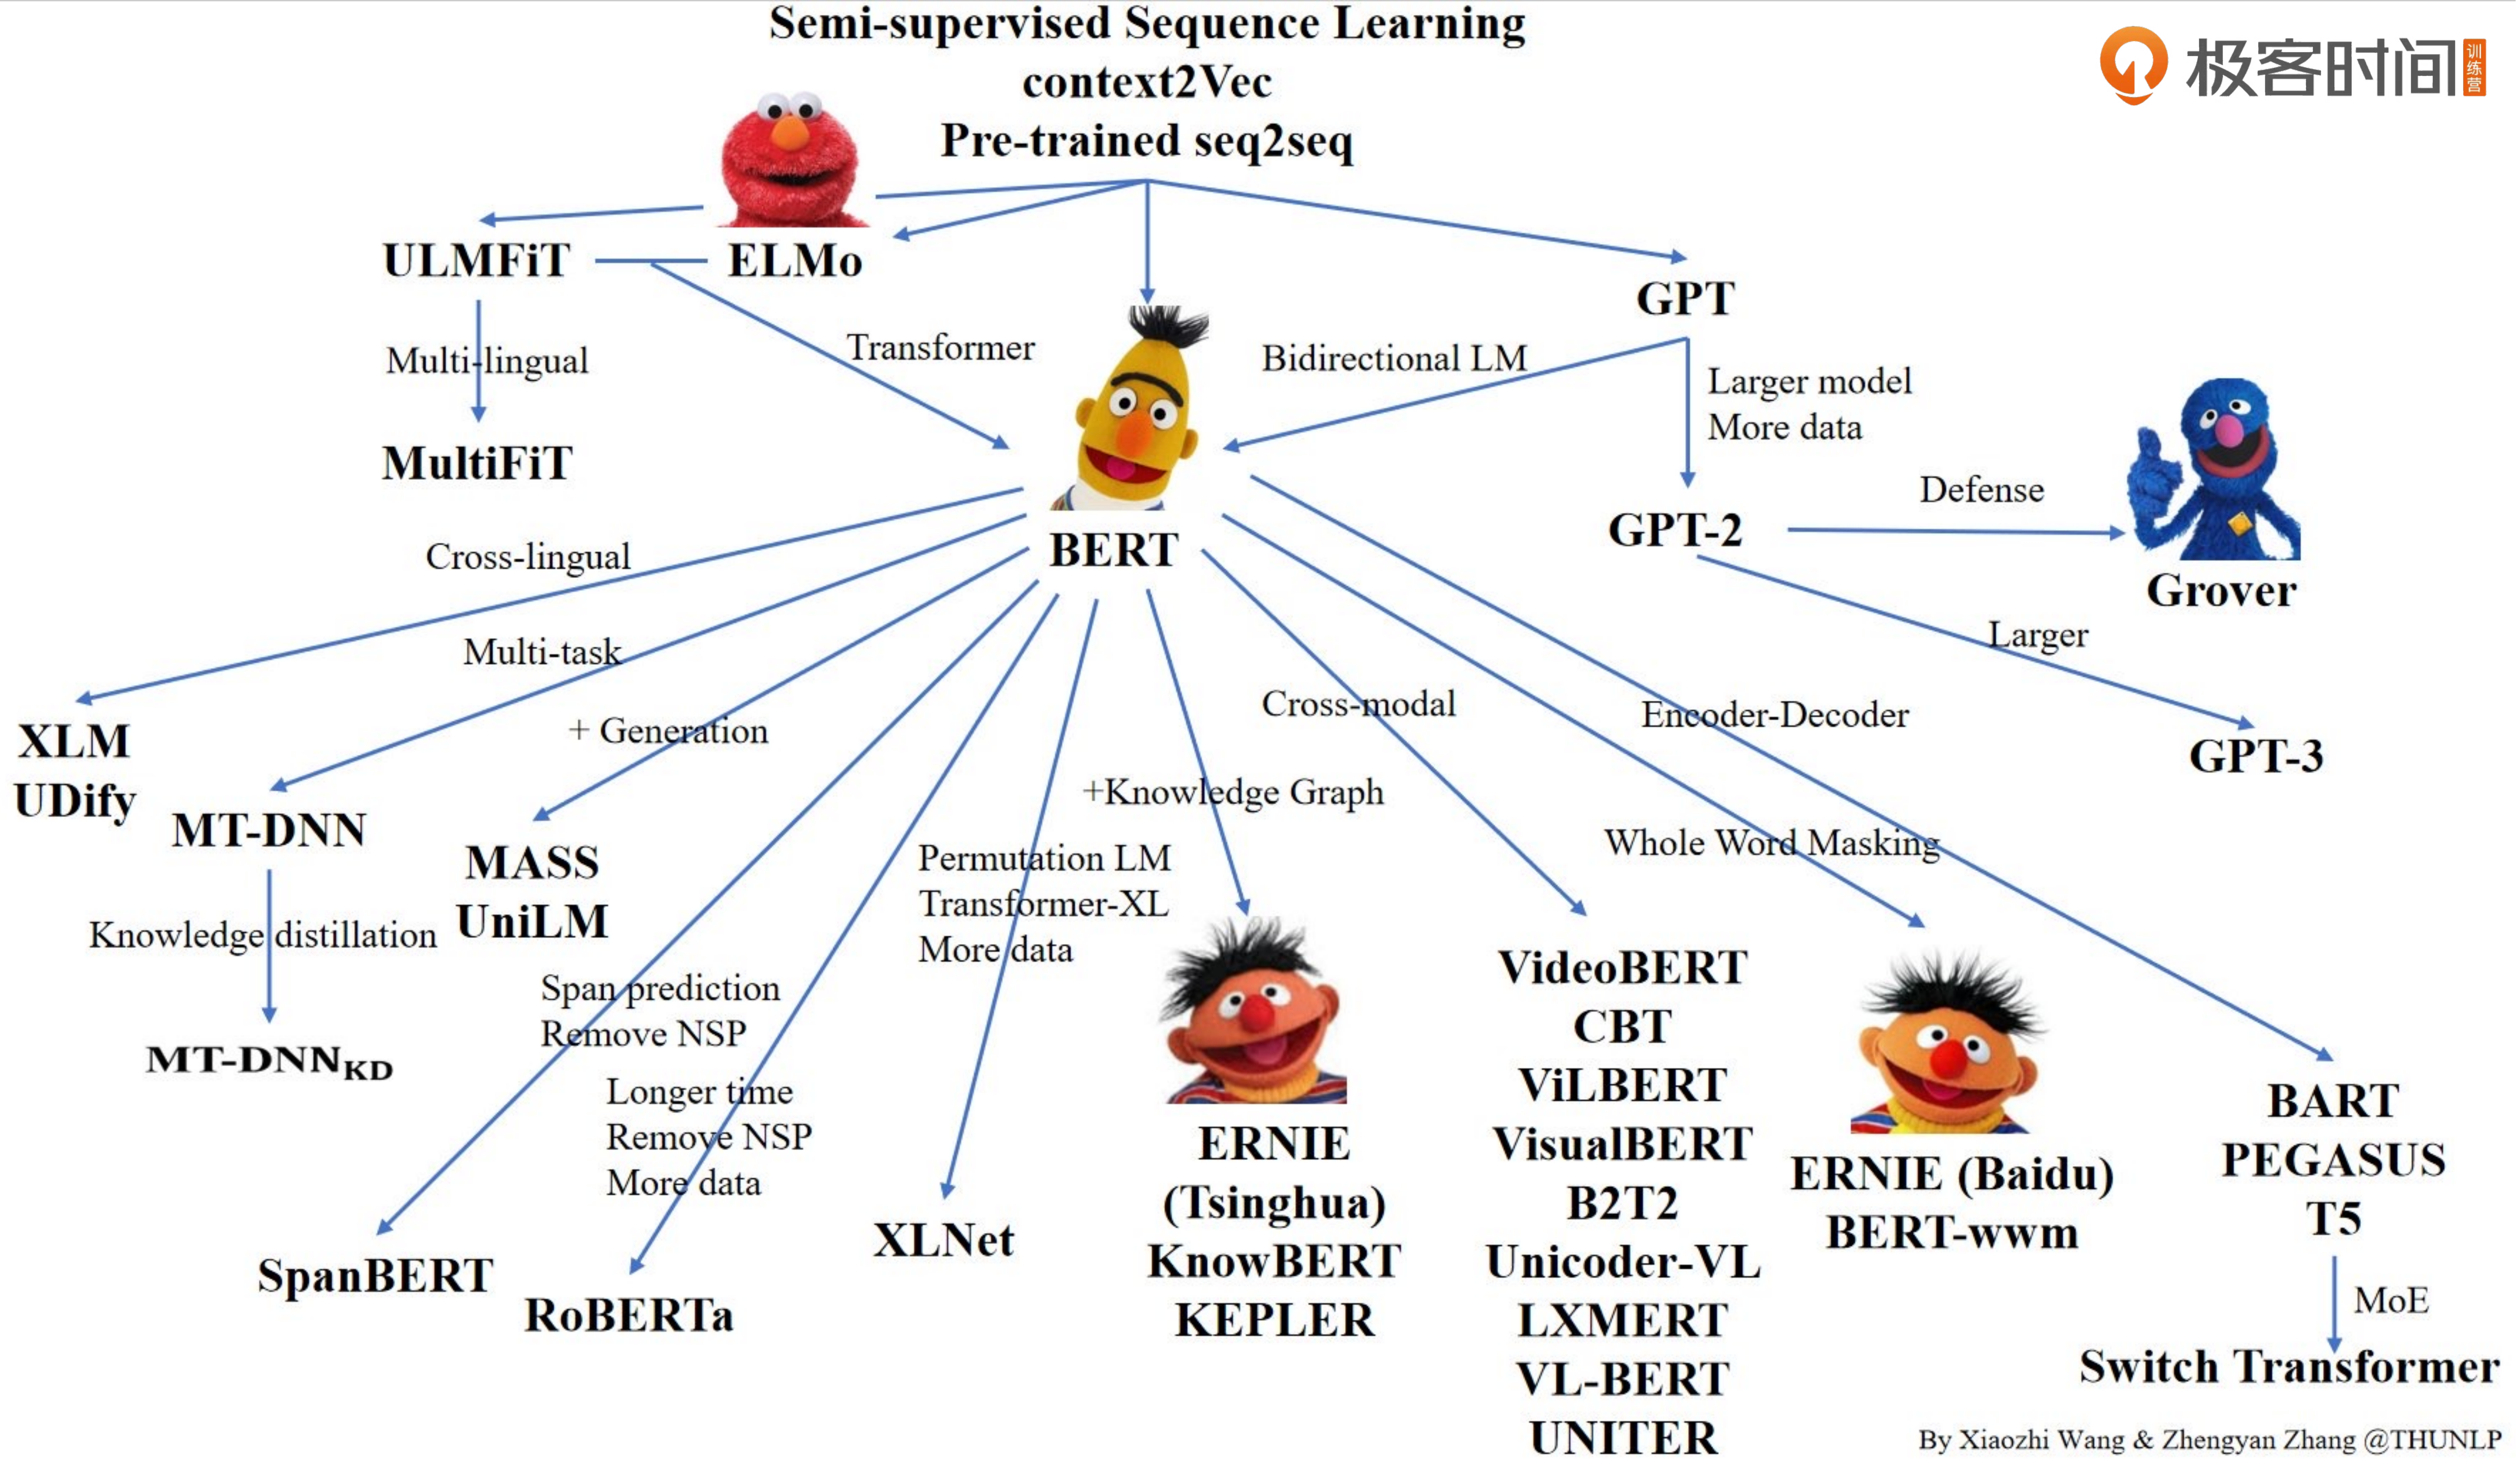

Semi-supervised Sequence Learning
context2Vec
Pre-trained seq2seq
ULMFiT
ELMo
GPT
Multi-lingual
MultiFiT
Transformer
Bidirectional LM
Larger model
More data
BERT
GPT-2
Defense
Grover
Larger
GPT-3
Cross-lingual
Multi-task
+ Generation
Cross-modal
Encoder-Decoder
XLM
UDify
MT-DNN
MASS
UniLM
+Knowledge Graph
Permutation LM
Transformer-XL
More data
Whole Word Masking
Knowledge distillation
MT-DNN$_{KD}$
Span prediction
Remove NSP
Longer time
Remove NSP
More data
SpanBERT
RoBERTa
XLNet
ERNIE (Tsinghua)
KnowBERT
KEPLER
VideoBERT
CBT
ViLBERT
VisualBERT
B2T2
Unicoder-VL
LXMERT
VL-BERT
UNITER
ERNIE (Baidu)
BERT-wwm
BART
PEGASUS
T5
MoE
Switch Transformer
By Xiaozhi Wang & Zhengyan Zhang @THUNLP

Hugging Face Transformers

Hugging Face 在 GitHub上维护了一个庞大的开源社区，提供了丰富的机器学习（ML）工具和模型，其中最著名的项目是**Transformers。**

Transformers：先进的机器学习库，提供了基于TensorFlow、PyTorch、JAX实现的各种SOTA模型和工具

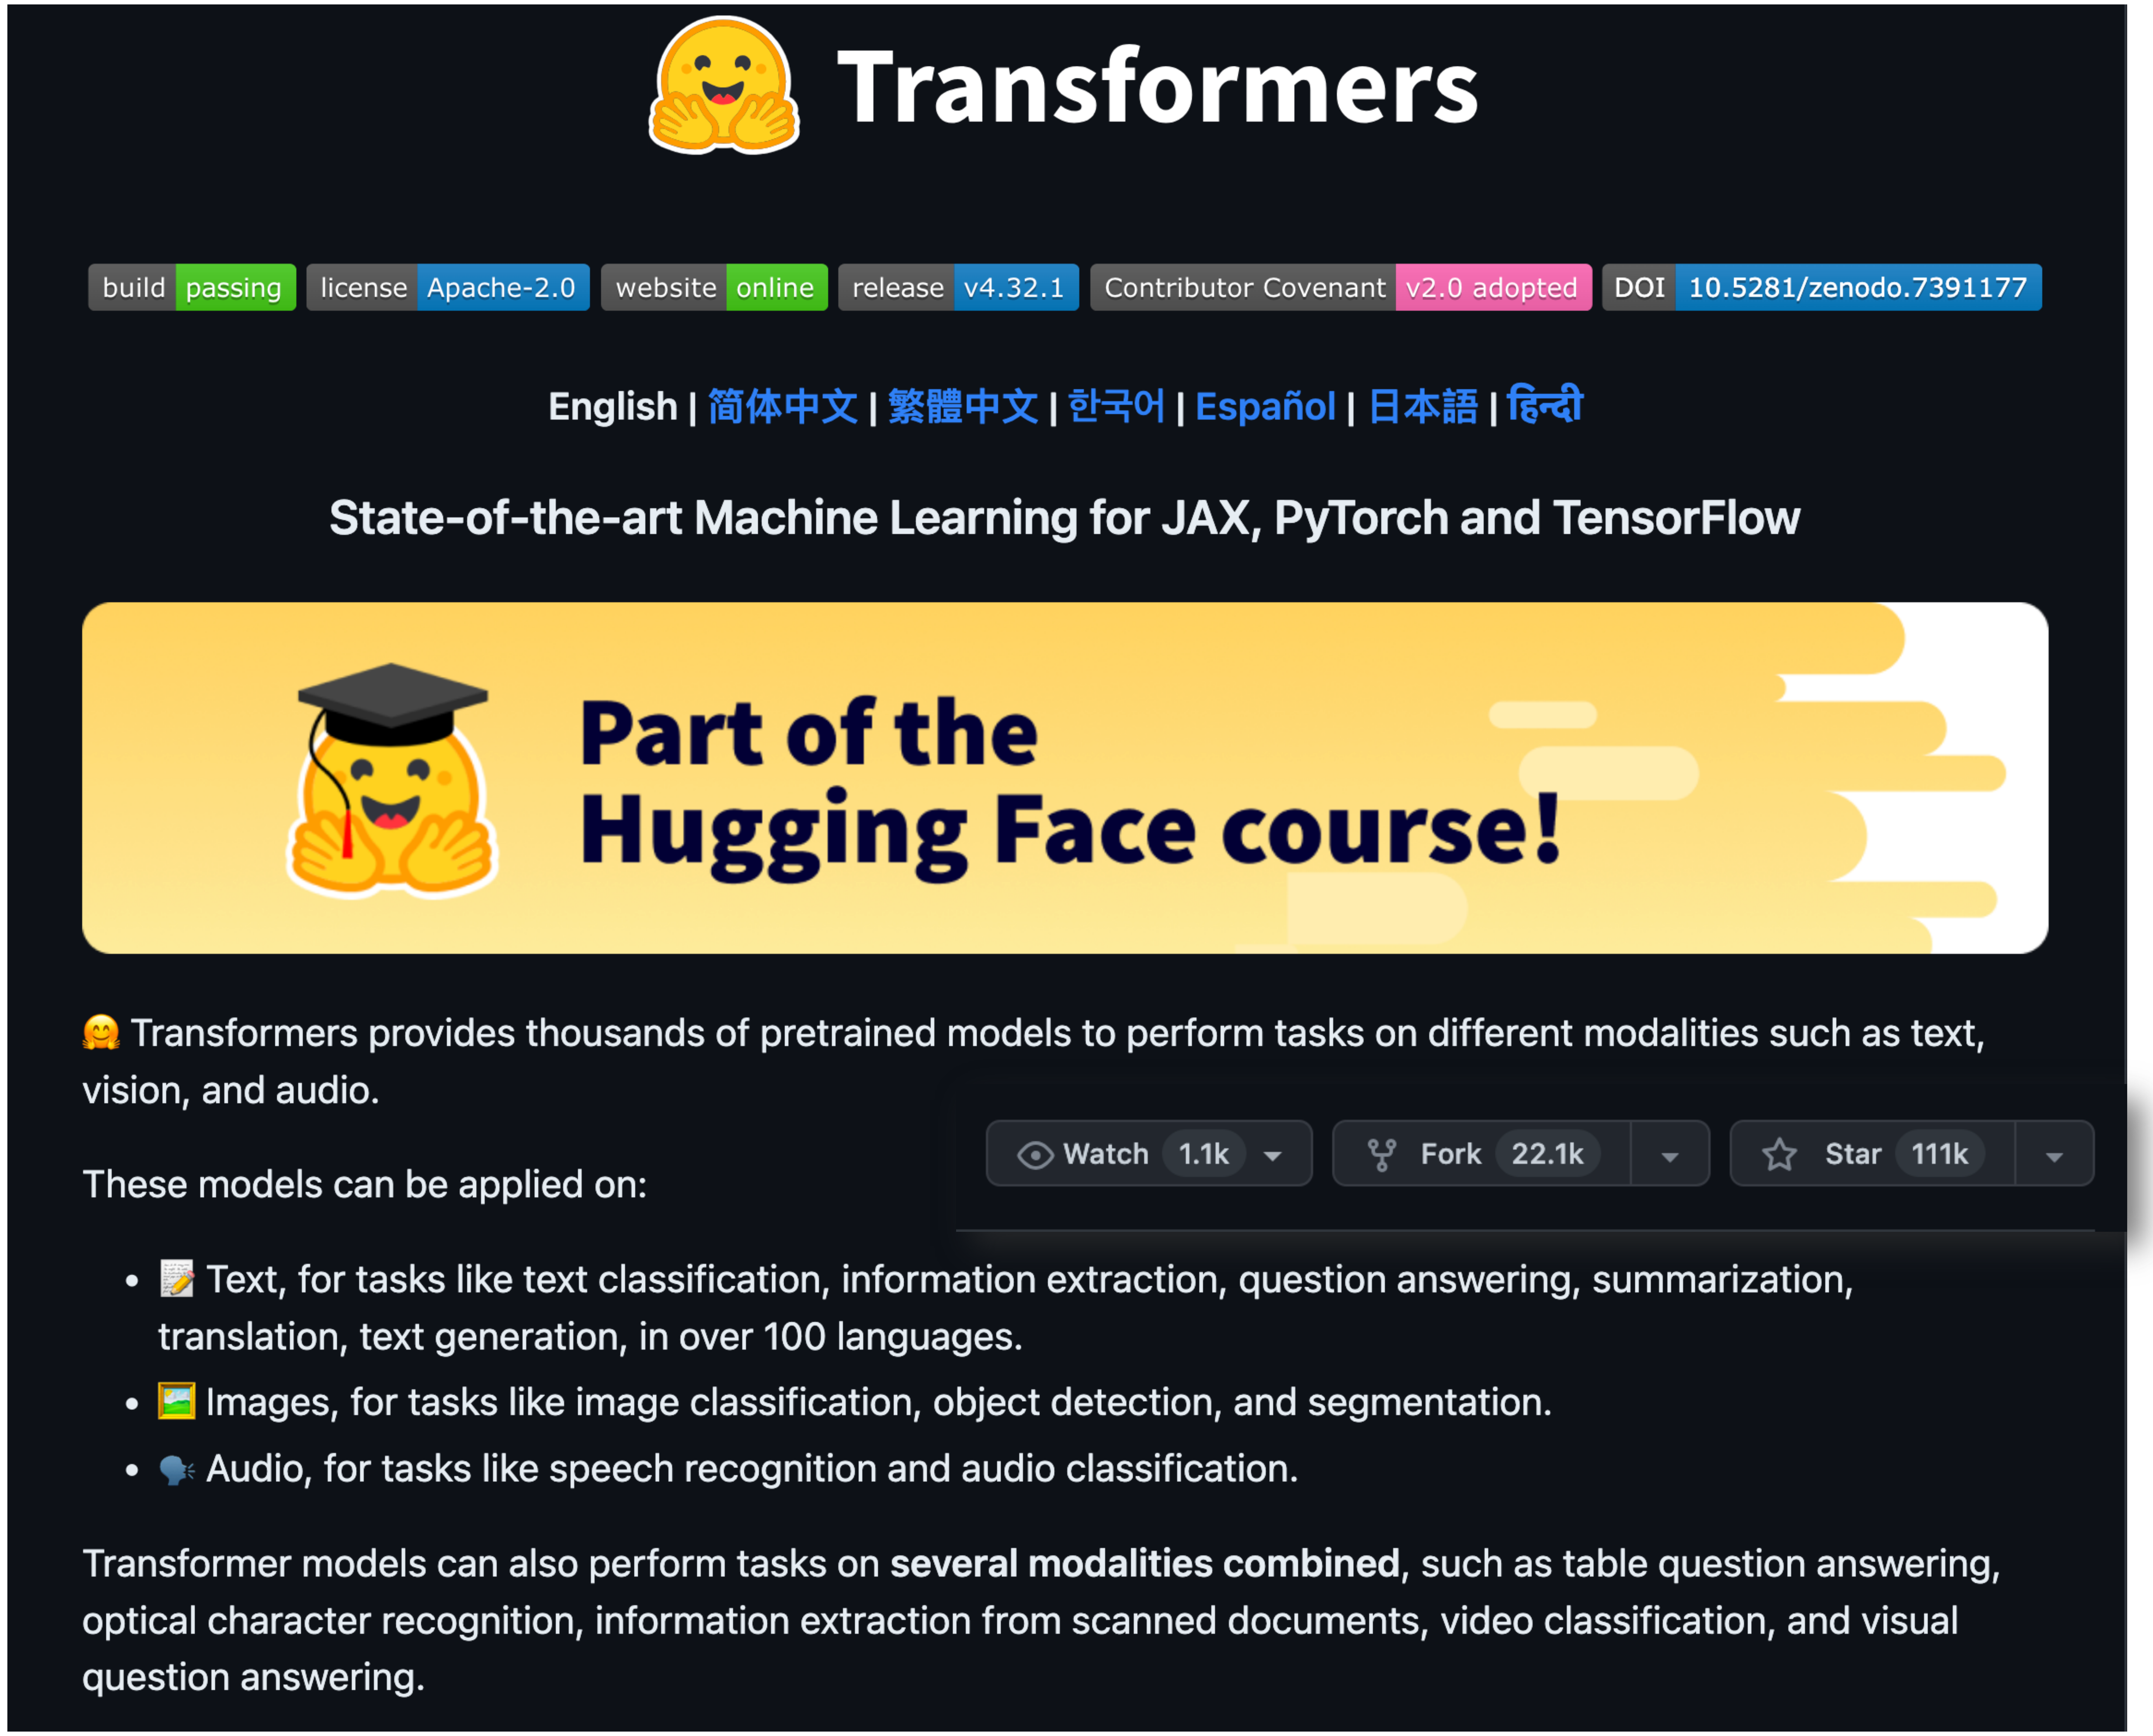

https://github.com/huggingface/transformers

The AI community building the future.

The platform where the machine learning community collaborates on models, datasets, and applications.

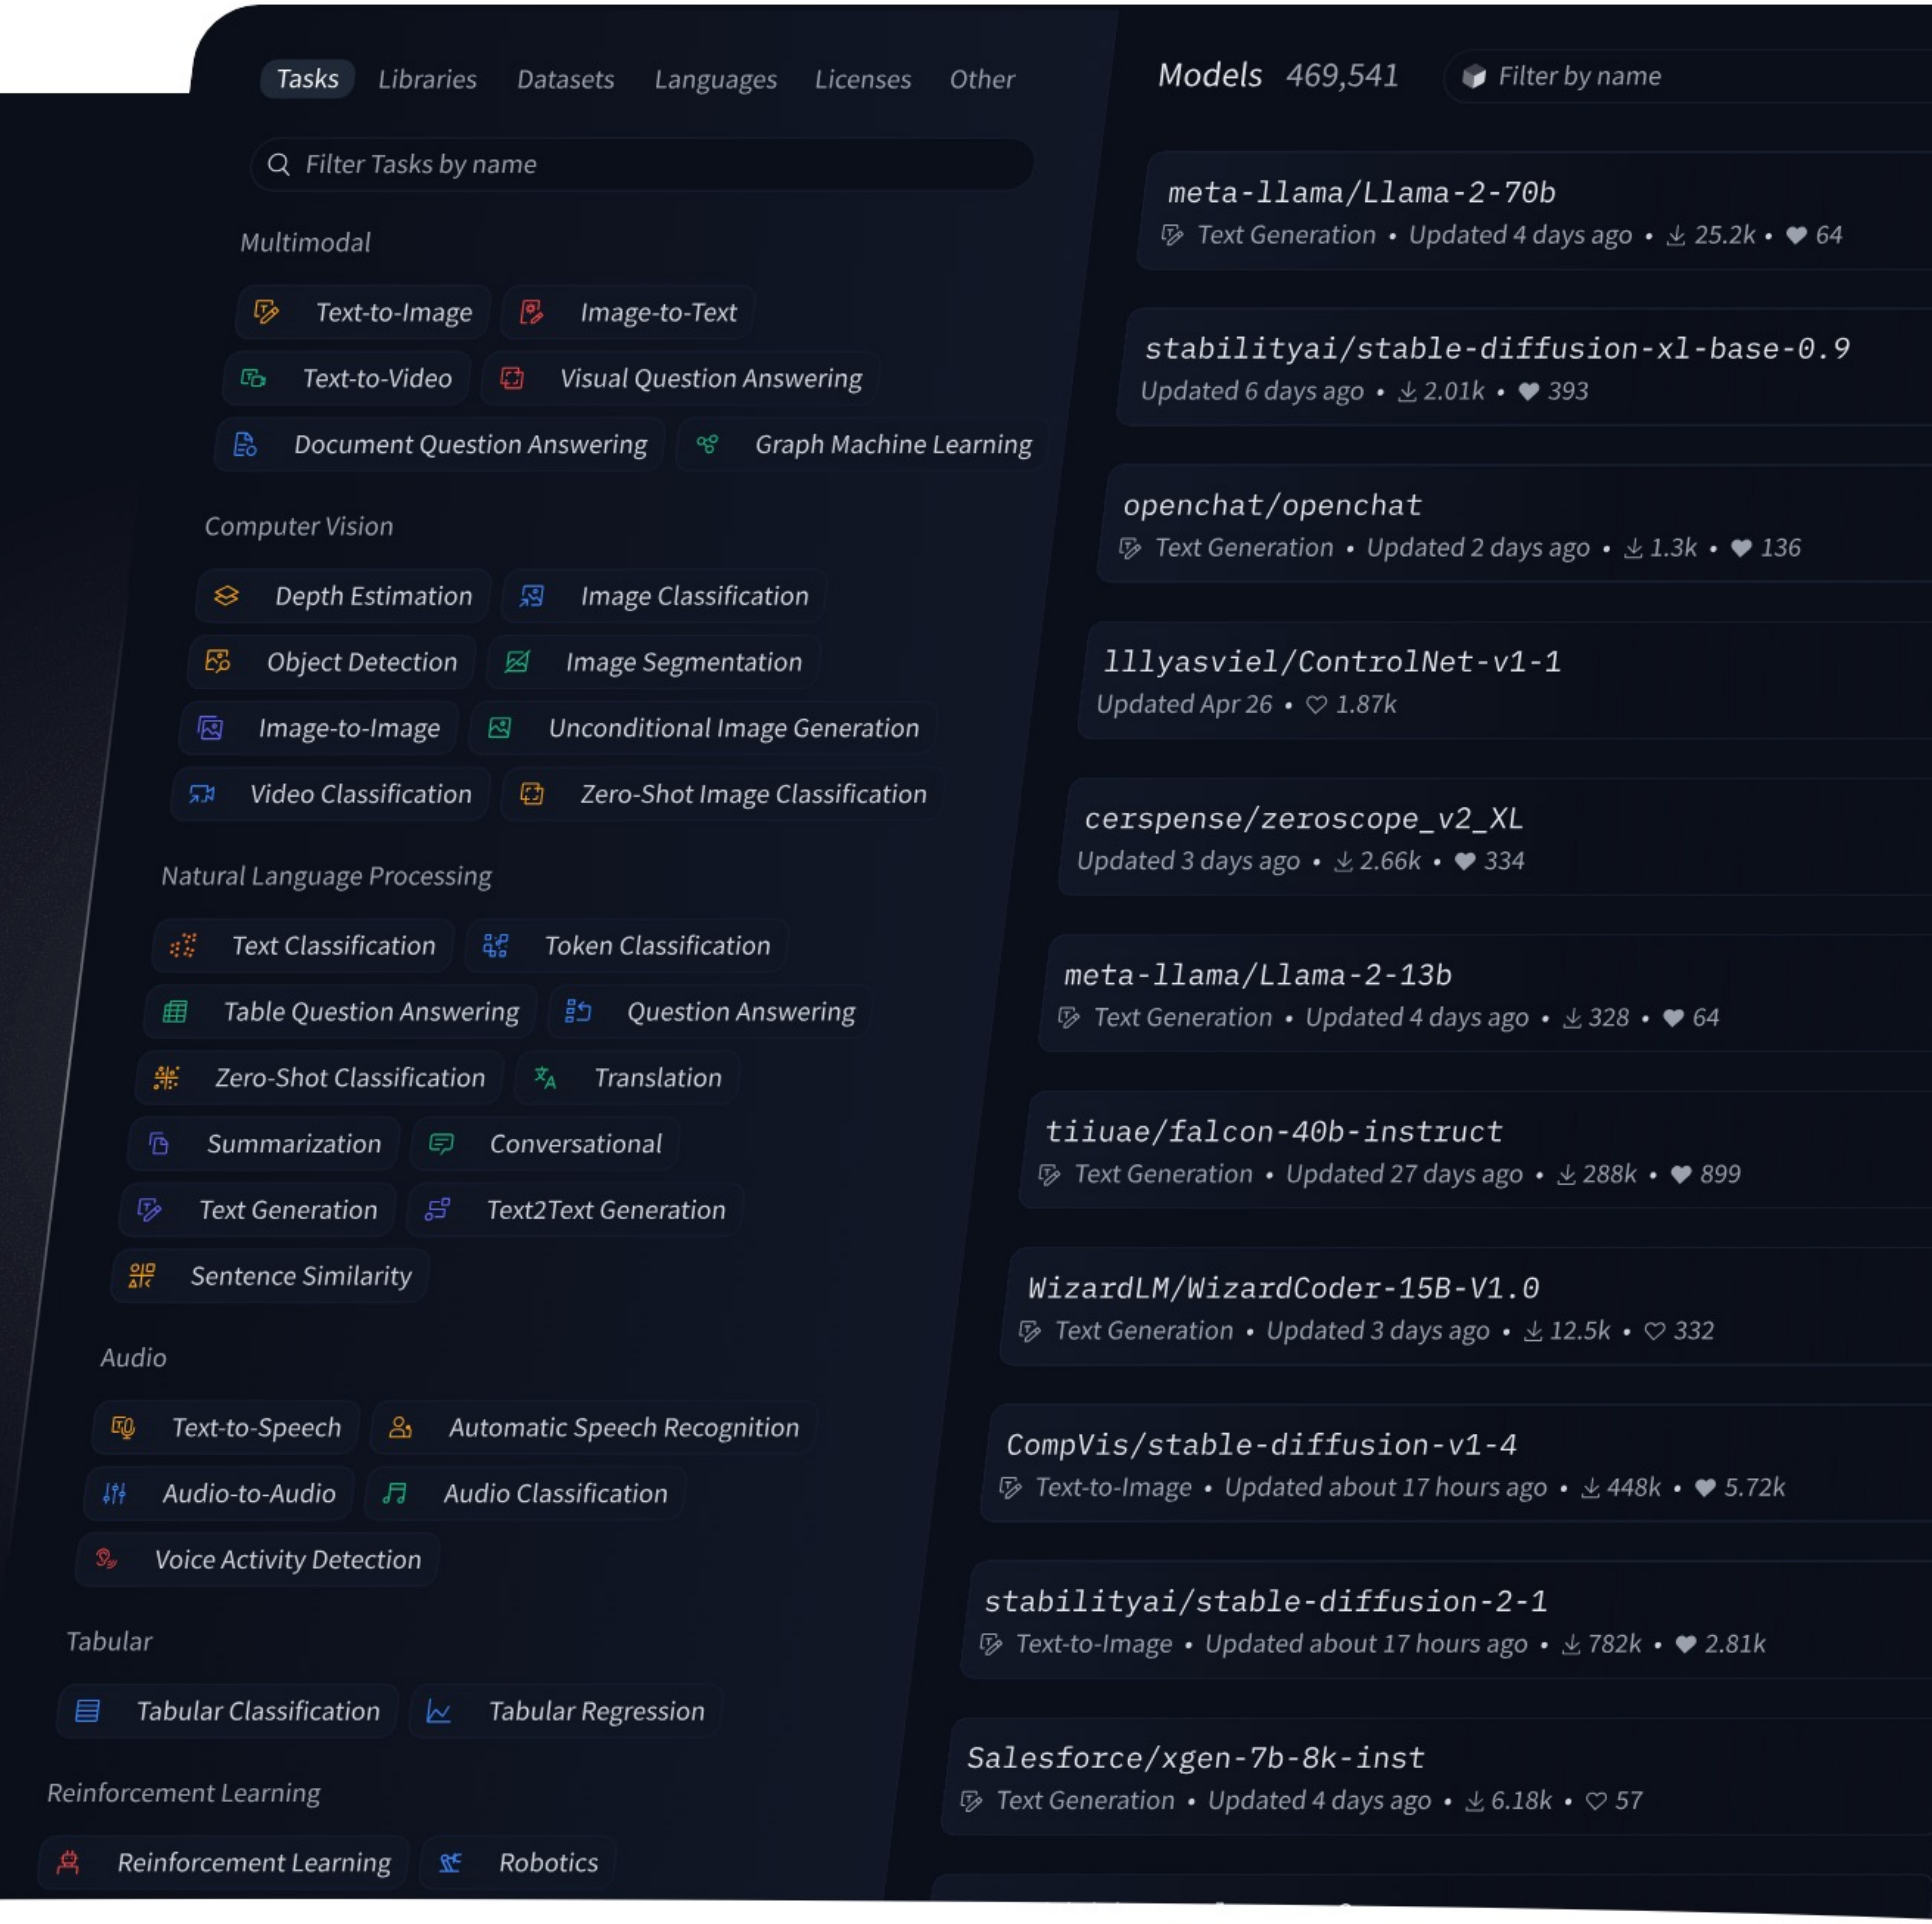

Hugging Face 开源社区

Hugging Face 公司提供了一个面向机器学习和数据科学的开源社区。它包含超过300,000个模型、50,000个数据集和100,000个名为Spaces的Demo Apps：

- **HF Models**： 用户可以在这里共享、下载和部署预训练模型。此外，他们还提供了Inference API，使开发者能够轻松地使用这些模型进行自然语言处理任务，无需深入了解模型的内部工作原理。
- **HF Datasets**：针对机器学习和大语言模型的各类任务，提供了一个分享和交流数据集的平台，便于缺少数据的开发者和用户快速启动项目。
- **HF Spaces**： Hugging Face通过提供AI计算资源来实现盈利。他们提供 AutoTrain、Spaces和Inference Endpoints等服务，用于将模型集成到实际应用中。
- **HF Docs**： 除了开源项目和商业产品，Hugging Face 还积极参与教育和研究社区，为学生、研究人员和开发者提供教程、文档和资源，以帮助他们更好地理解和应用ML和LLM技术。

Hugging Face

https://huggingface.co

Hugging Face 当周趋势榜

Trending on 🤗 this week

Models

WizardLM/WizardCoder-Python-34B-V1.0
Updated 8 days ago • 23.9k • 489

meta-llama/Llama-2-7b
Updated Jul 19 • 2.32k

stabilityai/stable-diffusion-xl-base-1…
Updated 1 day ago • 982k • 2.42k

Phind/Phind-CodeLlama-34B-v2
Updated 8 days ago • 3.22k • 183

lllyasviel/sd_control_collection
Updated 1 day ago • 113

Browse 300k+ models

Spaces

AI Comic Factory — 712

Open LLM Leaderboard — 4.95k

Model Memory Utility — 223

Seamless M4T — 527

MS Image2Video — 98

Browse 100k+ applications

Datasets

fka/awesome-chatgpt-prompts
Updated Mar 7 • 4.53k • 3.24k

dell-research-harvard/AmericanStories
Updated Jun 14 • 301 • 39

b-mc2/sql-create-context
Updated Apr 21 • 2.12k • 114

garage-bAInd/Open-Platypus
Updated 22 days ago • 9.28k • 173

allenai/dolma
Updated 18 days ago • 247 • 303

Browse 50k+ datasets

Hugging Face Models

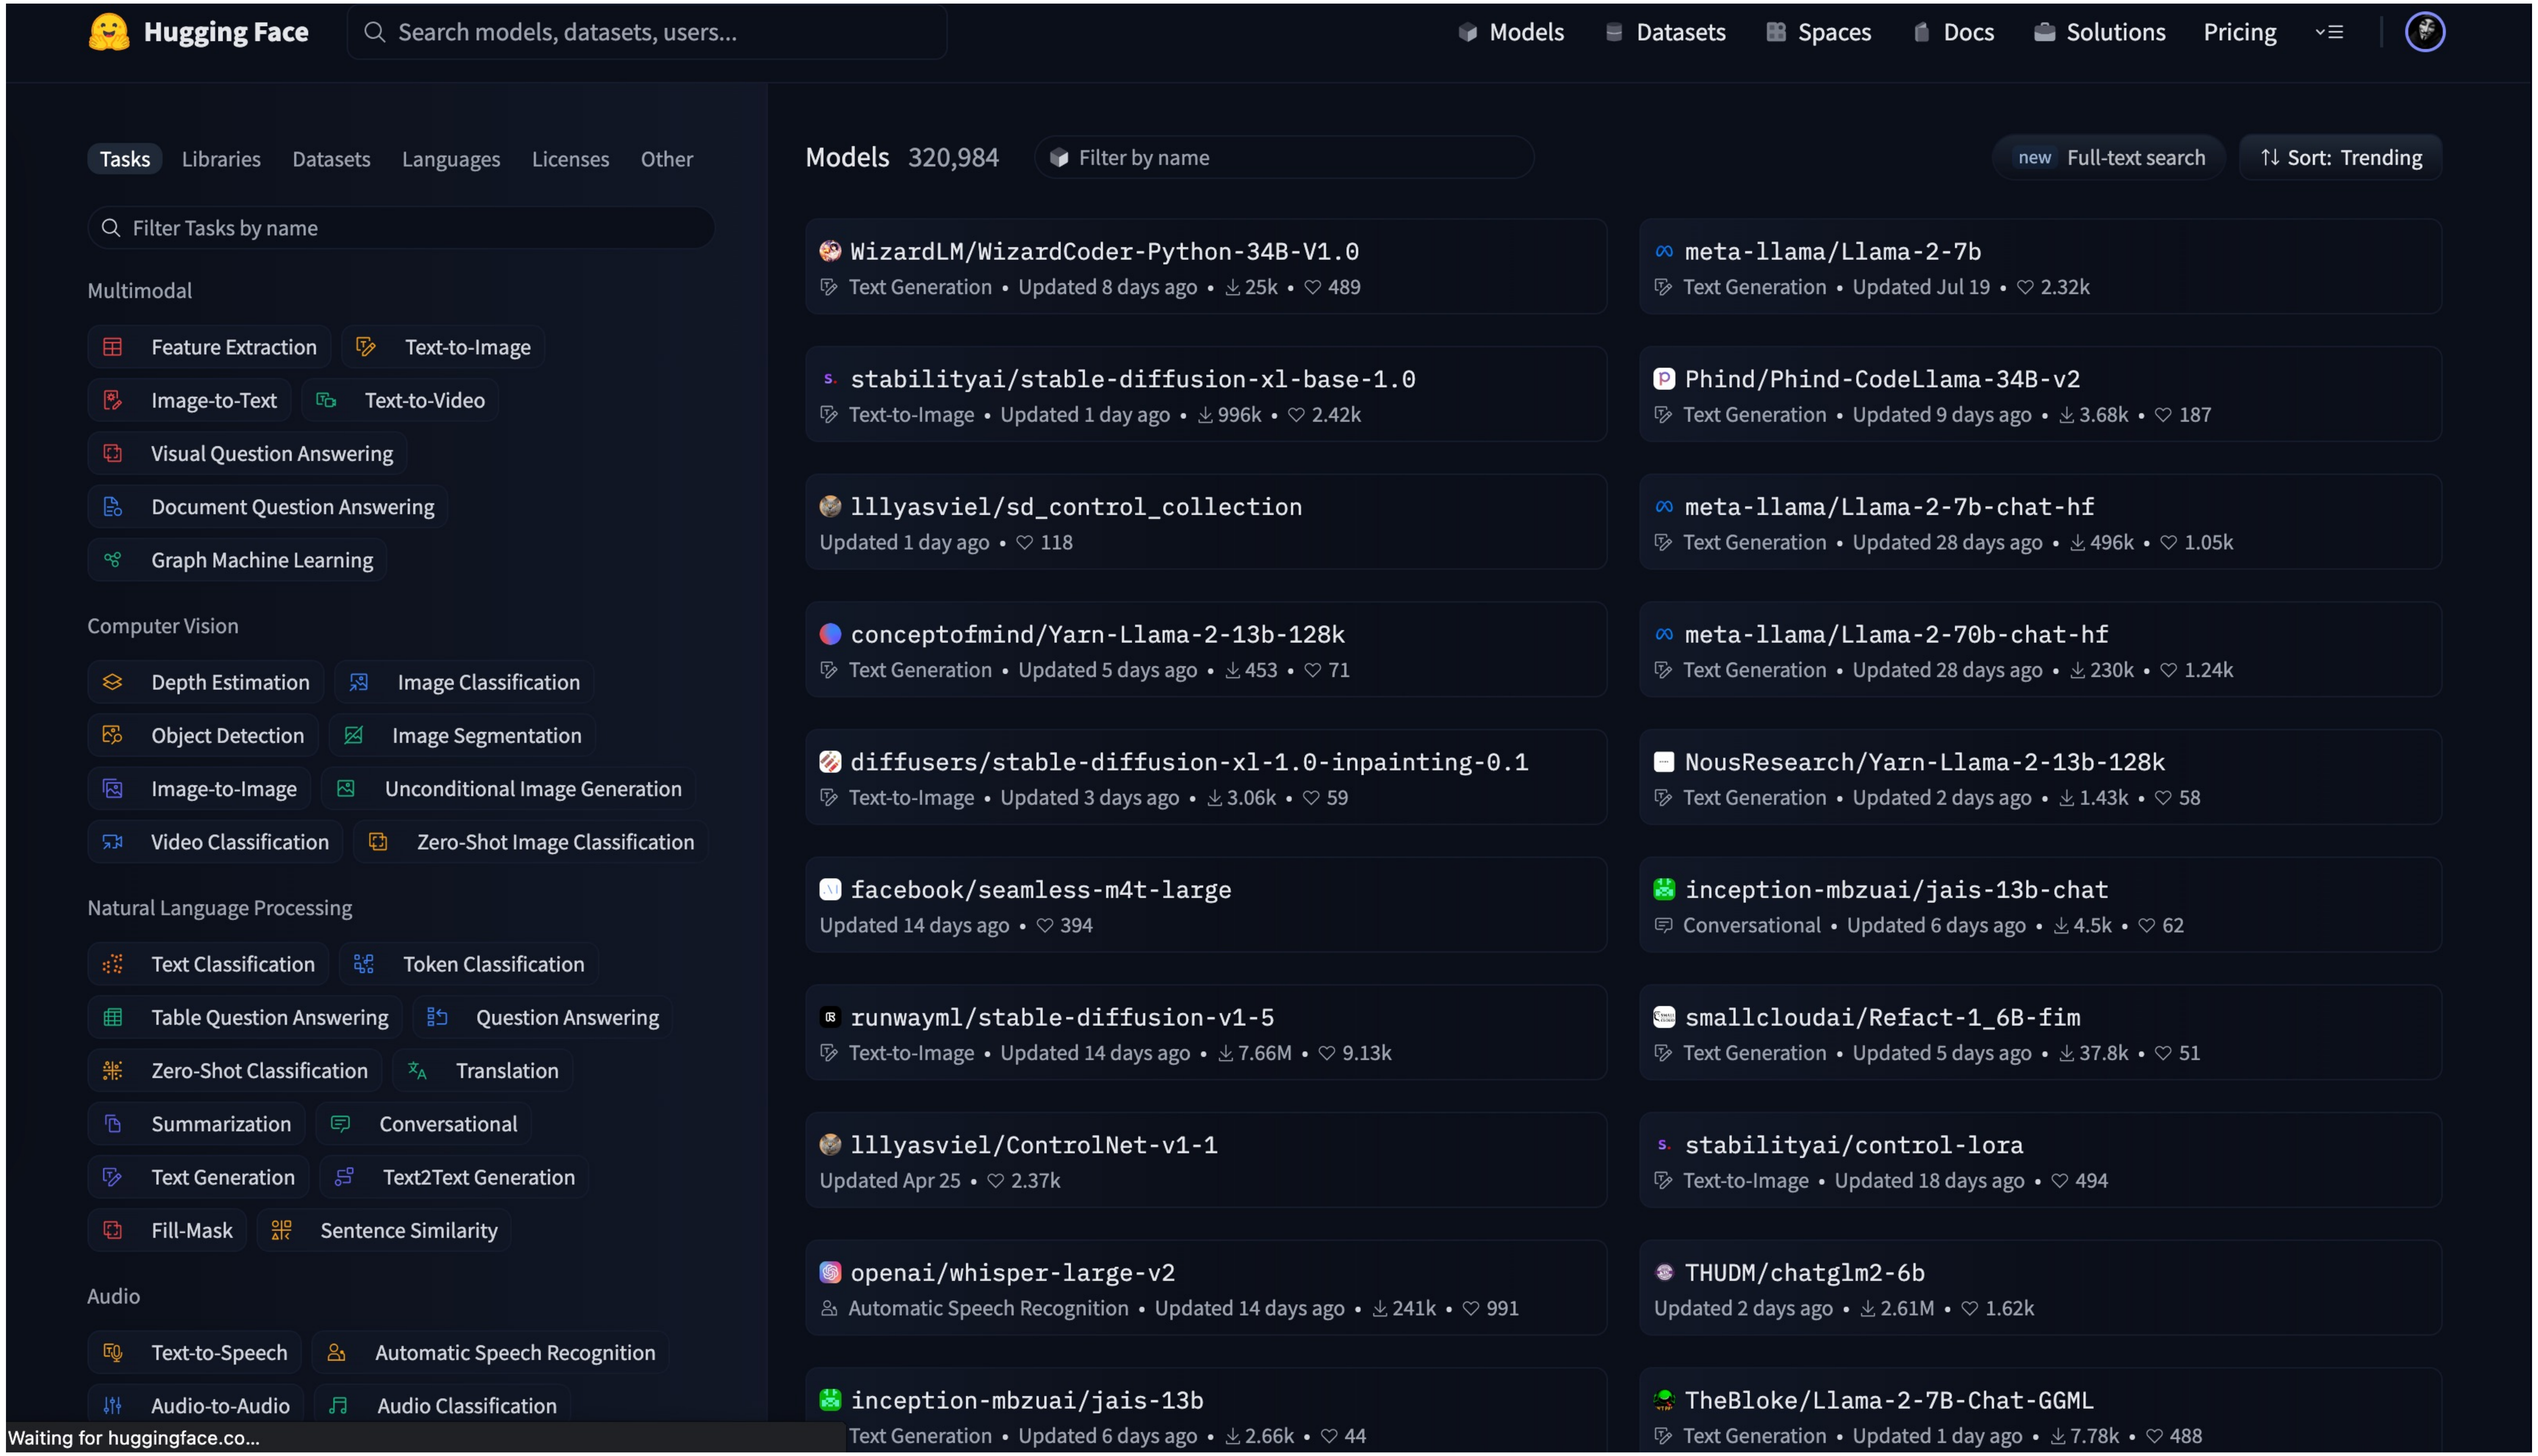

https://huggingface.co/models

Hugging Face Models – meta-llama/Llama-2-7b

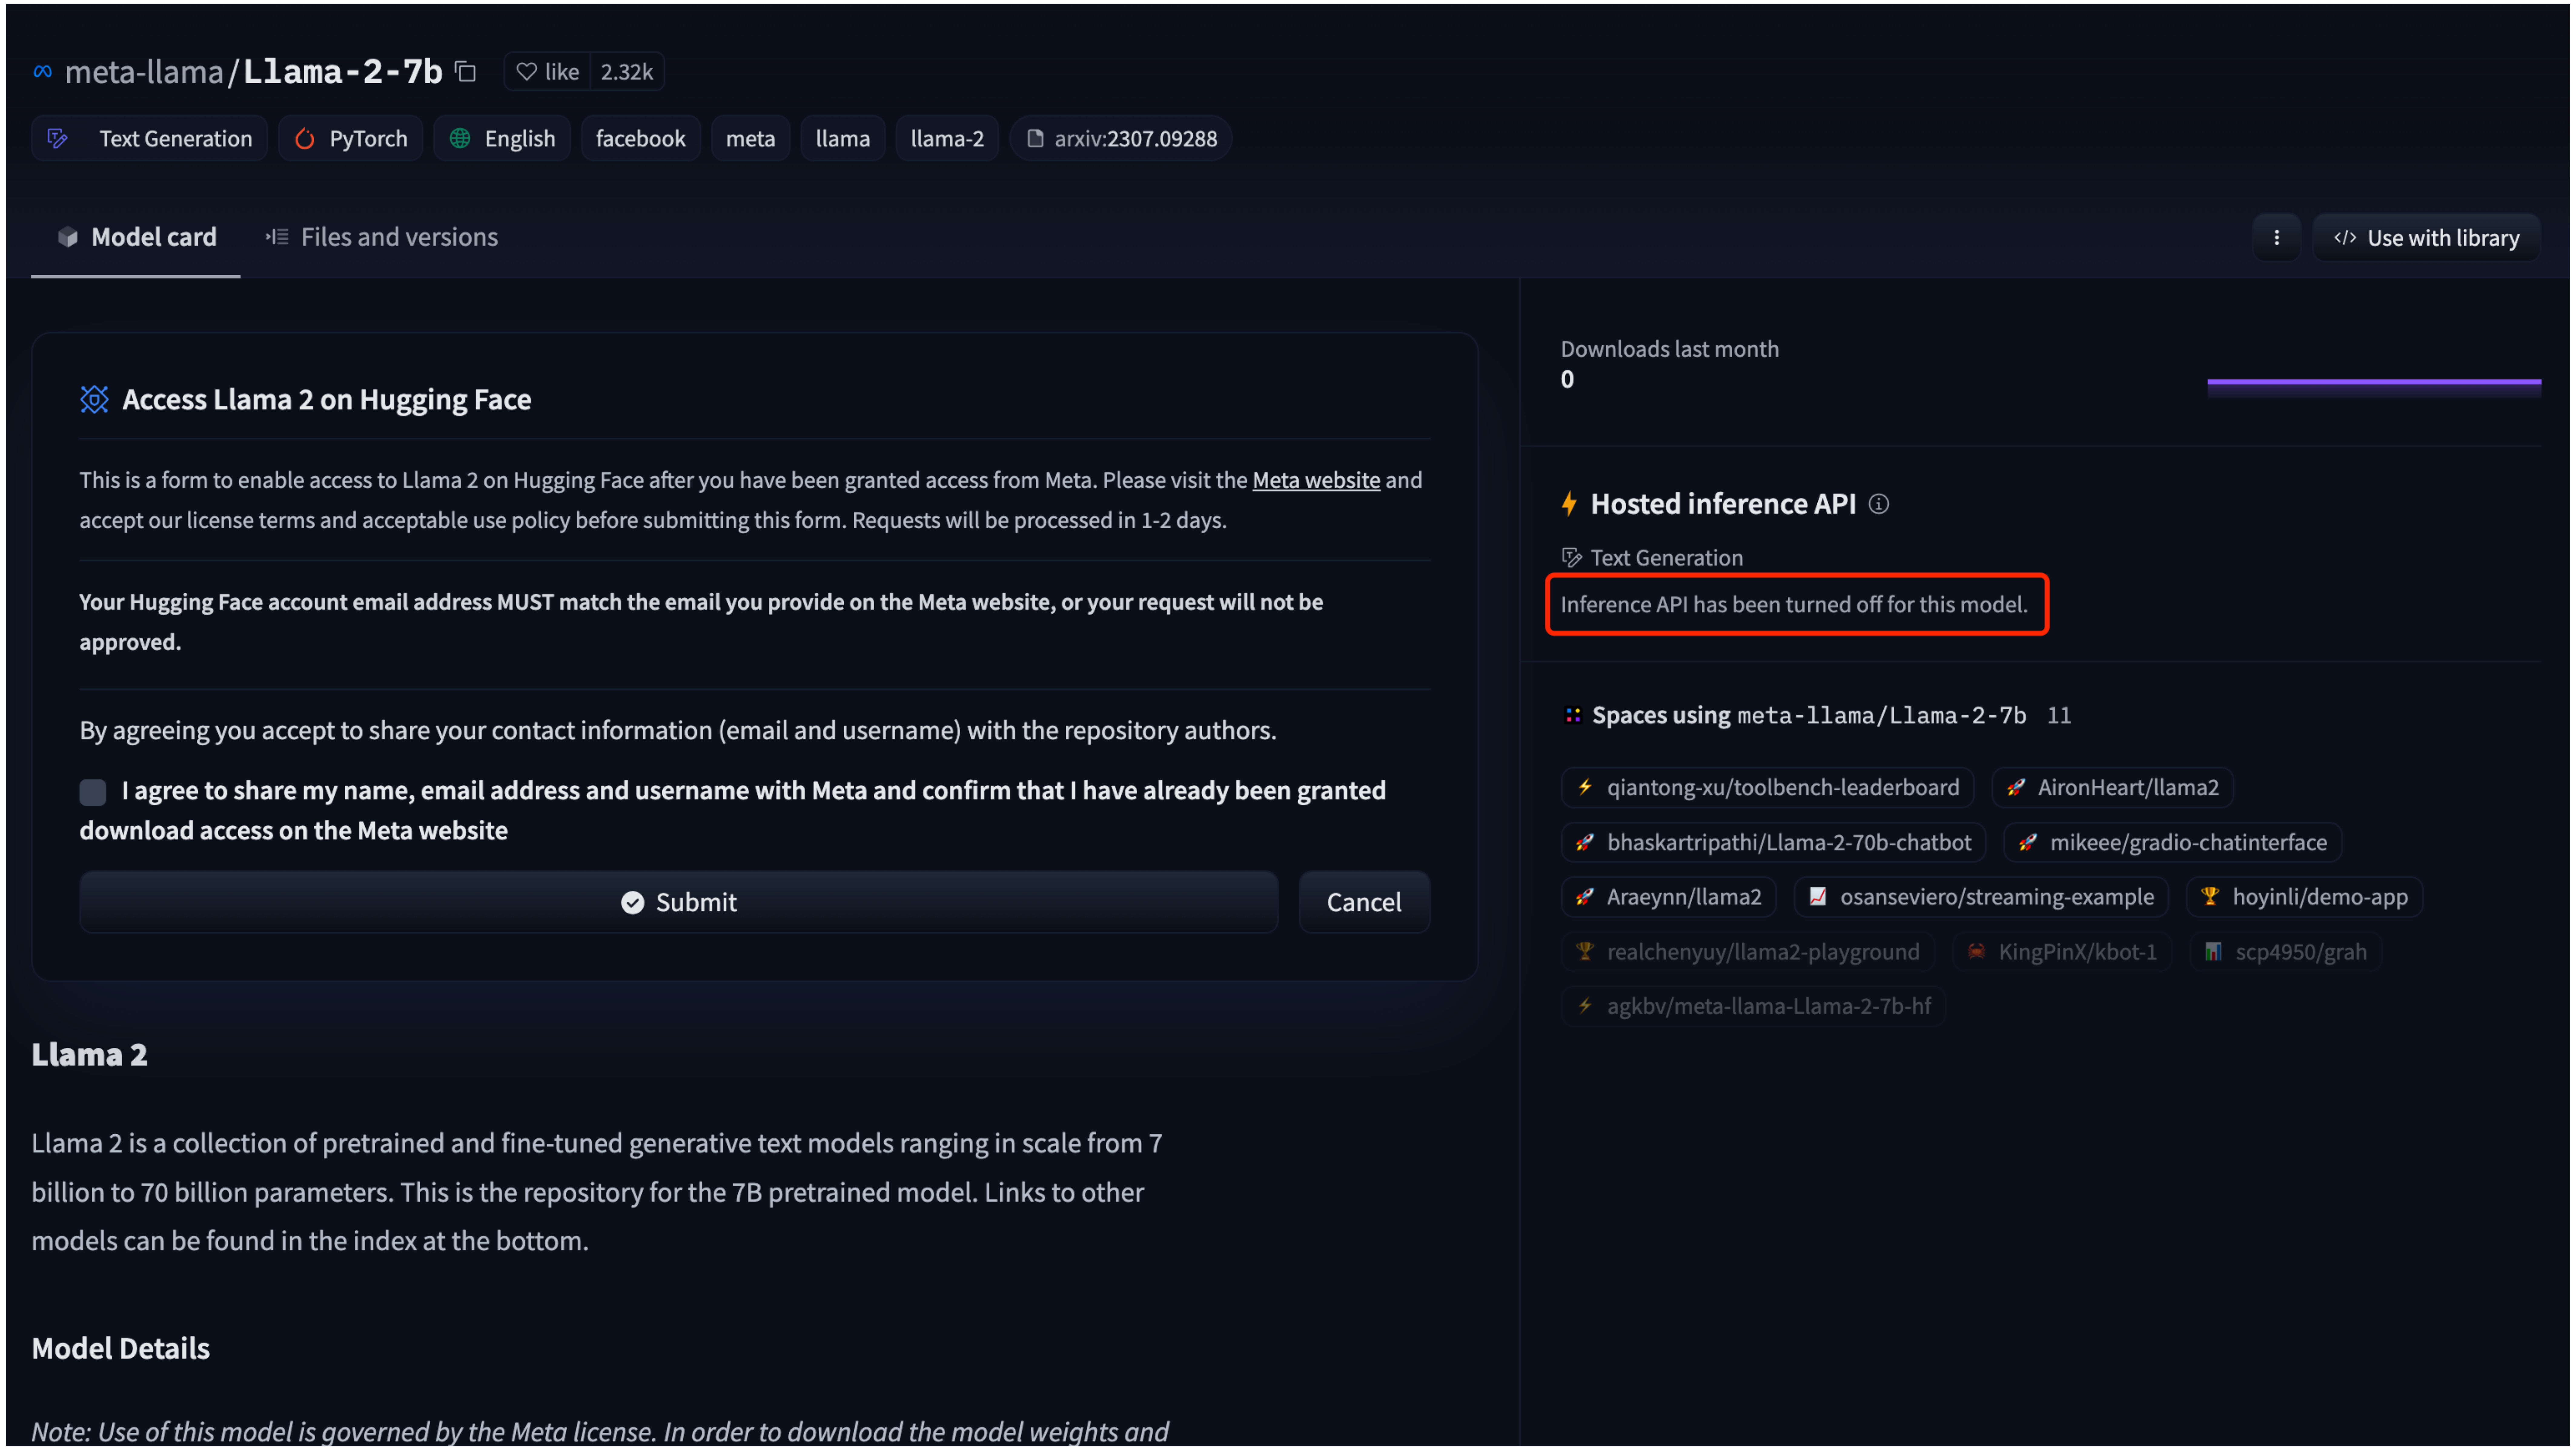

https://huggingface.co/meta-llama/Llama-2-7b

Hugging Face Datasets

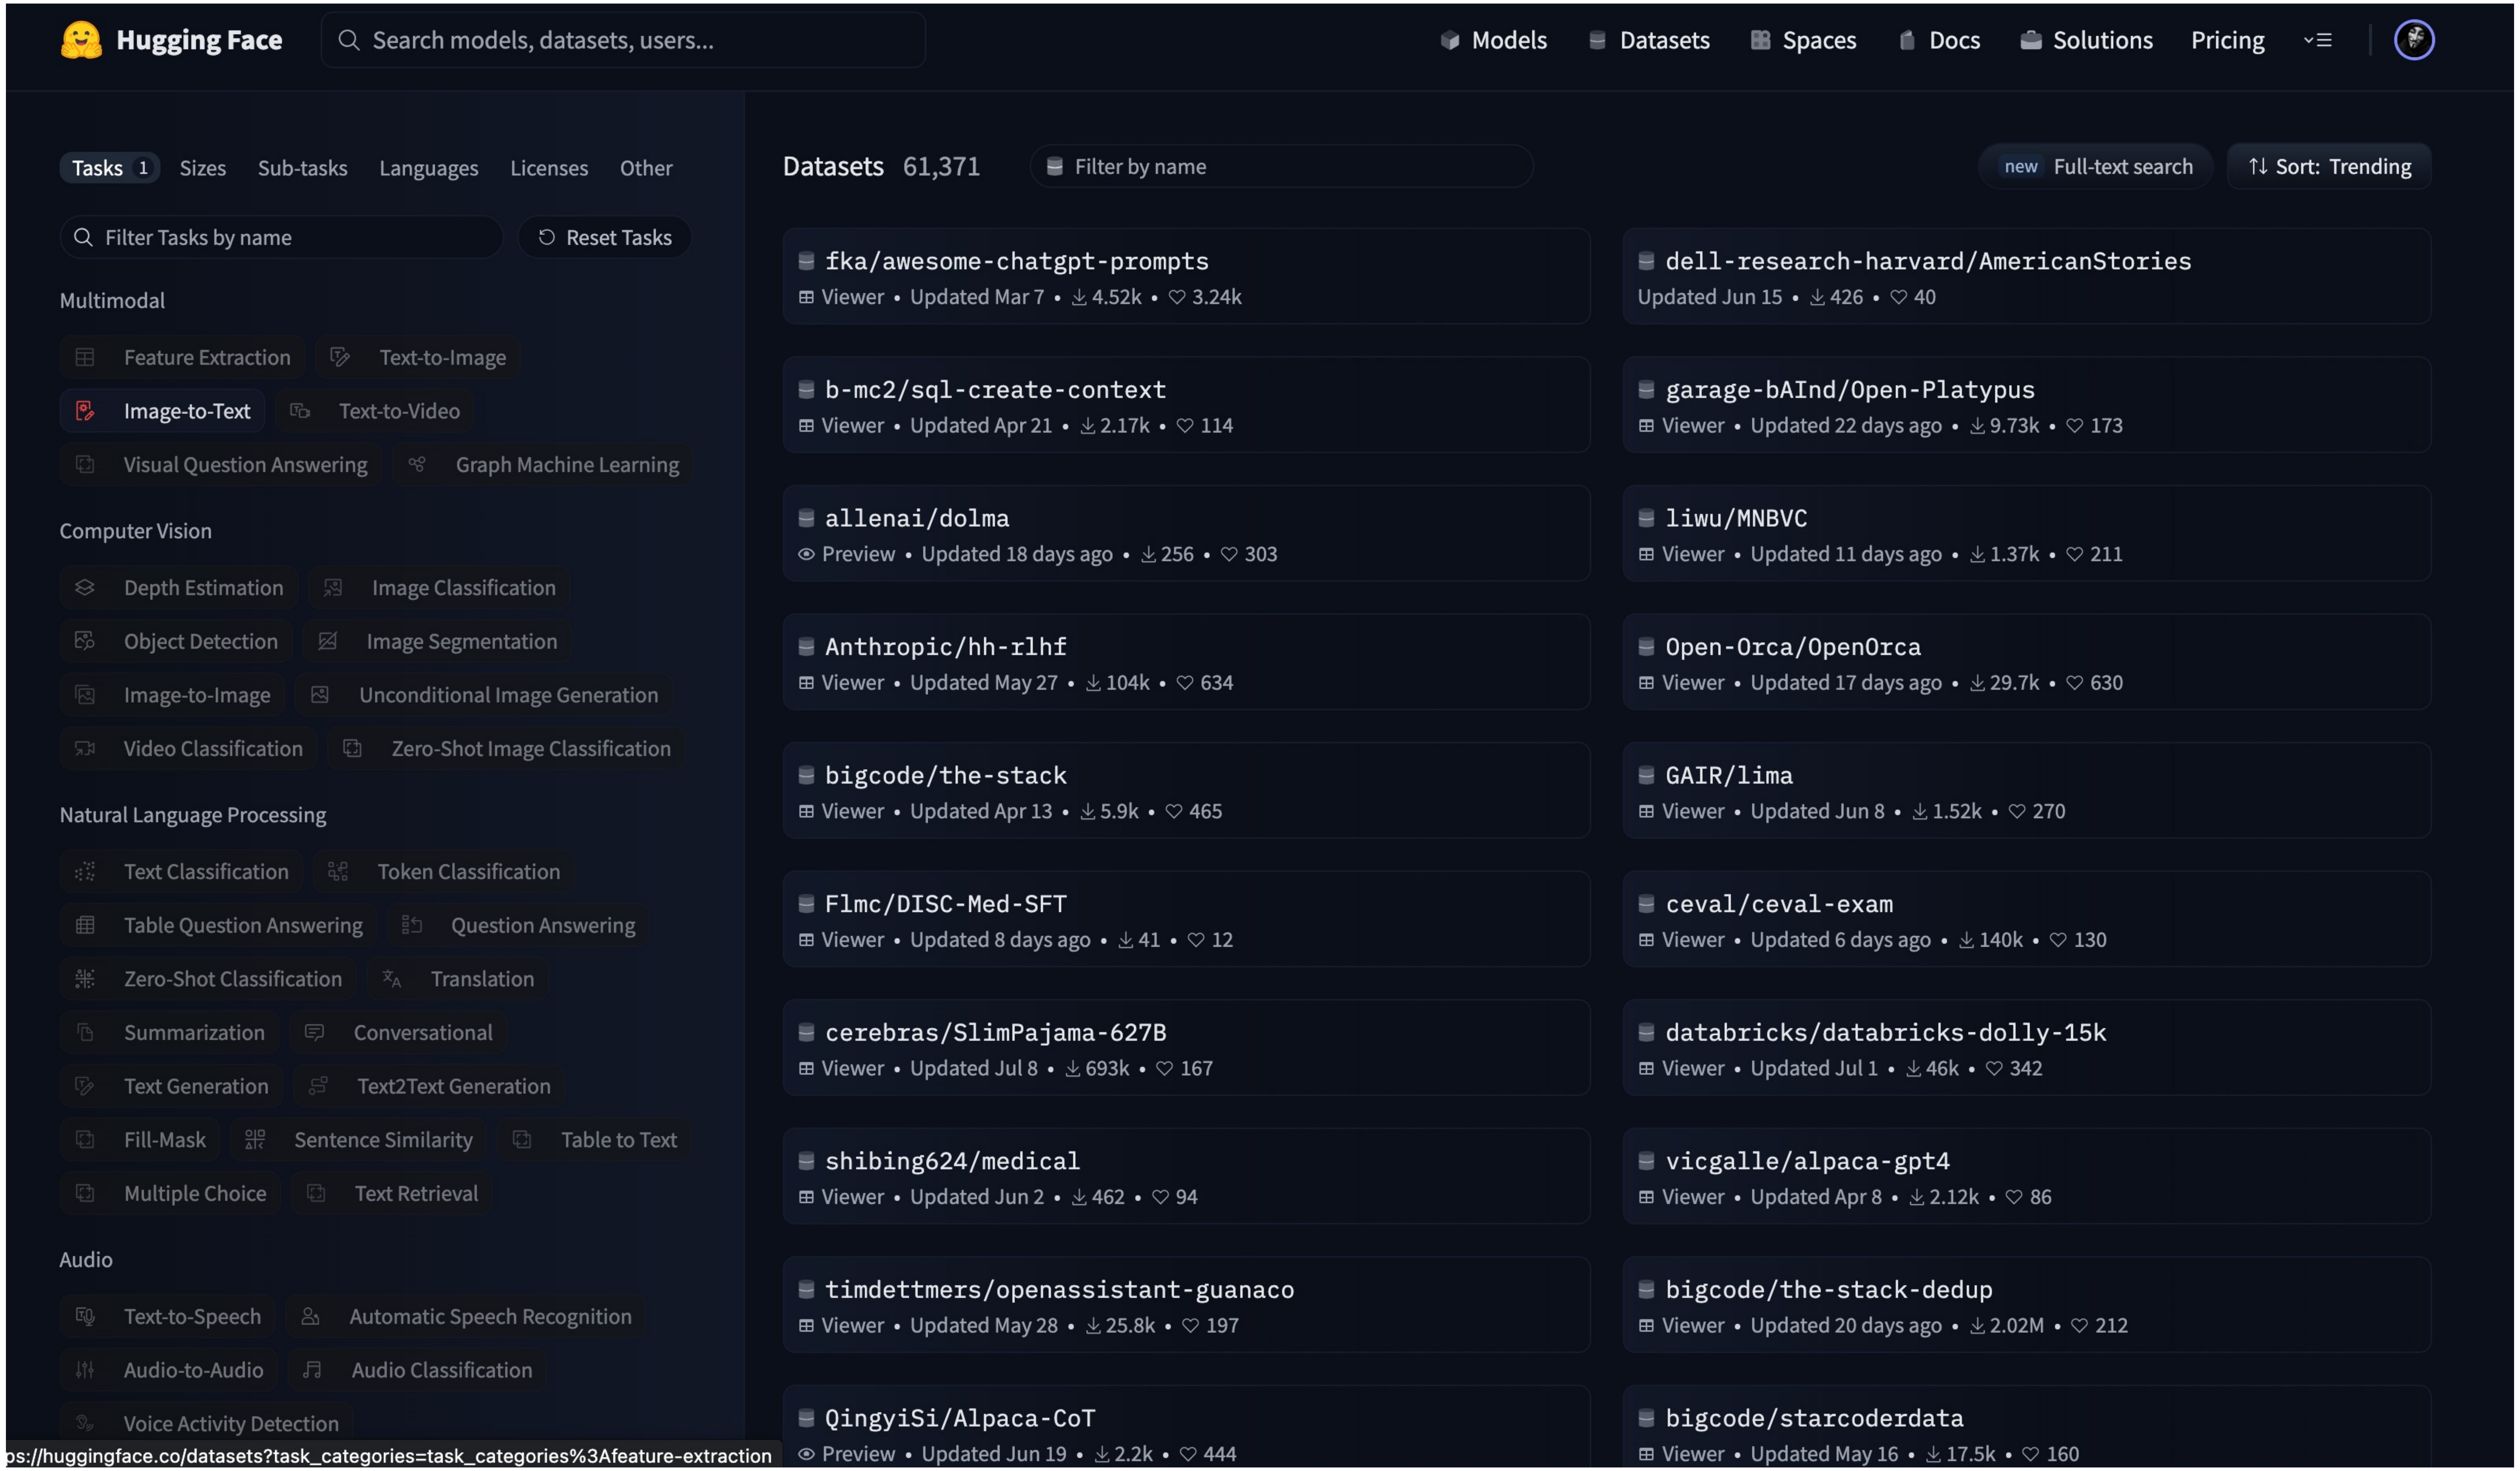

https://huggingface.co/datasets

Hugging Face Datasets – b-mc2/sql-create-context

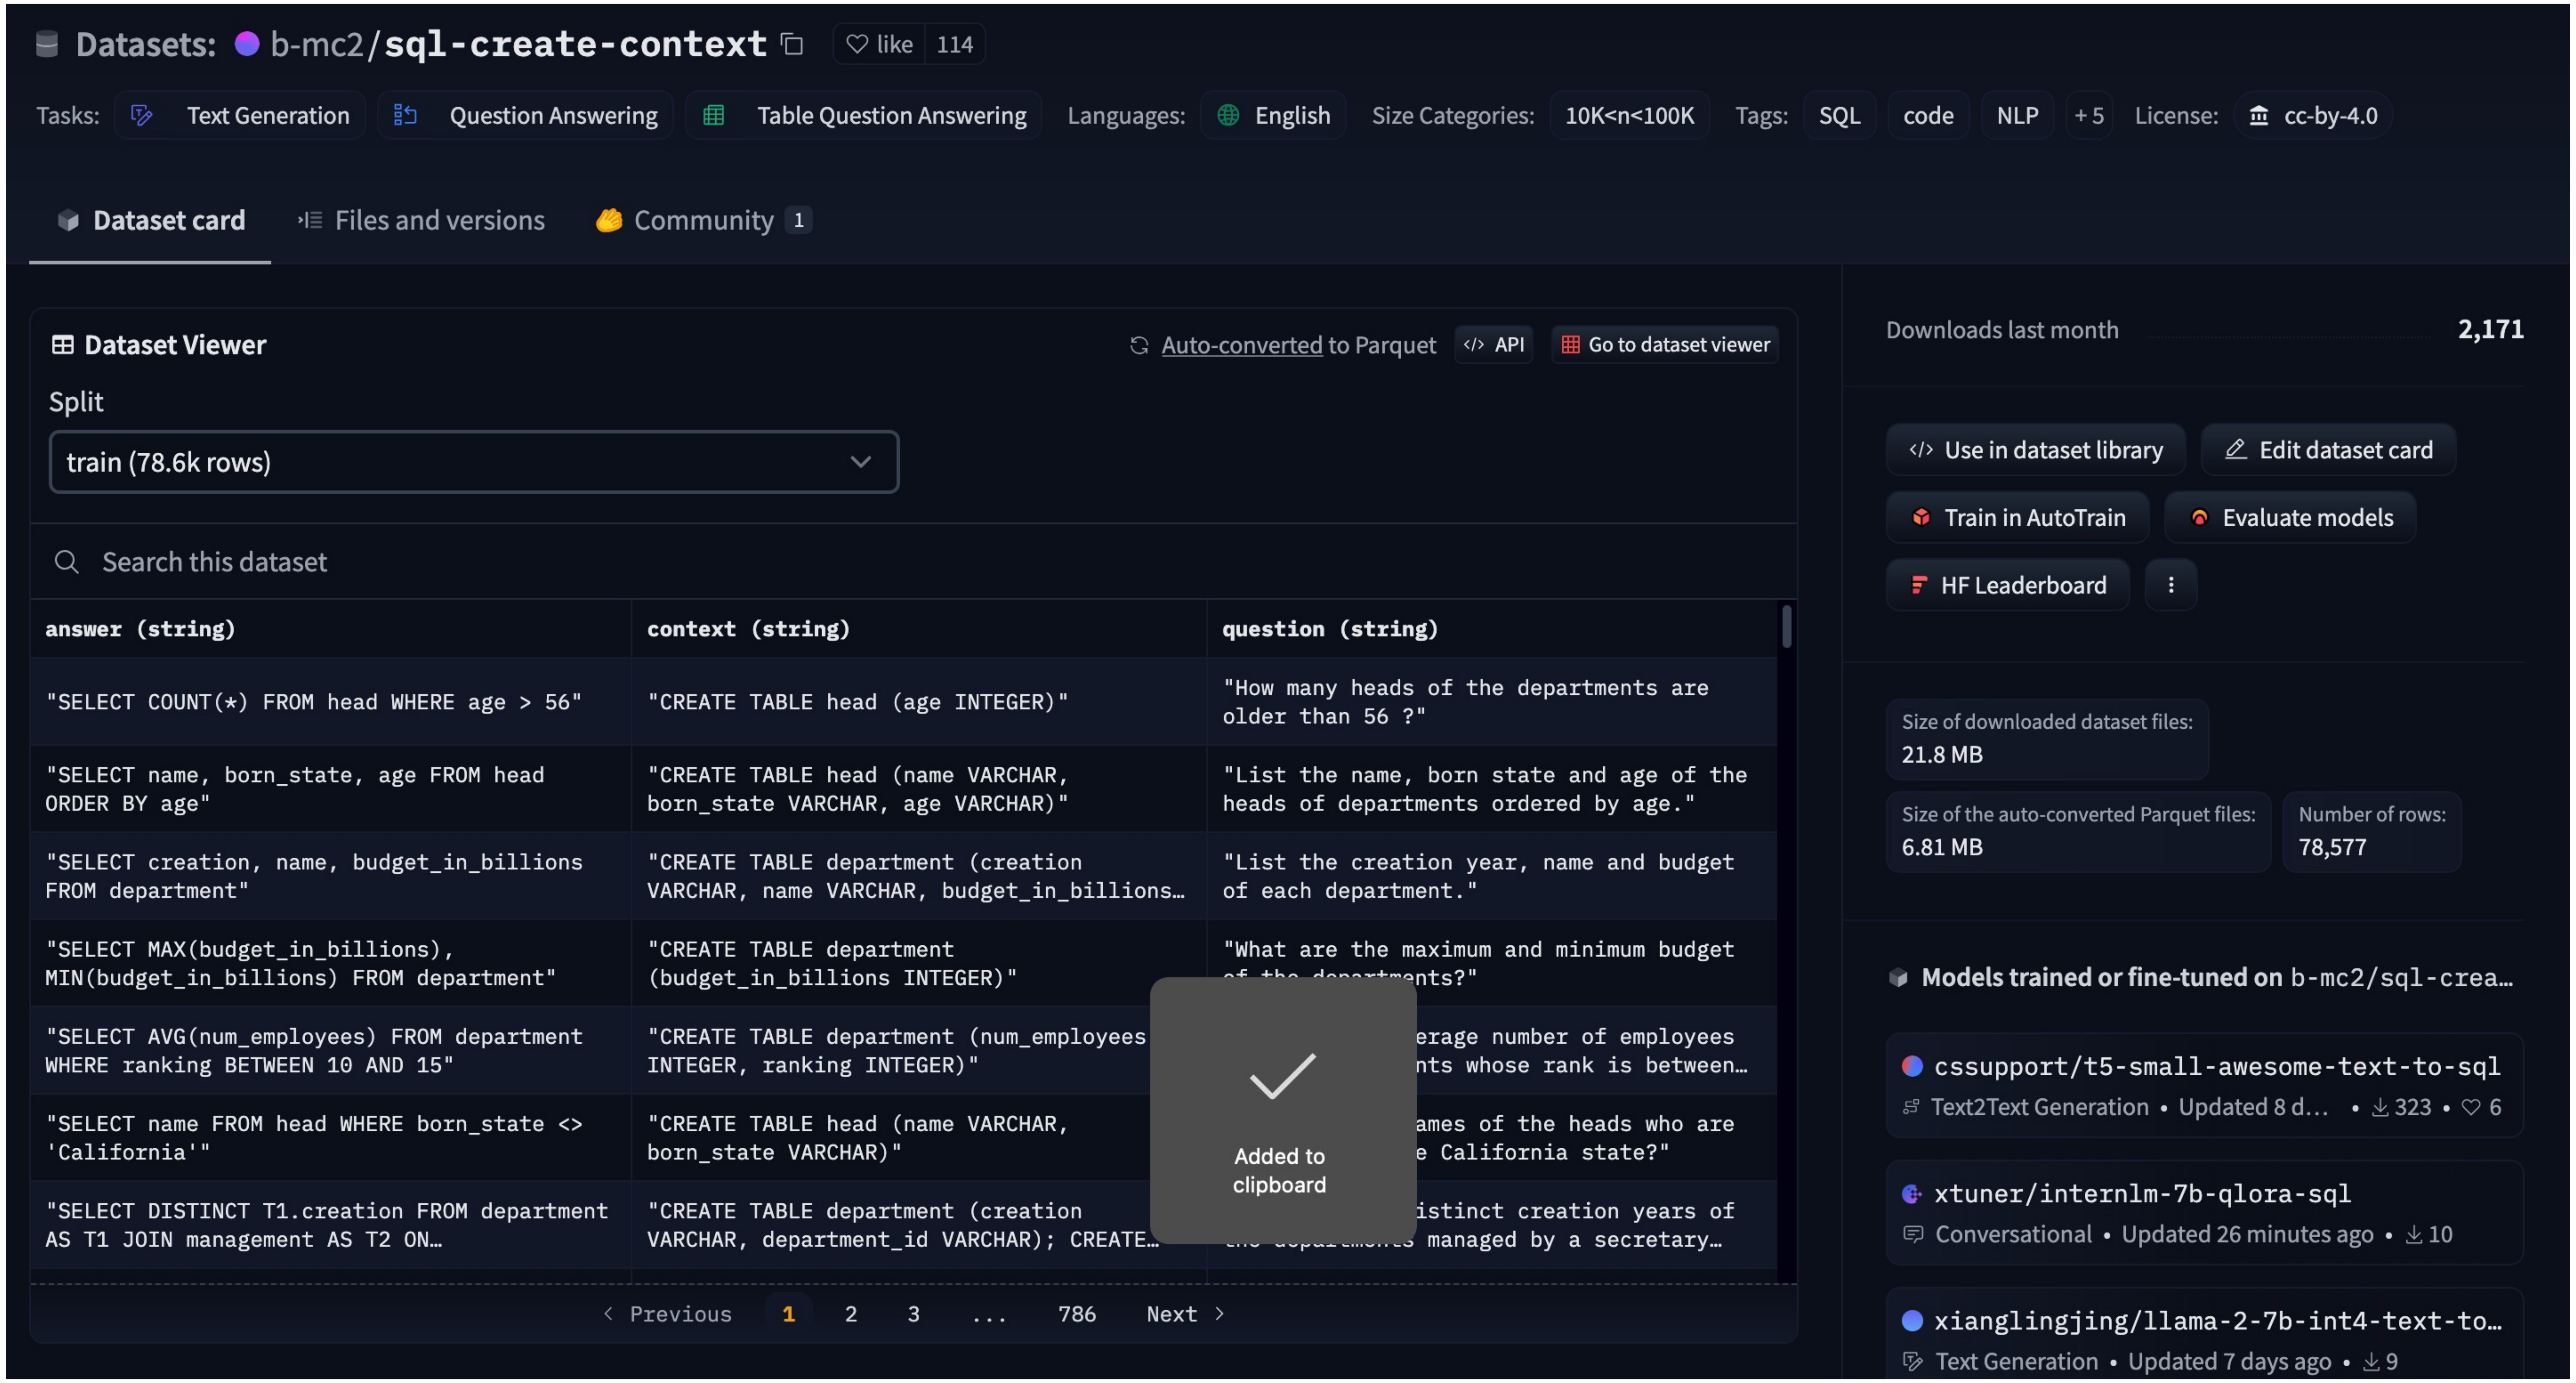

Hugging Face Spaces

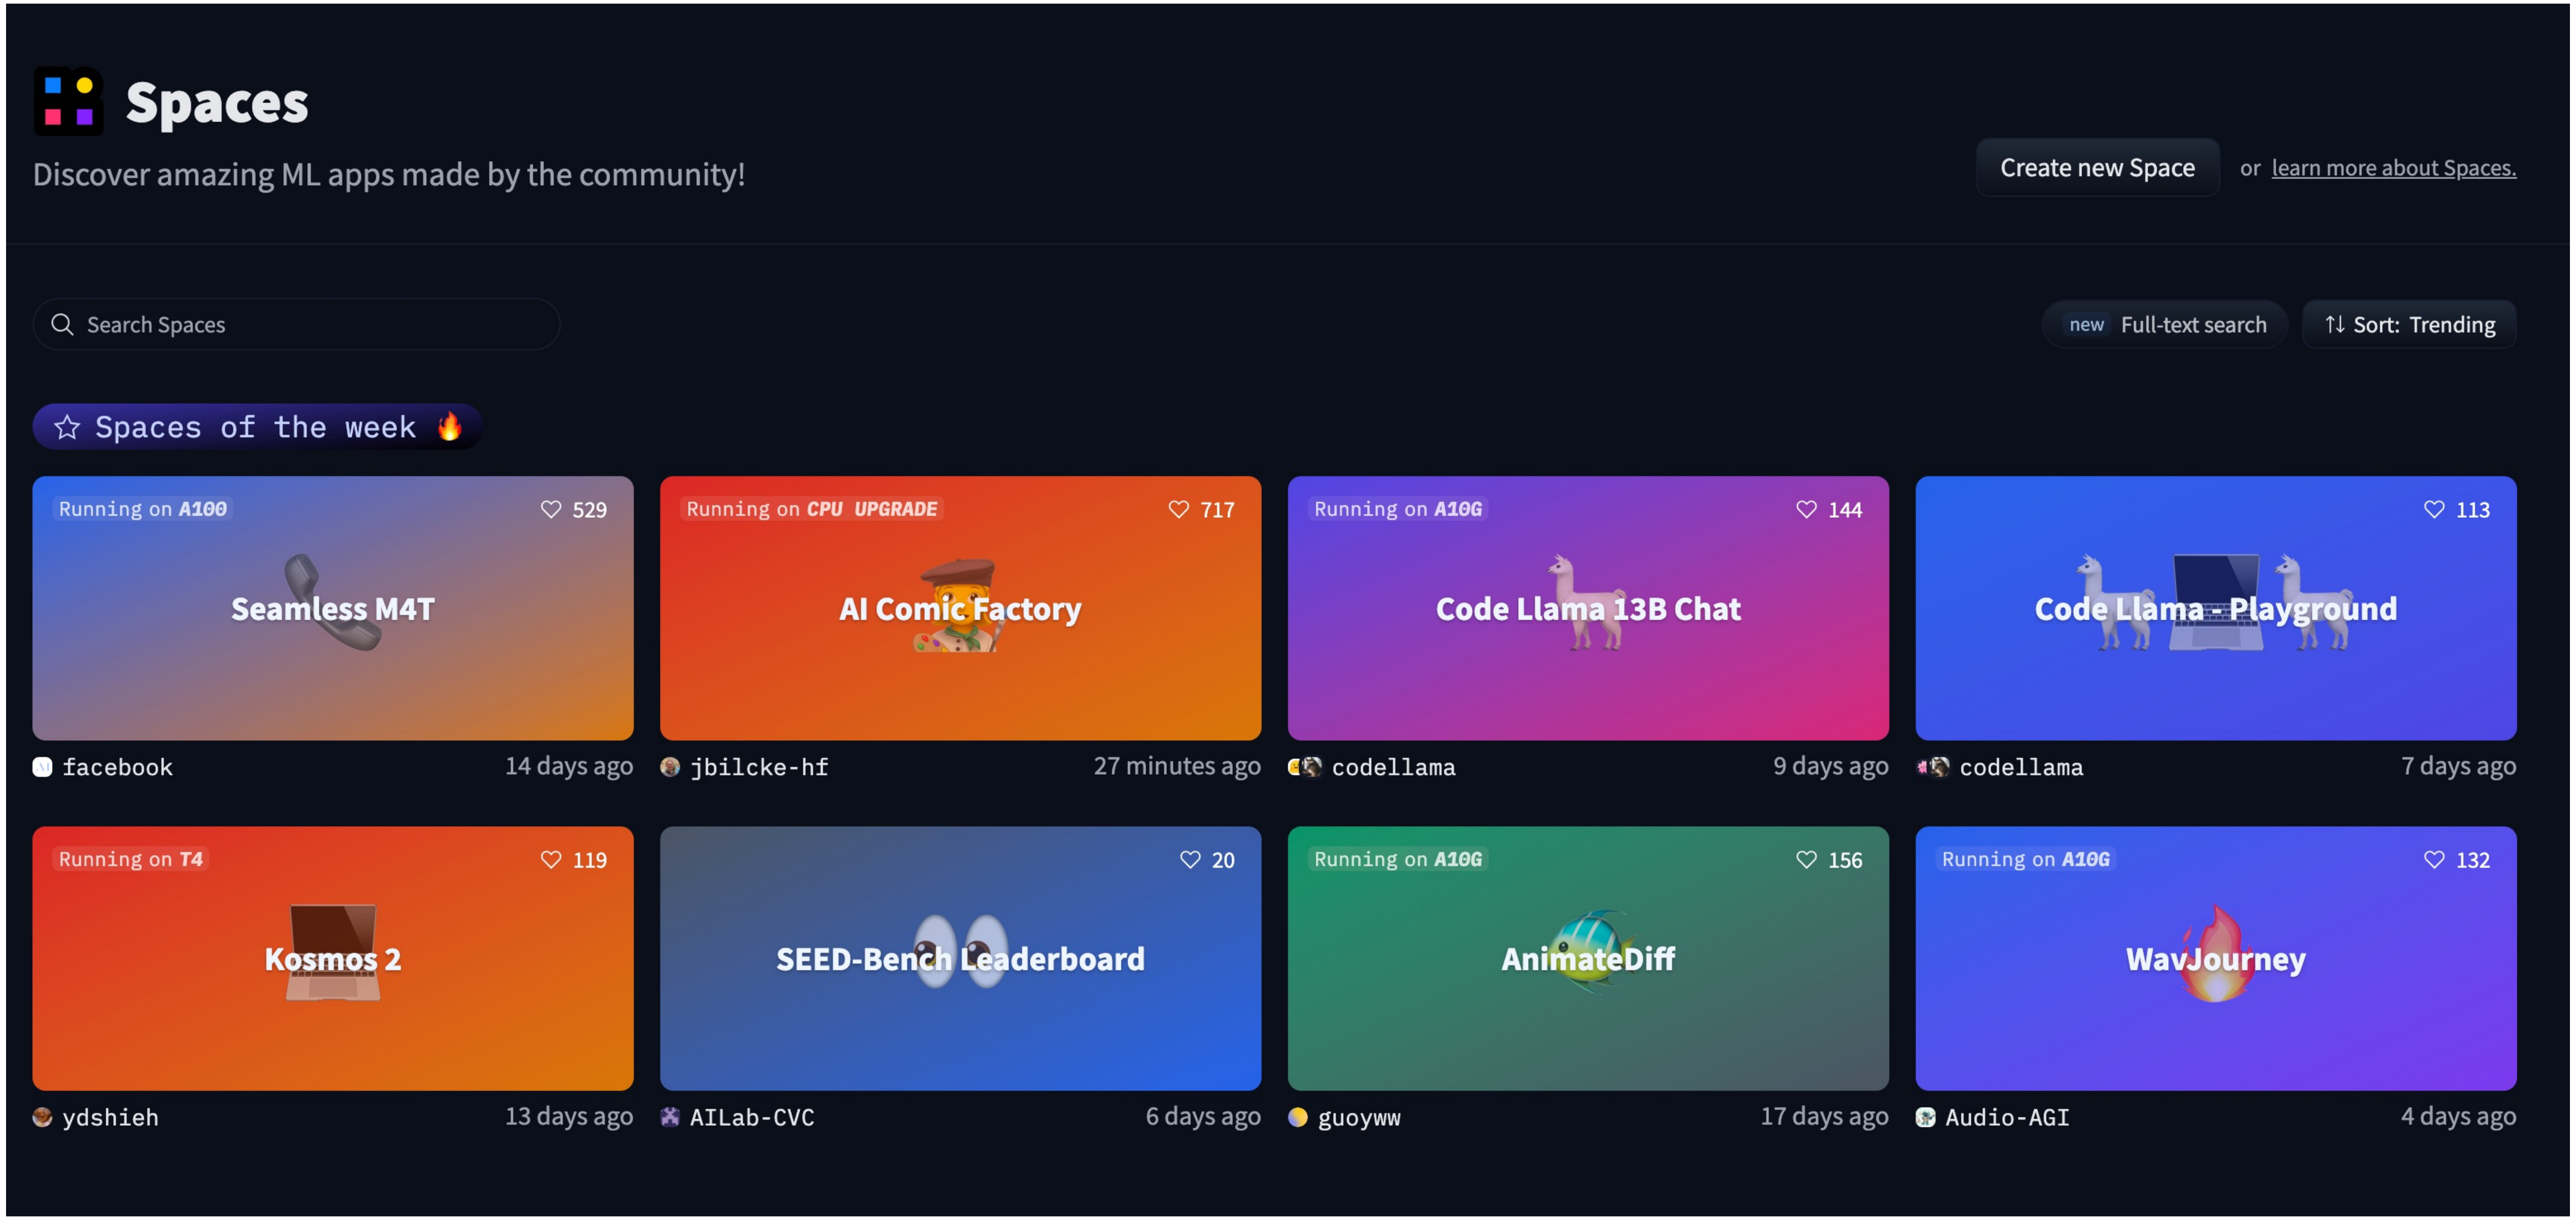

https://huggingface.co/spaces

Hugging Face Spaces – Facebook/seamless_m4t

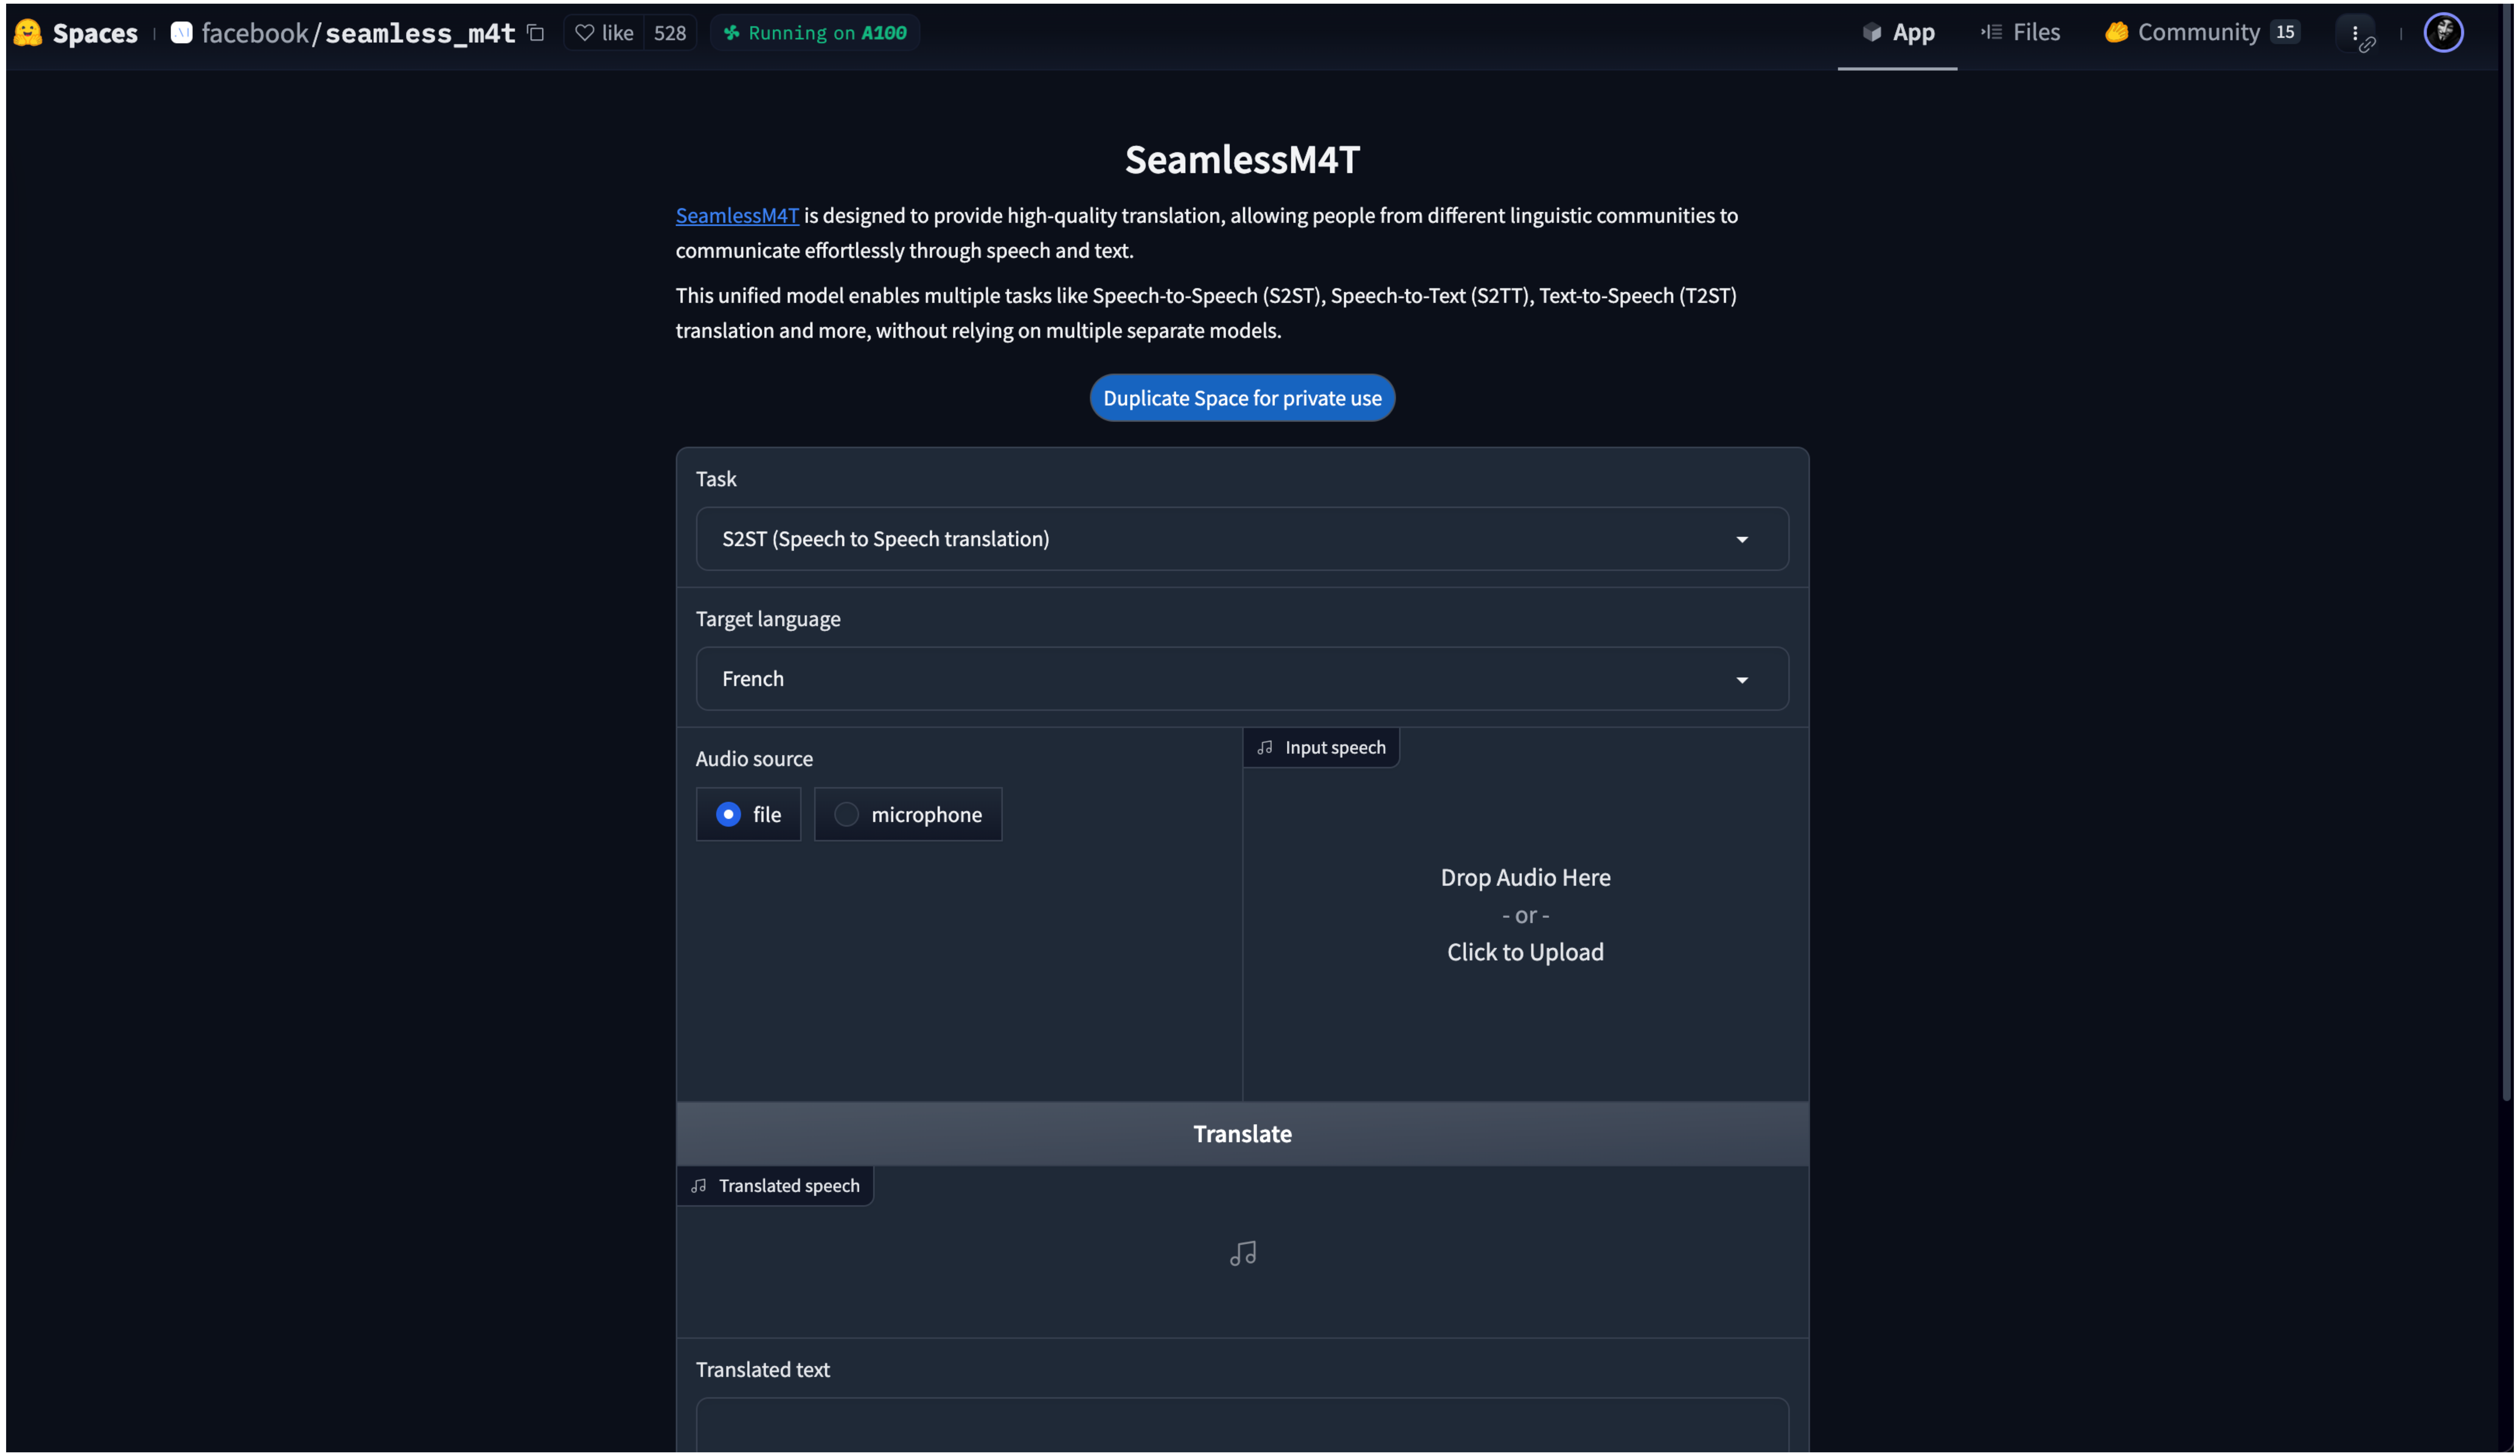

https://huggingface.co/spaces/facebook/seamless_m4t

Hugging Face Docs

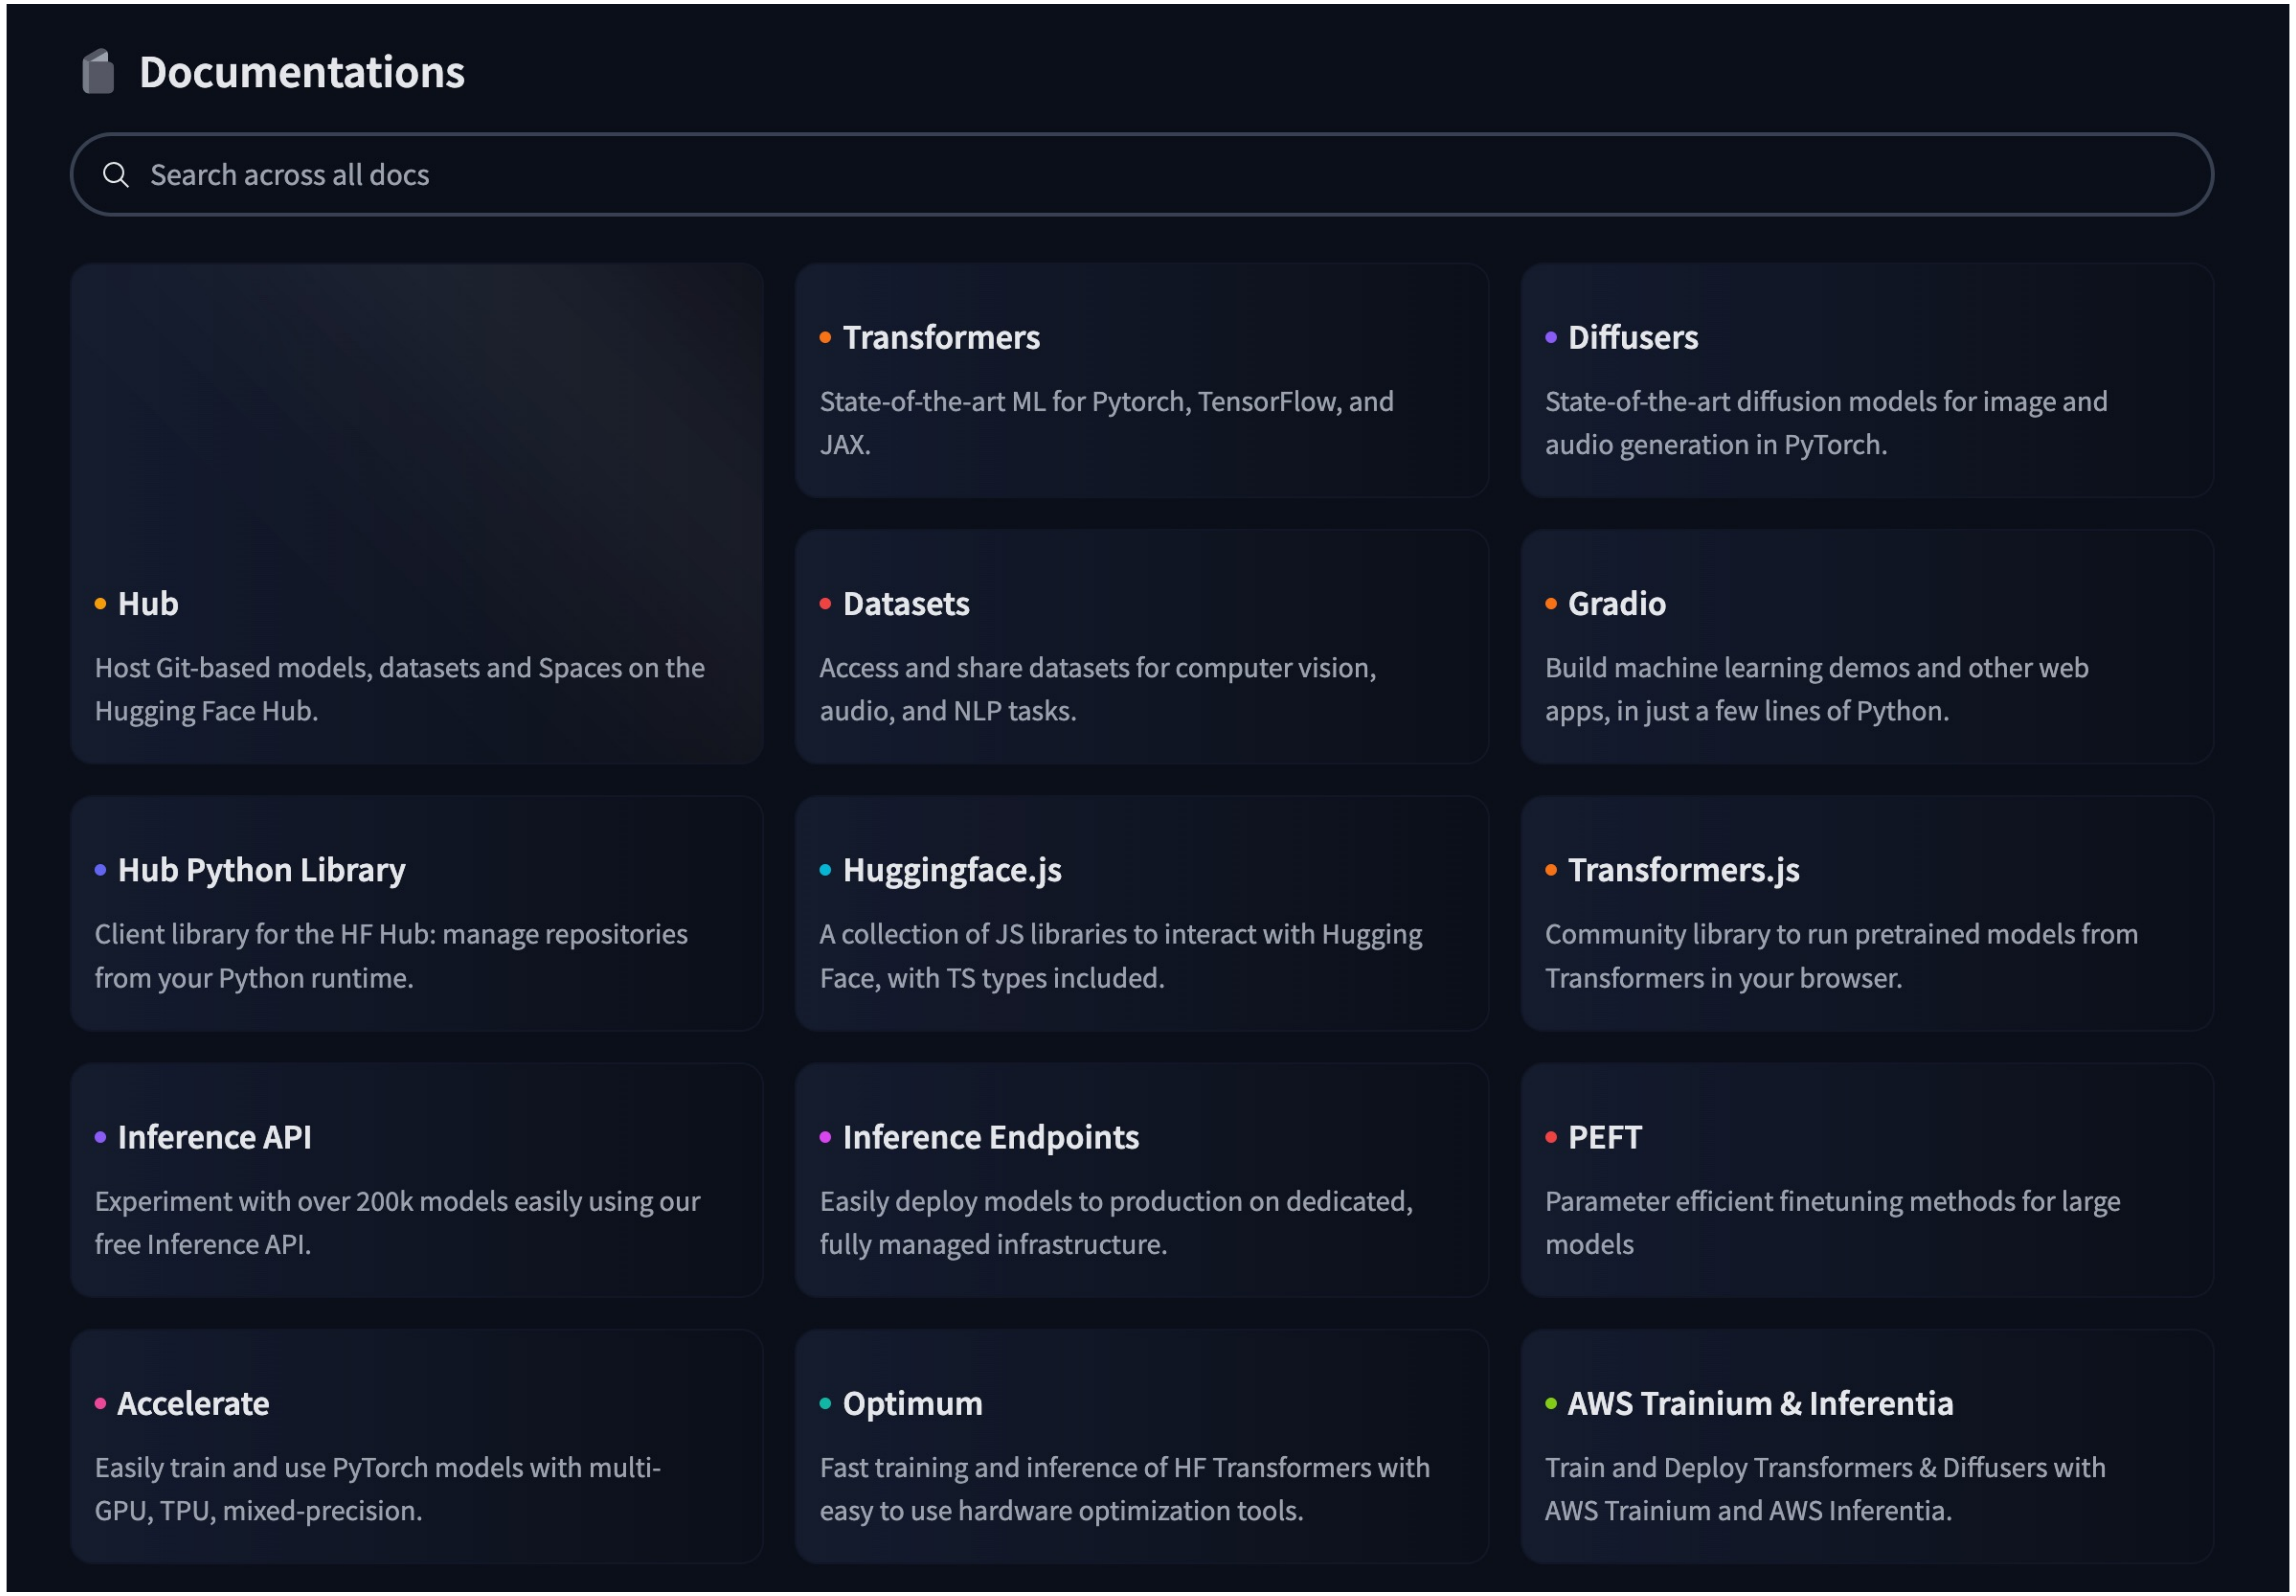

https://huggingface.co/docs

Hugging Face Docs - Transformers

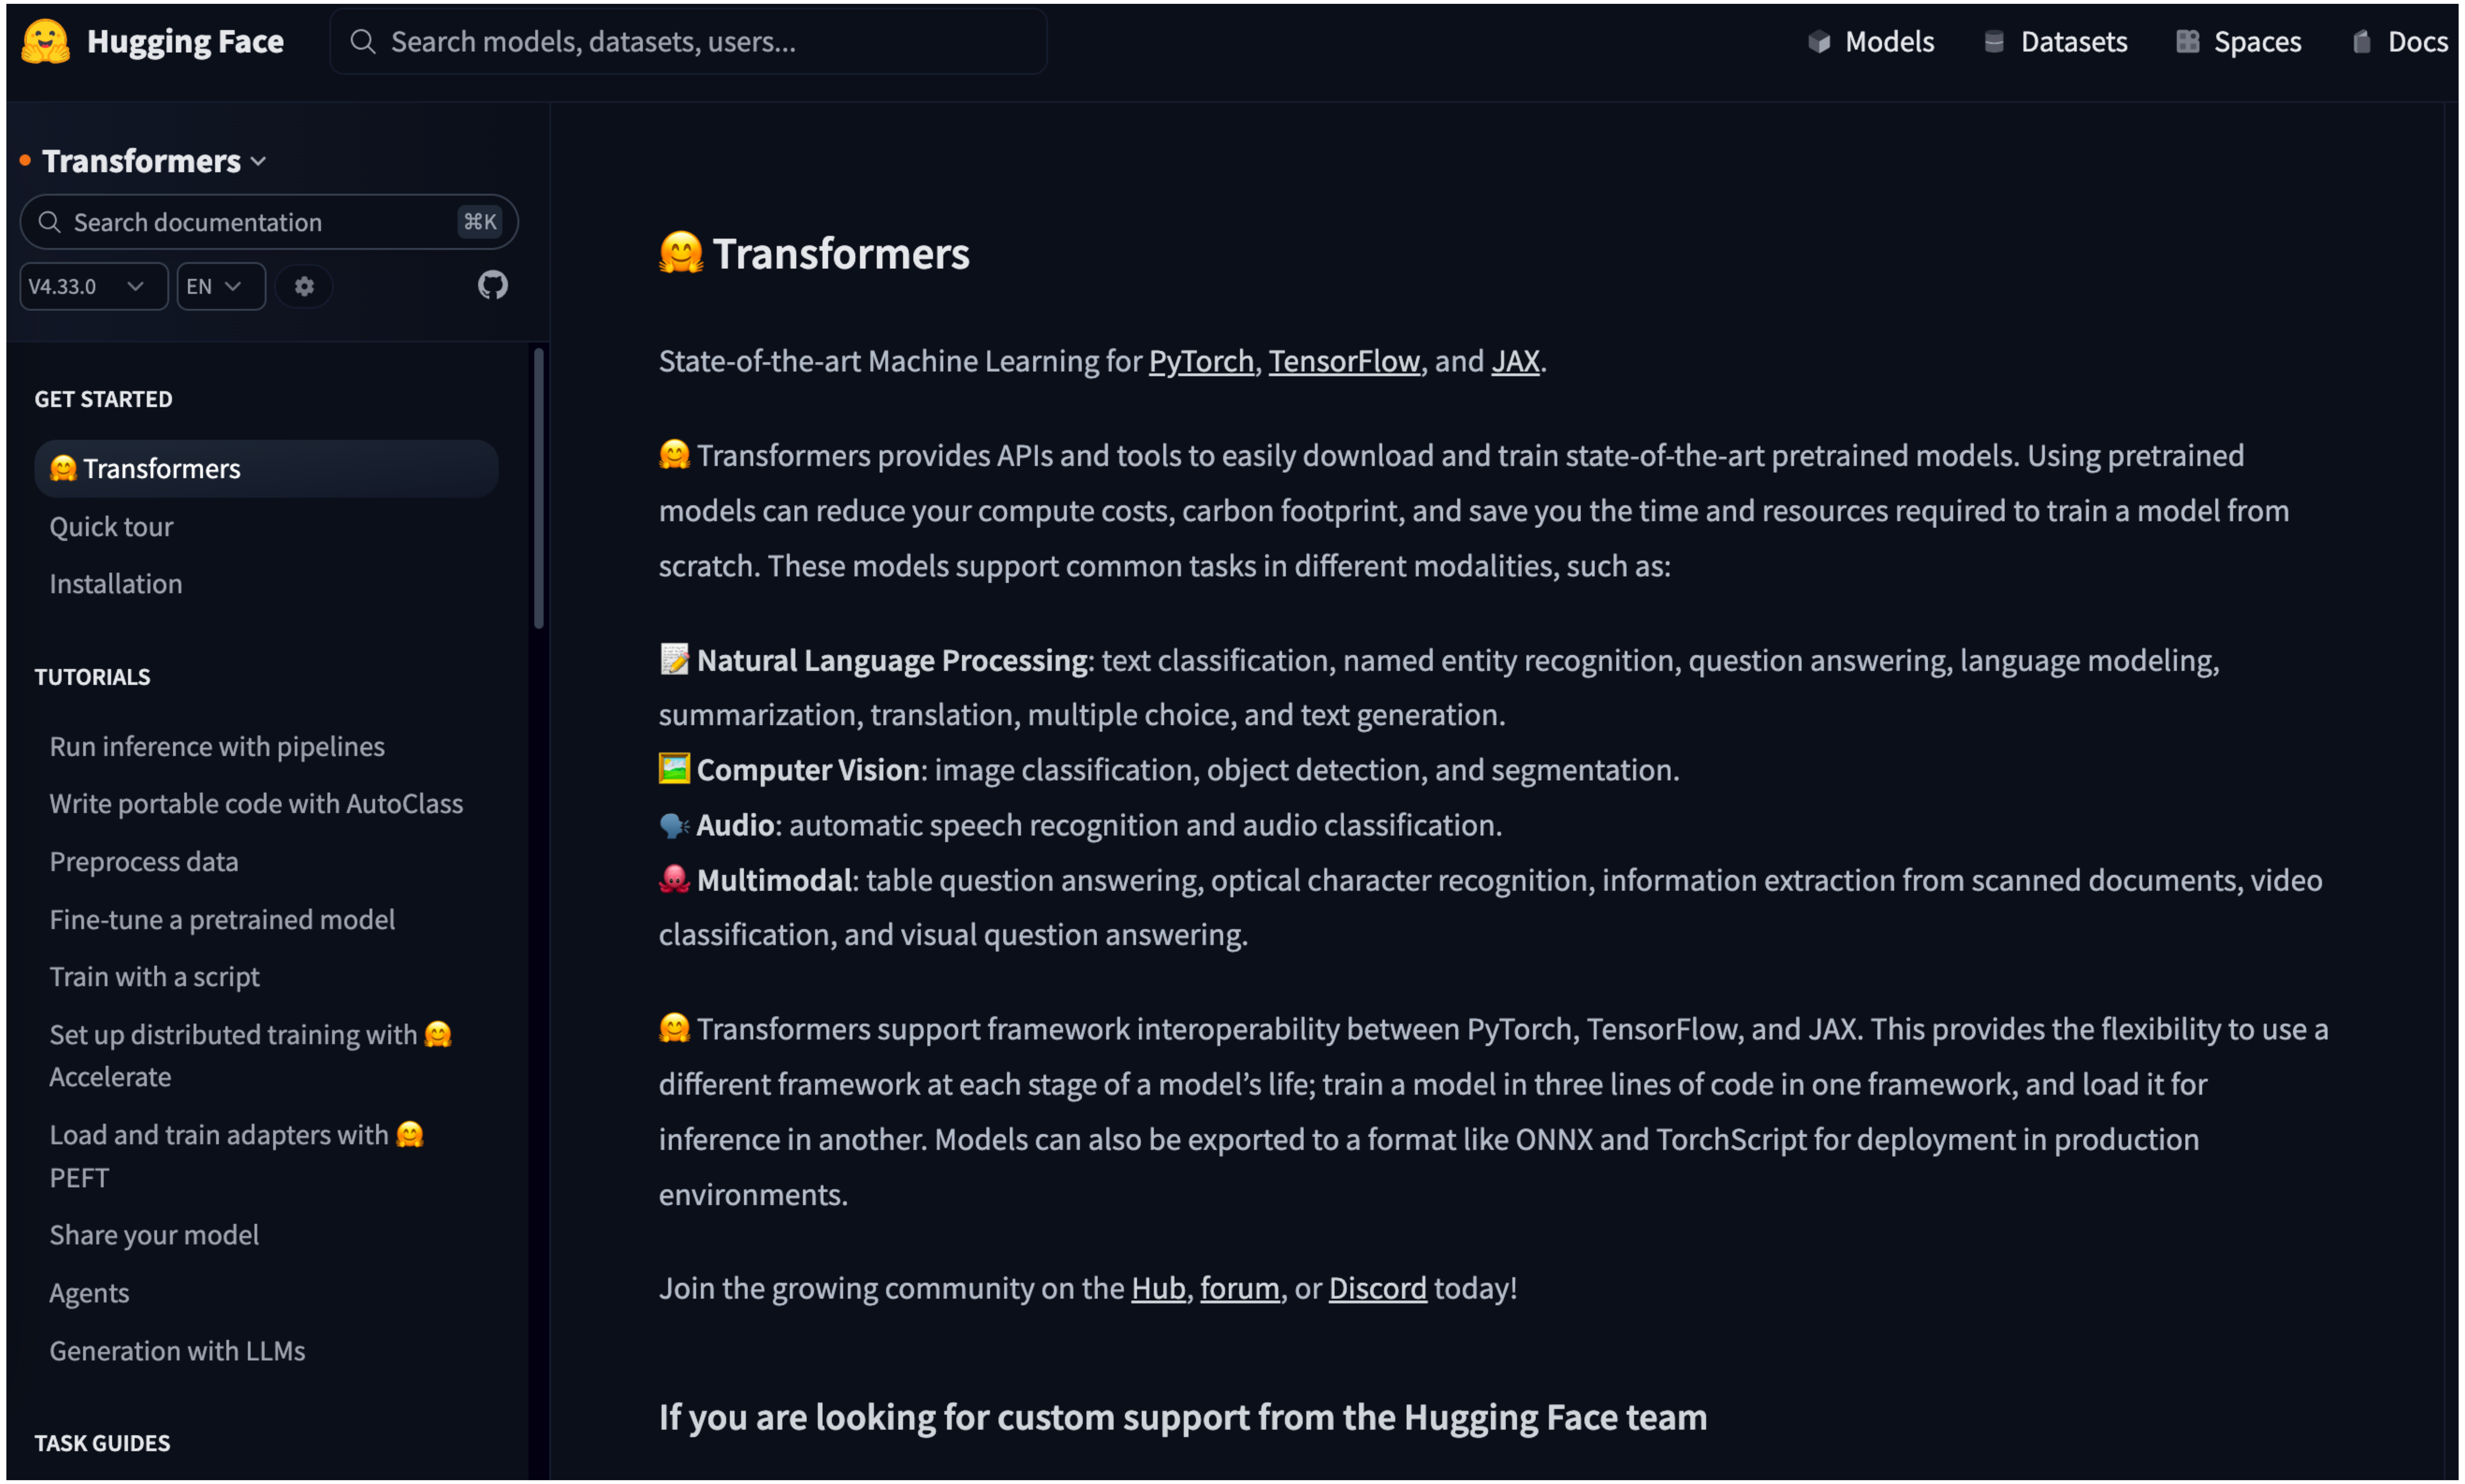

https://huggingface.co/docs/transformers/index

大模型横向对比

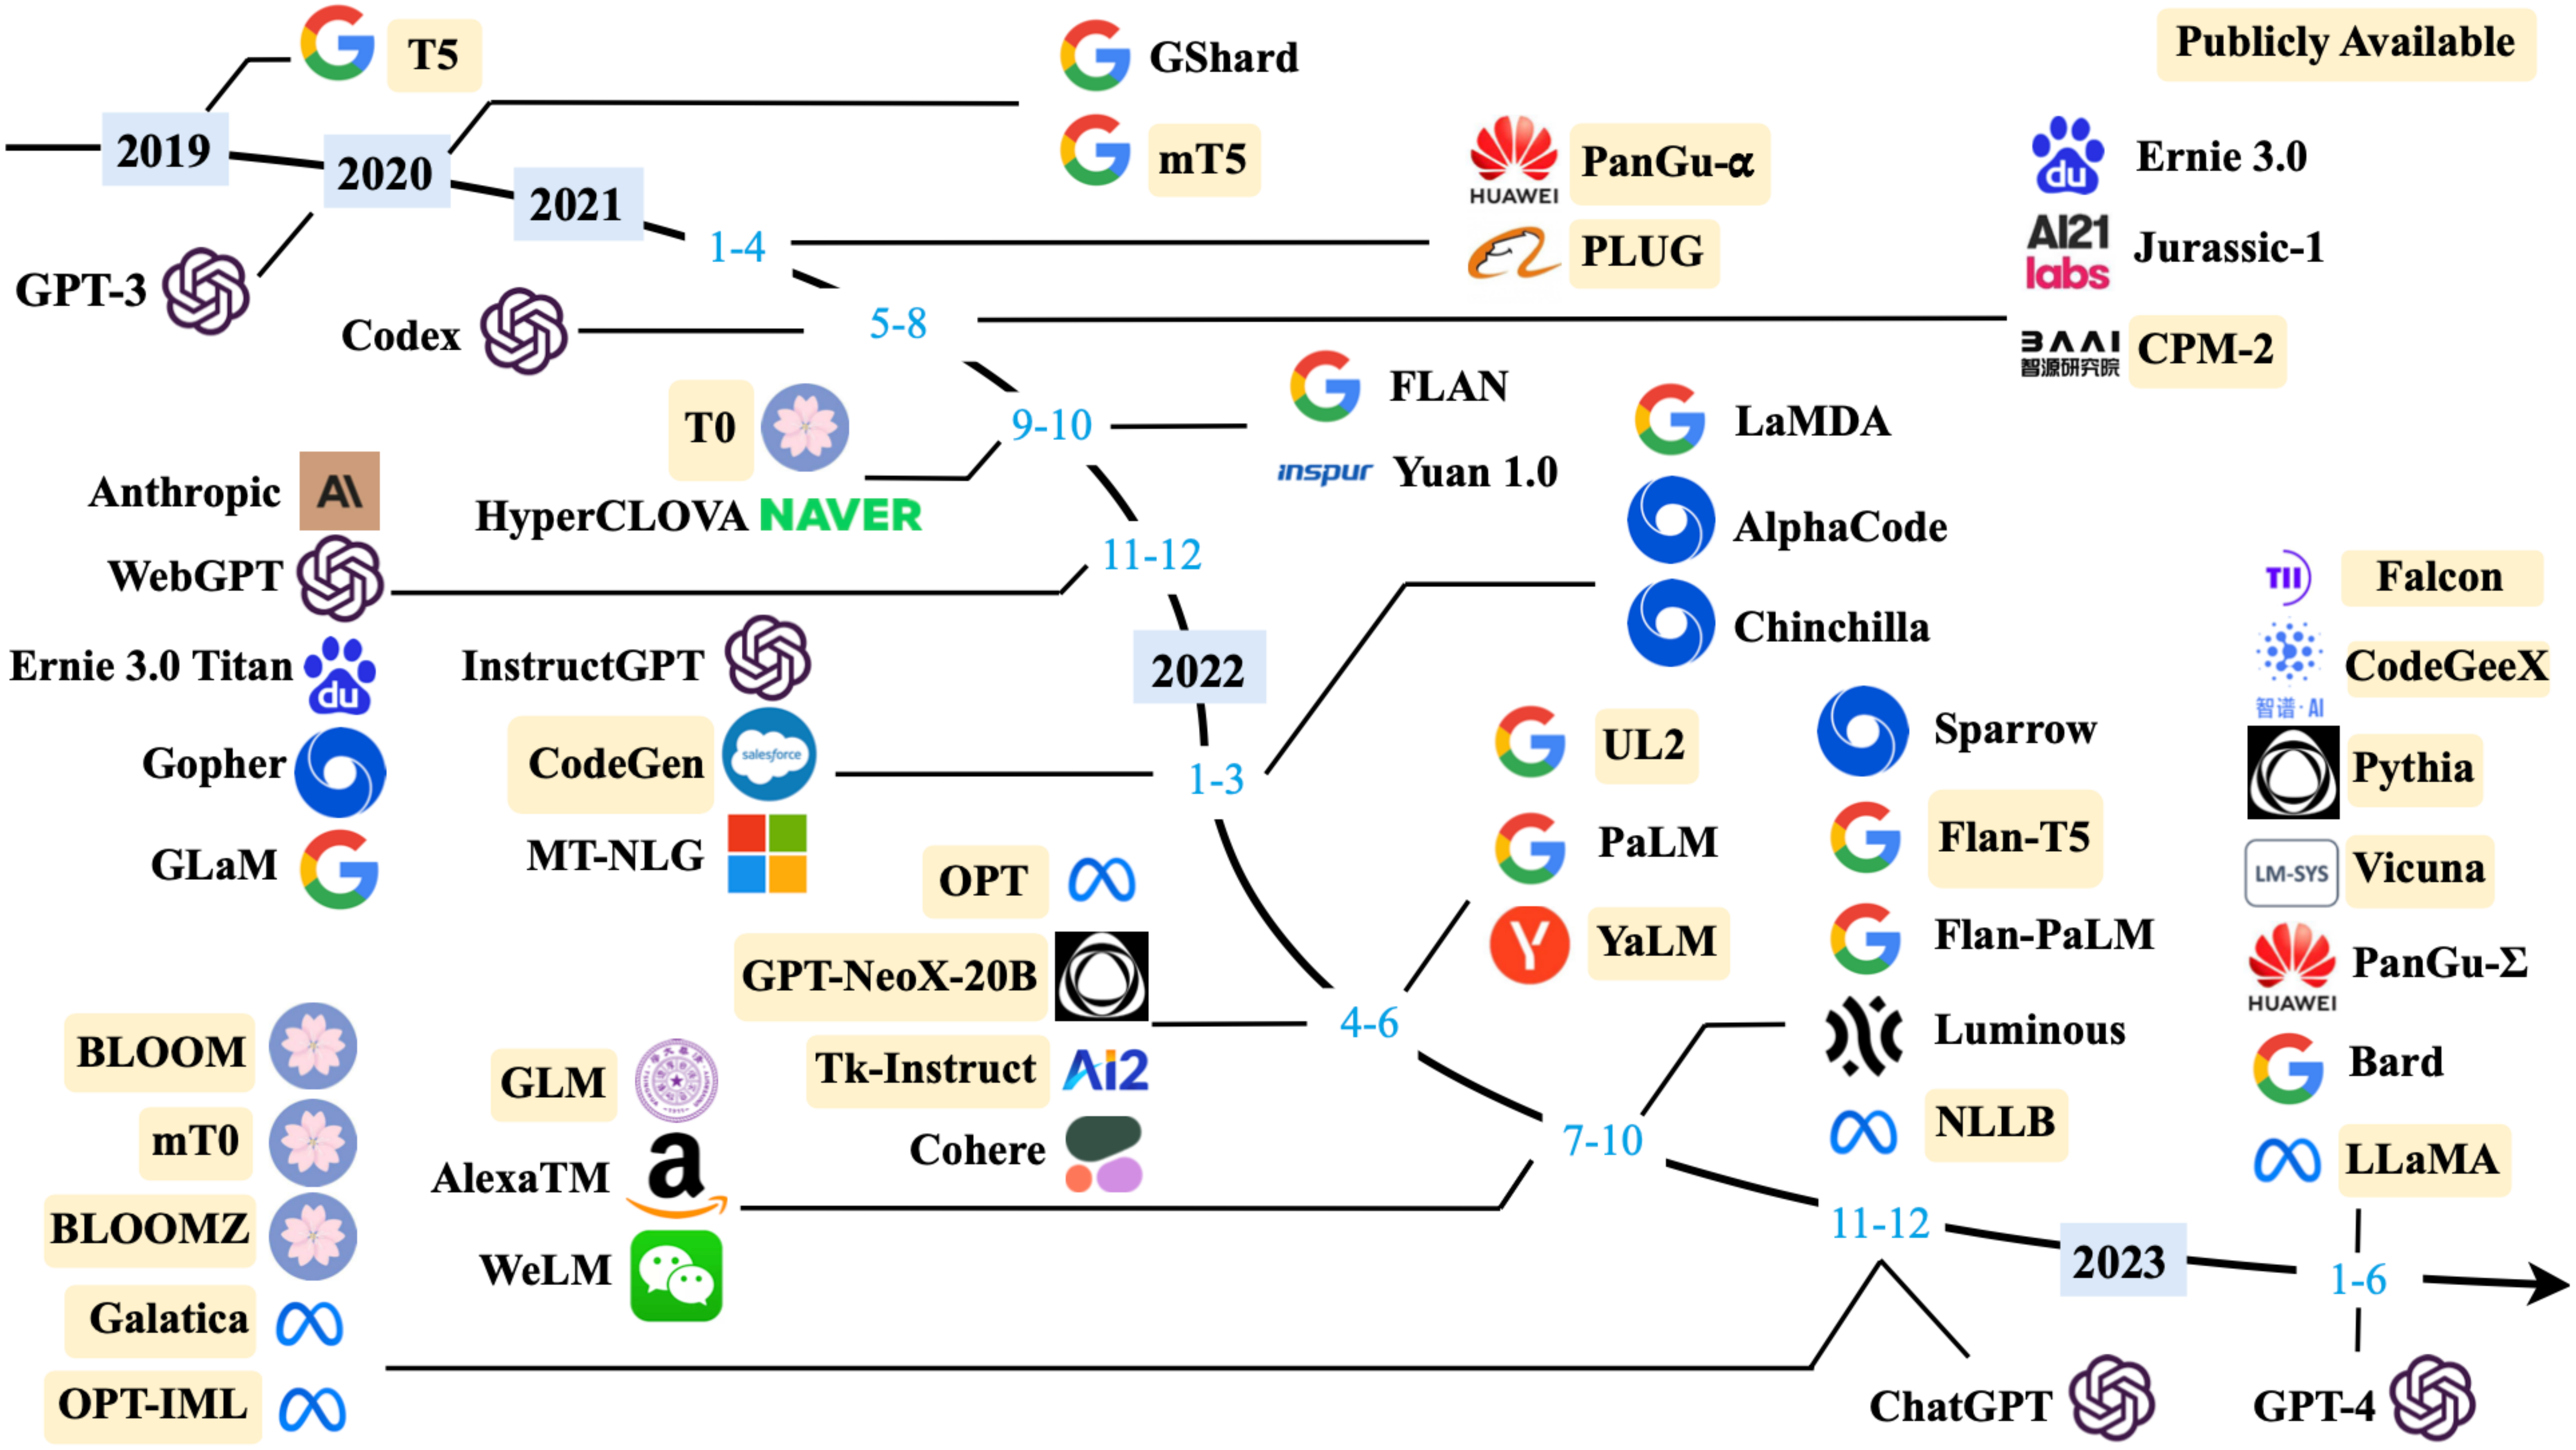

Publicly Available
2019
2020
2021
2022
2023
T5
GPT-3
GShard
mT5
1-4
PanGu-α
PLUG
Ernie 3.0
Jurassic-1
5-8
Codex
CPM-2
9-10
T0
HyperCLOVA
FLAN
Yuan 1.0
LaMDA
Anthropic
WebGPT
11-12
AlphaCode
Chinchilla
Ernie 3.0 Titan
InstructGPT
Gopher
CodeGen
1-3
GLaM
MT-NLG
UL2
PaLM
YaLM
Sparrow
Flan-T5
Flan-PaLM
OPT
GPT-NeoX-20B
4-6
BLOOM
GLM
Tk-Instruct
Luminous
mT0
AlexaTM
Cohere
7-10
NLLB
BLOOMZ
WeLM
11-12
Galatica
OPT-IML
ChatGPT
Falcon
CodeGeeX
Pythia
Vicuna
PanGu-Σ
Bard
LLaMA
1-6
GPT-4

大语言模型横向对比

	Model	Release Time	Size (B)	Base Model	Adaptation		Pre-train Data Scale	Latest Data Timestamp	Hardware (GPUs / TPUs)	Training Time	Evaluation	
					IT	RLHF					ICL	CoT
	T5 [73]	Oct-2019	11	-	-	-	1T tokens	Apr-2019	1024 TPU v3	-	✓	-
	mT5 [74]	Oct-2020	13	-	-	-	1T tokens	-	-	-	✓	-
	PanGu-α [75]	Apr-2021	13*	-	-	-	1.1TB	-	2048 Ascend 910	-	✓	-
	CPM-2 [76]	Jun-2021	198	-	-	-	2.6TB	-	-	-	-	-
	T0 [28]	Oct-2021	11	T5	✓	-	-	-	512 TPU v3	27 h	✓	-
	CodeGen [77]	Mar-2022	16	-	-	-	577B tokens	-	-	-	✓	-
	GPT-NeoX-20B [78]	Apr-2022	20	-	-	-	825GB	-	96 40G A100	-	✓	-
	Tk-Instruct [79]	Apr-2022	11	T5	✓	-	-	-	256 TPU v3	4 h	✓	-
	UL2 [80]	May-2022	20	-	-	-	1T tokens	Apr-2019	512 TPU v4	-	✓	✓
	OPT [81]	May-2022	175	-	-	-	180B tokens	-	992 80G A100	-	✓	-
	NLLB [82]	Jul-2022	54.5	-	-	-	-	-	-	-	✓	-
Publicly Available	GLM [83]	Oct-2022	130	-	-	-	400B tokens	-	768 40G A100	60 d	✓	-
	Flan-T5 [64]	Oct-2022	11	T5	✓	-	-	-	-	-	✓	✓
	BLOOM [69]	Nov-2022	176	-	-	-	366B tokens	-	384 80G A100	105 d	✓	-
	mT0 [84]	Nov-2022	13	mT5	✓	-	-	-	-	-	✓	-
	Galactica [35]	Nov-2022	120	-	-	-	106B tokens	-	-	-	✓	✓
	BLOOMZ [84]	Nov-2022	176	BLOOM	✓	-	-	-	-	-	✓	-
	OPT-IML [85]	Dec-2022	175	OPT	✓	-	-	-	128 40G A100	-	✓	✓
	LLaMA [57]	Feb-2023	65	-	-	-	1.4T tokens	-	2048 80G A100	21 d	✓	-
	CodeGeeX [86]	Sep-2022	13	-	-	-	850B tokens	-	1536 Ascend 910	60 d	✓	-
	Pythia [87]	Apr-2023	12	-	-	-	300B tokens	-	256 40G A100	-	✓	-
	GPT-3 [55]	May-2020	175	-	-	-	300B tokens	-	-	-	✓	-
	GShard [88]	Jun-2020	600	-	-	-	1T tokens	-	2048 TPU v3	4 d	-	-
	Codex [89]	Jul-2021	12	GPT-3	-	-	100B tokens	May-2020	-	-	✓	-
	ERNIE 3.0 [90]	Jul-2021	10	-	-	-	375B tokens	-	384 V100	-	✓	-
	Jurassic-1 [91]	Aug-2021	178	-	-	-	300B tokens	-	800 GPU	-	✓	-
	HyperCLOVA [92]	Sep-2021	82	-	-	-	300B tokens	-	1024 A100	13.4 d	✓	-
	FLAN [62]	Sep-2021	137	LaMDA-PT	✓	-	-	-	128 TPU v3	60 h	✓	-
	Yuan 1.0 [93]	Oct-2021	245	-	-	-	180B tokens	-	2128 GPU	-	✓	-
	Anthropic [94]	Dec-2021	52	-	-	-	400B tokens	-	-	-	✓	-
	WebGPT [72]	Dec-2021	175	GPT-3	-	✓	-	-	-	-	✓	-
	Gopher [59]	Dec-2021	280	-	-	-	300B tokens	-	4096 TPU v3	920 h	✓	-
	ERNIE 3.0 Titan [95]	Dec-2021	260	-	-	-	-	-	-	-	✓	-
	GLaM [96]	Dec-2021	1200	-	-	-	280B tokens	-	1024 TPU v4	574 h	✓	-
Closed Source	LaMDA [63]	Jan-2022	137	-	-	-	768B tokens	-	1024 TPU v3	57.7 d	-	-
	MT-NLG [97]	Jan-2022	530	-	-	-	270B tokens	-	4480 80G A100	-	✓	-
	AlphaCode [98]	Feb-2022	41	-	-	-	967B tokens	Jul-2021	-	-	-	-
	InstructGPT [61]	Mar-2022	175	GPT-3	✓	✓	-	-	-	-	✓	-
	Chinchilla [34]	Mar-2022	70	-	-	-	1.4T tokens	-	-	-	✓	-
	PaLM [56]	Apr-2022	540	-	-	-	780B tokens	-	6144 TPU v4	-	✓	✓
	AlexaTM [99]	Aug-2022	20	-	-	-	1.3T tokens	-	128 A100	120 d	✓	✓
	Sparrow [100]	Sep-2022	70	-	-	✓	-	-	64 TPU v3	-	✓	-
	WeLM [101]	Sep-2022	10	-	-	-	300B tokens	-	128 A100 40G	24 d	✓	-
	U-PaLM [102]	Oct-2022	540	PaLM	-	-	-	-	512 TPU v4	5 d	✓	✓
	Flan-PaLM [64]	Oct-2022	540	PaLM	✓	-	-	-	512 TPU v4	37 h	✓	✓
	Flan-U-PaLM [64]	Oct-2022	540	U-PaLM	✓	-	-	-	-	-	✓	✓
	GPT-4 [46]	Mar-2023	-	-	✓	✓	-	-	-	-	✓	✓
	PanGu-Σ [103]	Mar-2023	1085	PanGu-α	-	-	329B tokens	-	512 Ascend 910	100 d	✓	-

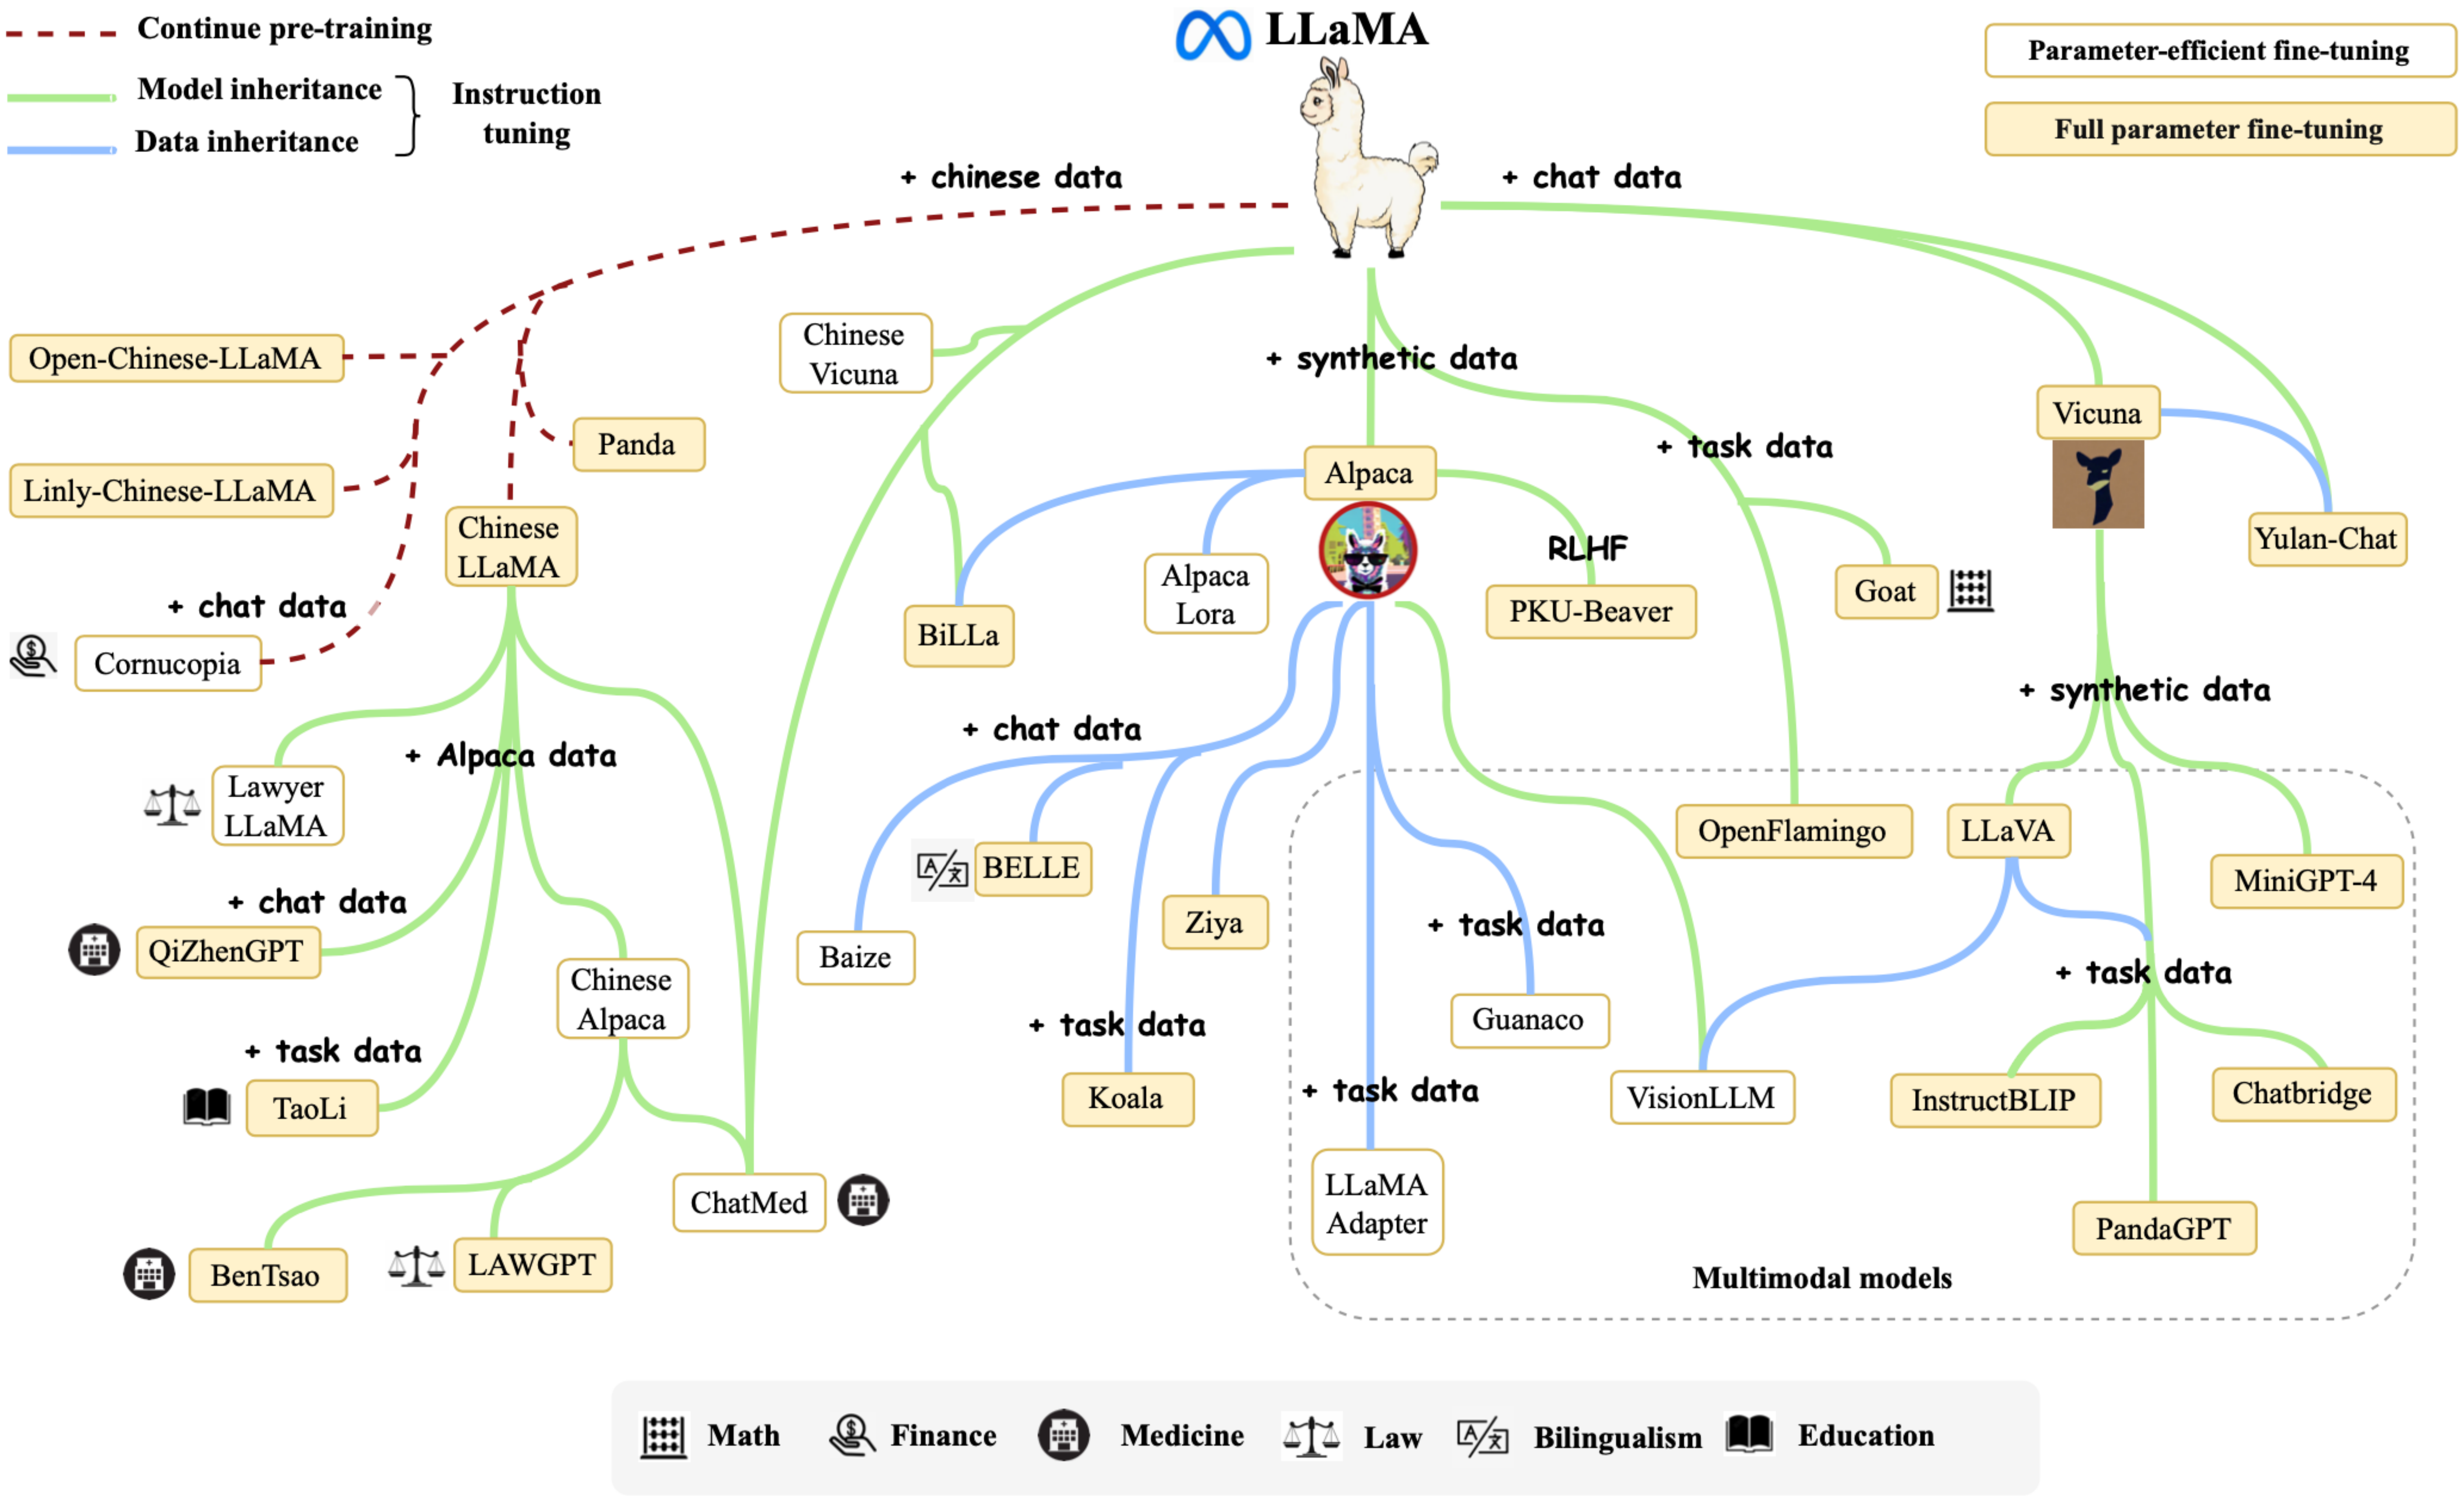

Continue pre-training
Model inheritance
Data inheritance
Instruction tuning
LLaMA
Parameter-efficient fine-tuning
Full parameter fine-tuning
+ chinese data
+ chat data
Open-Chinese-LLaMA
Linly-Chinese-LLaMA
Panda
Chinese LLaMA
Chinese Vicuna
+ synthetic data
Alpaca
+ task data
Vicuna
Yulan-Chat
+ chat data
Cornucopia
BiLLa
Alpaca Lora
RLHF
PKU-Beaver
Goat
+ synthetic data
+ Alpaca data
+ chat data
Lawyer LLaMA
+ chat data
QiZhenGPT
BELLE
Ziya
Baize
OpenFlamingo
LLaVA
MiniGPT-4
Chinese Alpaca
+ task data
TaoLi
+ task data
Guanaco
+ task data
Koala
+ task data
VisionLLM
InstructBLIP
Chatbridge
ChatMed
LLaMA Adapter
PandaGPT
BenTsao
LAWGPT
Multimodal models
Math
Finance
Medicine
Law
Bilingualism
Education

大模型跑分？

HF Open LLM Leaderboard

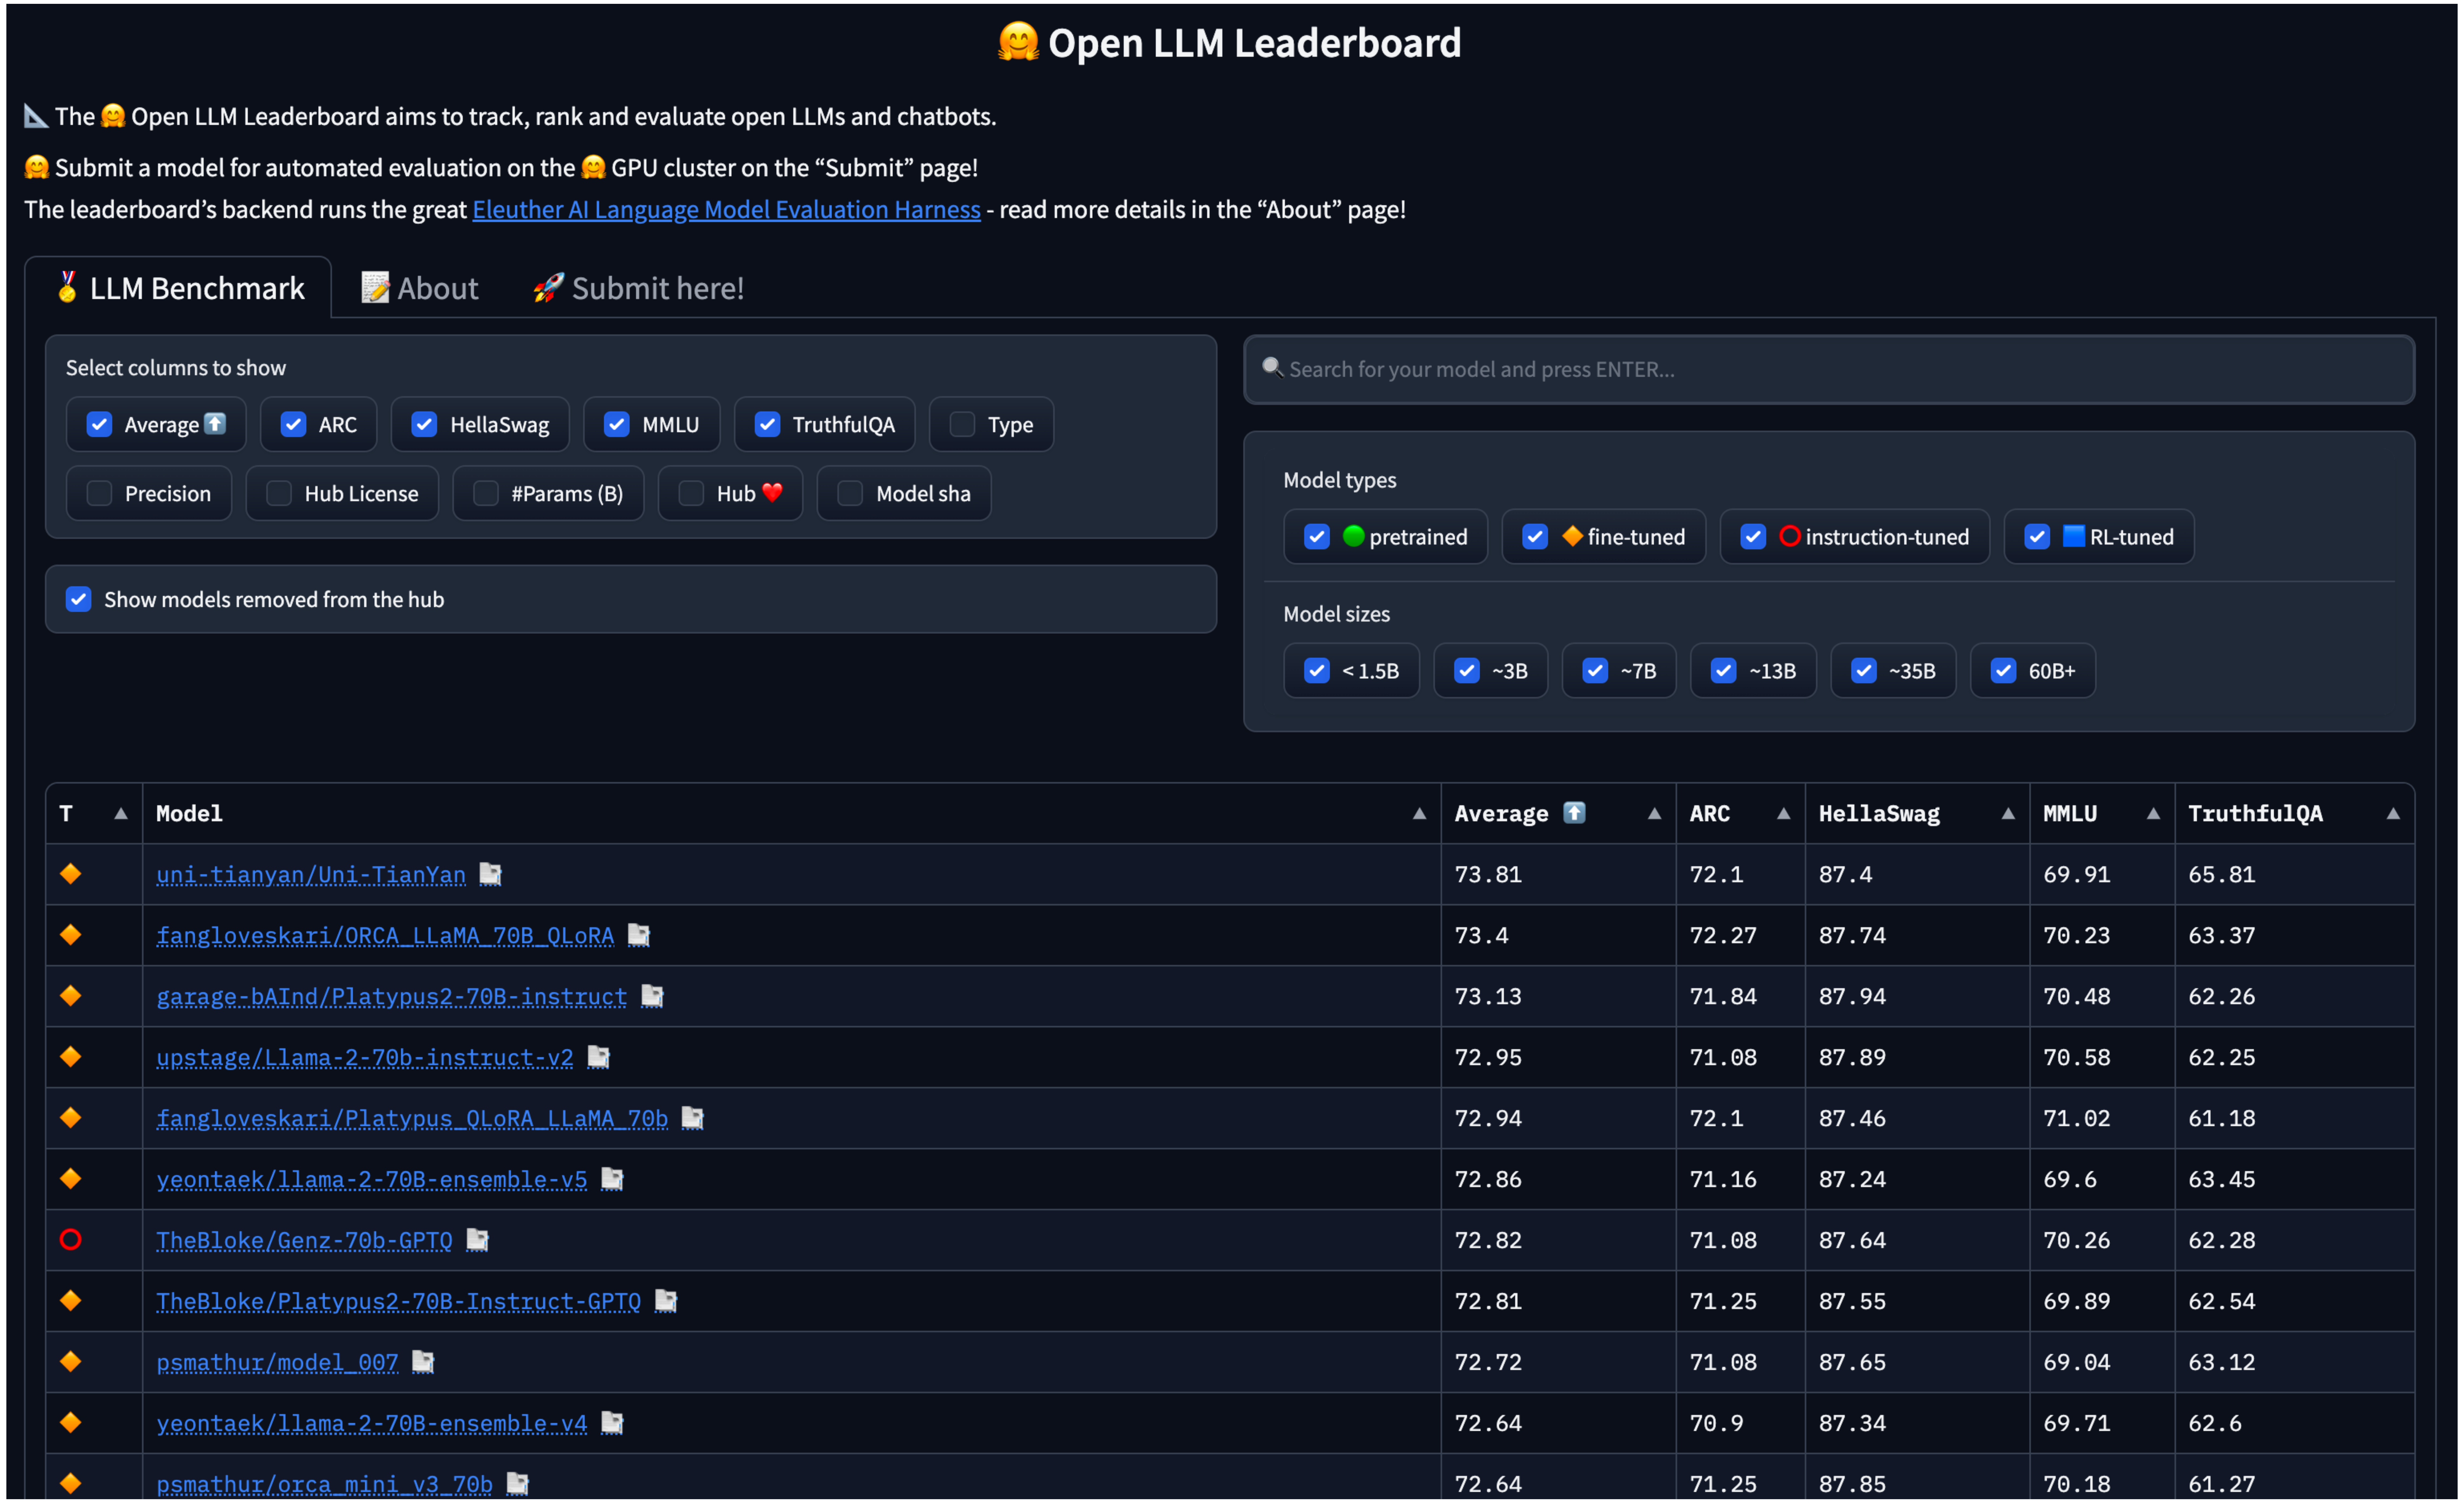

🤗 Open LLM Leaderboard

📐 The 🤗 Open LLM Leaderboard aims to track, rank and evaluate open LLMs and chatbots.

🤗 Submit a model for automated evaluation on the 🤗 GPU cluster on the "Submit" page!
The leaderboard's backend runs the great Eleuther AI Language Model Evaluation Harness - read more details in the "About" page!

🏅 LLM Benchmark | 📝 About | 🚀 Submit here!

Select columns to show

☑ Average ⬆️ ☑ ARC ☑ HellaSwag ☑ MMLU ☑ TruthfulQA ☐ Type
☐ Precision ☐ Hub License ☐ #Params (B) ☐ Hub ❤️ ☐ Model sha

☑ Show models removed from the hub

🔍 Search for your model and press ENTER...

Model types

☑ 🟢 pretrained ☑ 🔶 fine-tuned ☑ ⭕ instruction-tuned ☑ 🟦 RL-tuned

Model sizes

☑ < 1.5B ☑ ~3B ☑ ~7B ☑ ~13B ☑ ~35B ☑ 60B+

T	Model	Average ⬆️	ARC	HellaSwag	MMLU	TruthfulQA
🔶	uni-tianyan/Uni-TianYan 📑	73.81	72.1	87.4	69.91	65.81
🔶	fangloveskari/ORCA_LLaMA_70B_QLoRA 📑	73.4	72.27	87.74	70.23	63.37
🔶	garage-bAInd/Platypus2-70B-instruct 📑	73.13	71.84	87.94	70.48	62.26
🔶	upstage/Llama-2-70b-instruct-v2 📑	72.95	71.08	87.89	70.58	62.25
🔶	fangloveskari/Platypus_QLoRA_LLaMA_70b 📑	72.94	72.1	87.46	71.02	61.18
🔶	yeontaek/llama-2-70B-ensemble-v5 📑	72.86	71.16	87.24	69.6	63.45
⭕	TheBloke/Genz-70b-GPTQ 📑	72.82	71.08	87.64	70.26	62.28
🔶	TheBloke/Platypus2-70B-Instruct-GPTQ 📑	72.81	71.25	87.55	69.89	62.54
🔶	psmathur/model_007 📑	72.72	71.08	87.65	69.04	63.12
🔶	yeontaek/llama-2-70B-ensemble-v4 📑	72.64	70.9	87.34	69.71	62.6
🔶	psmathur/orca_mini_v3_70b 📑	72.64	71.25	87.85	70.18	61.27

https://huggingface.co/spaces/HuggingFaceH4/open_llm_leaderboard

HF Open LLM Leaderboard （大模型天梯榜）

Open LLM Leaderboard使用 Eleuther A I语言模型评估工具对模型进行了4个关键基准测试，这是一个统一的框架，用于在大量不同的评估任务上测试生成式语言模型。

- AI2推理挑战（25-shot）- 一组小学科学问题。
- HellaSwag（10-shot）- 这是一个常识推理测试，对人类来说很容易（约95%），但对SOTA模型来说具有挑战性。
- MMLU（5-shot）- 这是一个测量文本模型多任务准确性的测试。该测试涵盖57个任务，包括初等数学、美国历史、计算机科学、法律等等。
- TruthfulQA（0-shot）- 这是一个衡量模型倾向于复制在线常见谬误的测试。（注意：Harness中的TruthfulQA实际上是一个6-shots任务，在启动时即使将few-shot示例数量设置为0，也会自动添加6个示例。）

对于所有这些评估，得分越高越好。 Open LLM Leaderboard 选择了这些基准作为它们在0-shot和few-shot环境下涵盖了各种推理和广泛知识领域。

HF Open LLM Leaderboard

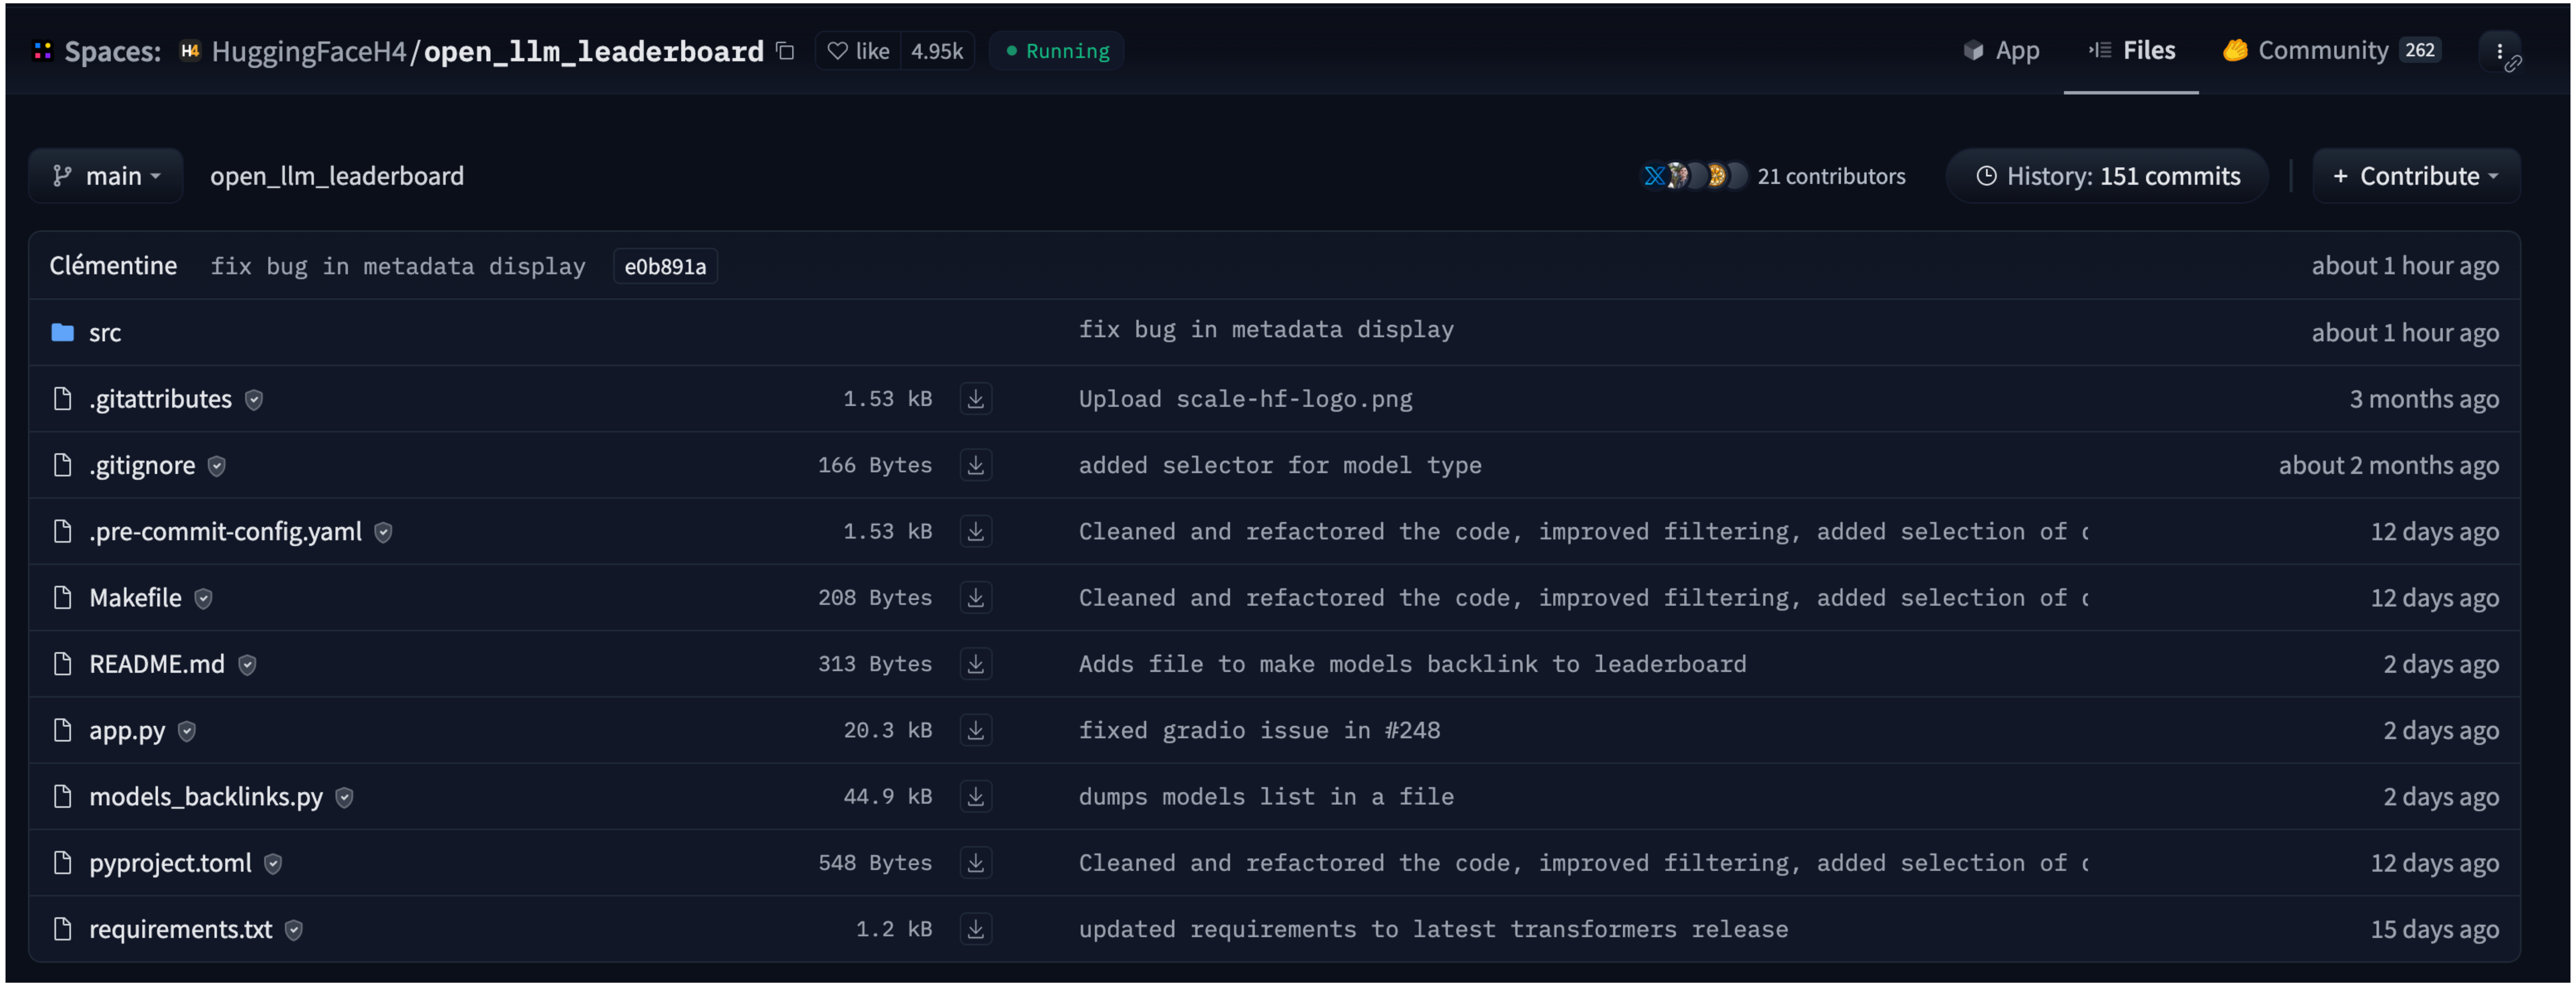

https://huggingface.co/spaces/HuggingFaceH4/open_llm_leaderboard/tree/main

目录

UPGRADE

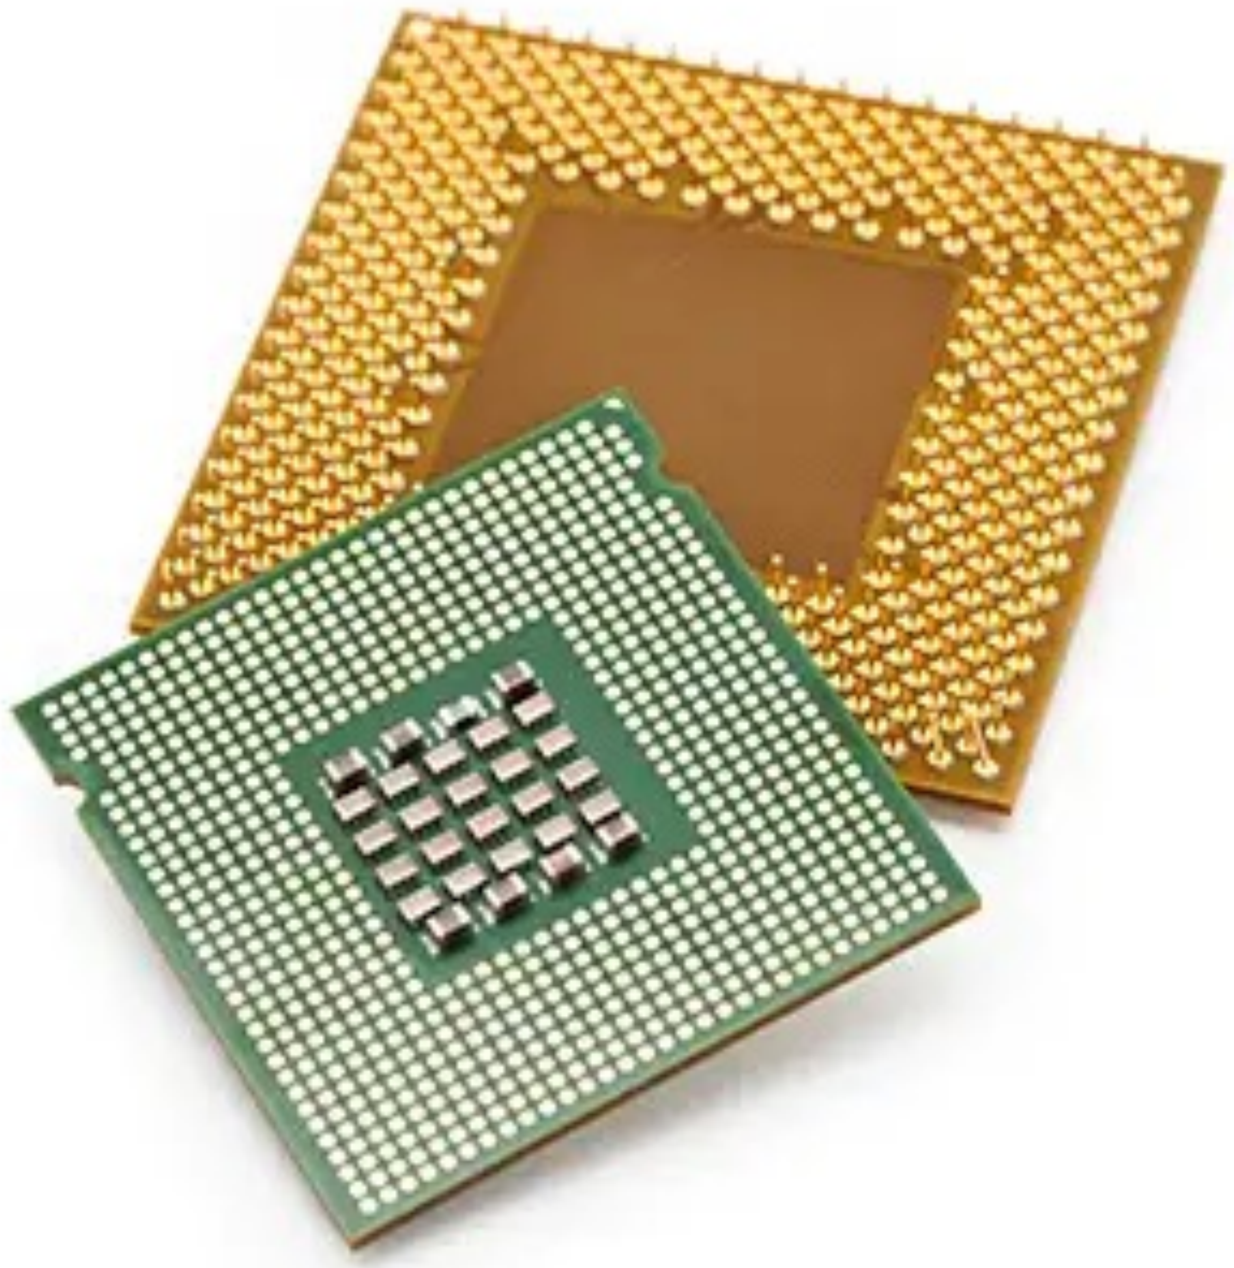

CPU

OR

GPU

GPU vs 显卡

GPU（图形处理单元）：计算机内部的硬件组件，用于处理图形和图像相关的任务。**主要功能：**

- 处理图形渲染，包括游戏、视频和动画。
- 加速通用计算，如深度学习、科学模拟等。
- 高度并行处理，适用于大规模数据处理和处理密集型任务。

显卡：包含一个或多个GPU芯片的硬件设备，通常用于图形渲染和计算任务。 主流显卡的显示芯片主要由NVIDIA（英伟达）和AMD（超威半导体 ）两大厂商制造，通常将采用NVIDIA显示芯片的显卡称为N卡，而将采用AMD显示芯片的显卡称为A卡。主要作用：

- 将GPU集成到计算机中，通过接口（如PCIe）连接到主板。
- 提供图形输出接口，如HDMI、DisplayPort，使显示器能够显示图像。
- 可以有不同的物理尺寸和散热解决方案，适应各种计算机类型和用途。

GPU与显卡关系：

- GPU是显卡的核心组件，决定了计算性能。
- 显卡则是将GPU与必要的接口、散热、电源管理等元件集成在一起的硬件设备。

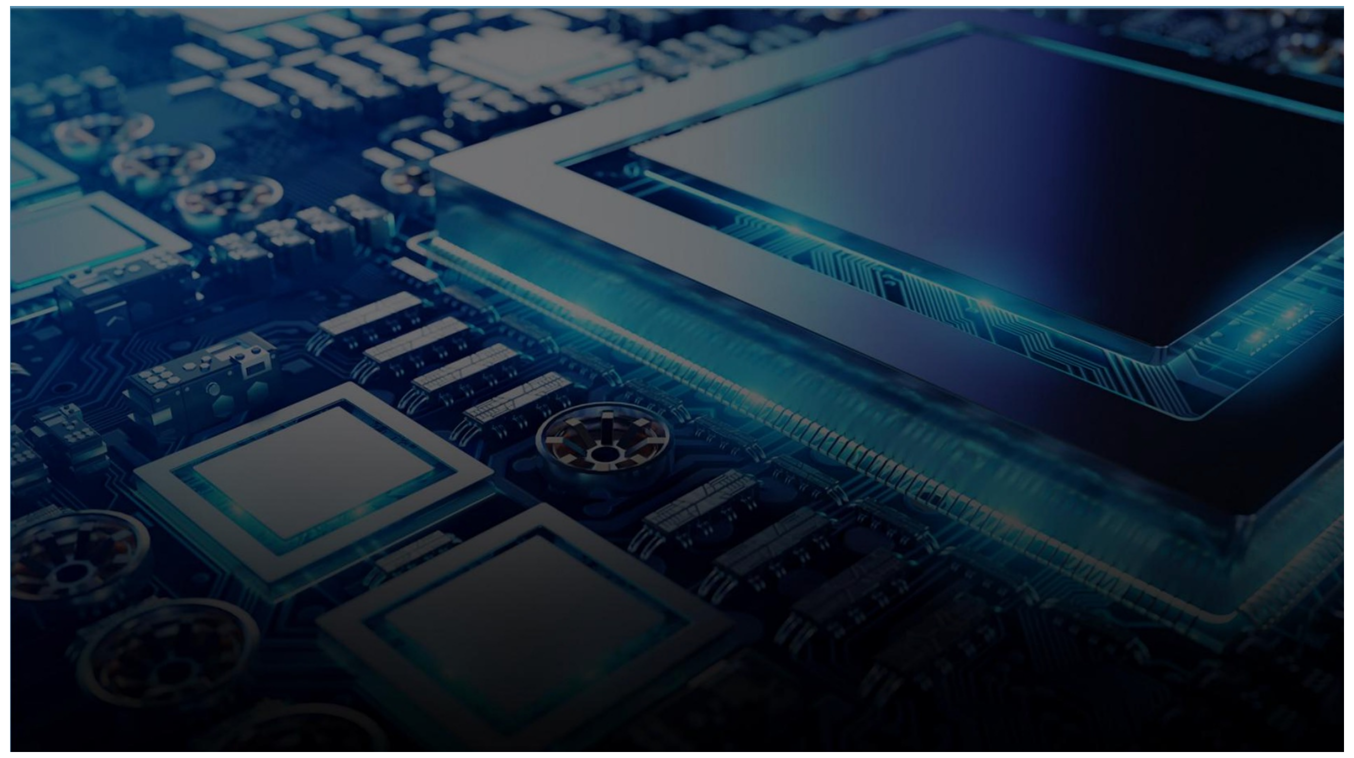

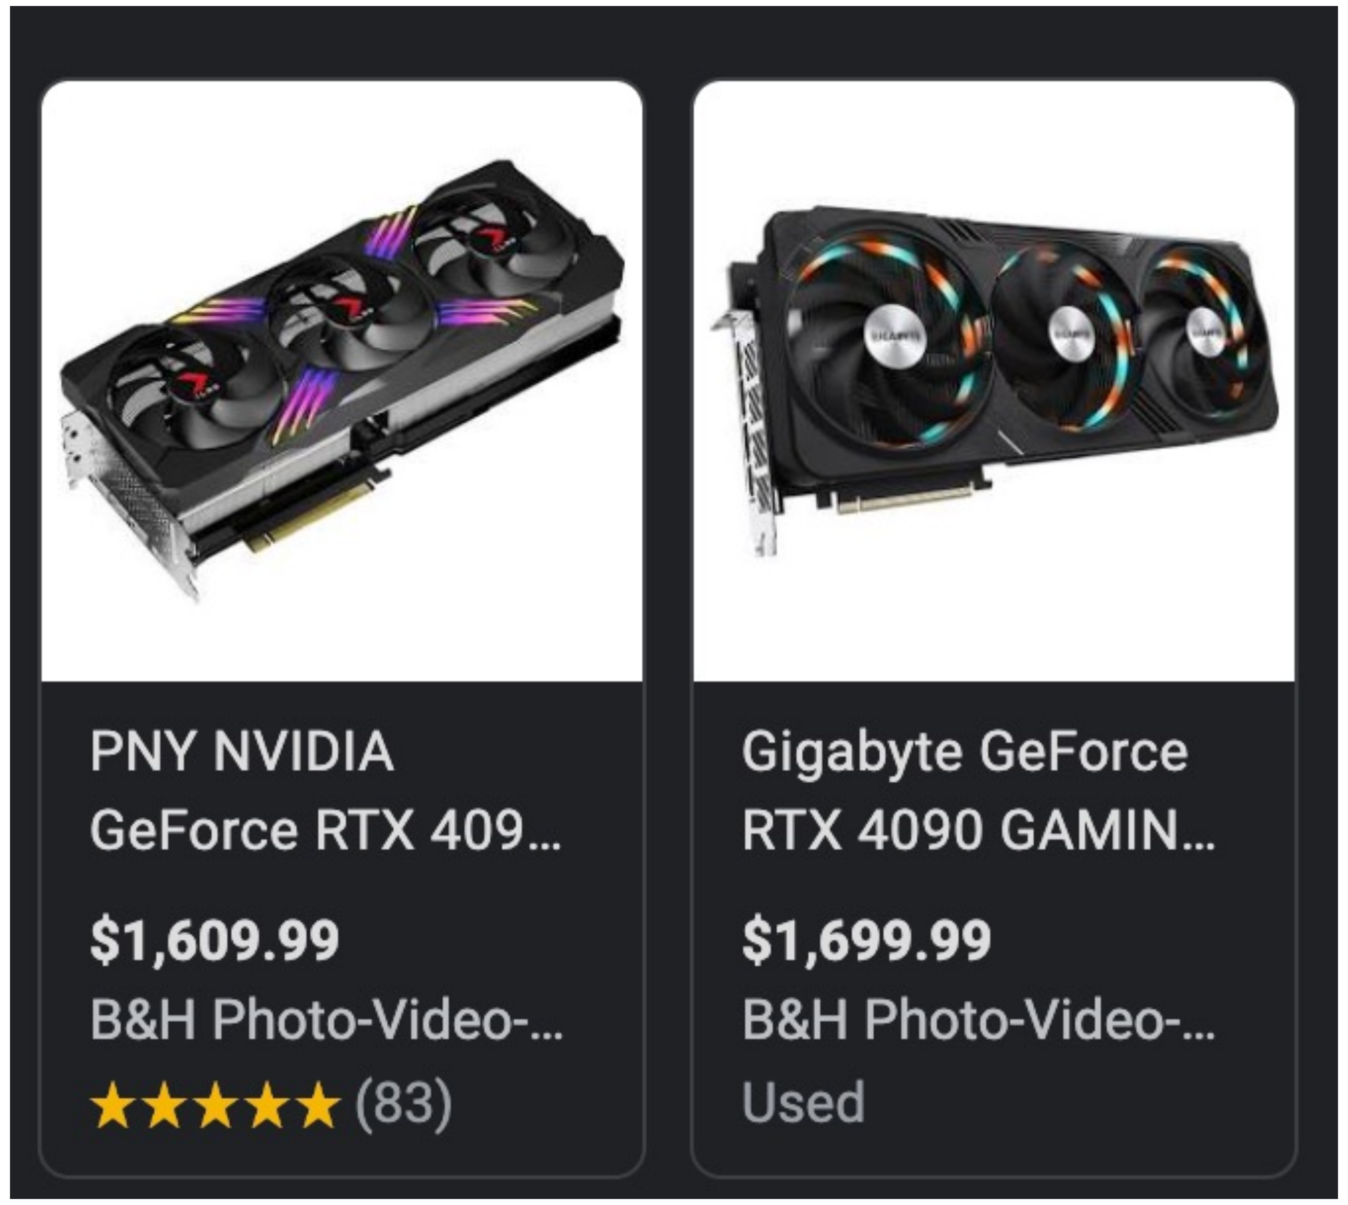

GPU Core vs AMD CU

显卡虽然是一大块卡，但它真正执行运算的部分只是一枚和 CPU 一样大小的芯片——**显卡核心**；显卡 PCB 上其他组件，都是为它提供电源、通信、存储功能的。

这个小芯片承担着与 CPU 不同的定位和功能，芯片设计思路也完全不同。这就导致，我们谈论 GPU 时，所说的 Core，完全不是 CPU 上那个意思。

作为辅助 CPU 执行计算的周边器件，它不需要承担那些系统管理、调度的功能，完全专注于使用（大量的）小核心并行化地执行基础运算（通常都有数千个核心同时执行）。—— GPU Core 小而且多，这是我们的初步印象。

AMD 倾向于简化整个模型，用 CU 来讨论他们的显卡核心数量。Compute Unit 指的是一组执行运算的元件的集群（cluster），它里面有大量更小的计算单元。

由于技术路线和优势不同，AMD 更在乎自己的总线技术（例如 Infinity Cache）和集群结构，自然也倾向于以 CU 数量来讨论显卡性能。CU 不会具体对应到计算单元的数量，而只是跟缓存、总线结构有关。

CU 在概念上更接近 Nvidia 的 SM。所以千万不要拿 A 卡的 CU 与 N 卡的 CUDA Core 相比，是两个完全错位的概念。

CUDA Core

N 卡上，经常提到的概念是 CUDA Core。英伟达倾向于用**最小的运算单元**表示自己的运算能力，**CUDA Core** 指的是一个执行基础运算的处理元件。最早的时候，这个「基础组件」类似于 CPU 中负责各种数值计算的那个 core，能做很多通用运算。

但后来就不一样了，例如整型计算和浮点型计算单元的数量不一样了。CUDA Core 不再能 1:1 地对应上这些小运算单元。它的定义就开始变化：有时2个 CUDA Core 才能凑出1个整型运算单元。

所以 CUDA Core 的定义其实是复杂而且变化的。你不能单纯用 CUDA Core 的数量来跨代际比较显卡性能（因为它在两代显卡中的定义都不同）。

由于 CUDA Core 根本就是为了方便商业营销而创造的概念，英伟达喜欢将其称为「用于营销目的」的核心。
随着架构的更替，经过一代又一代的演变。

现在 Ampere 架构上所说的 CUDA Core（的数量），对应的其实是 FP32 计算单元（的数量）

Nvidia A100

Ampere 架构最强显卡 A100 的内部架构：
128 个 **SM**（Streaming Multiprocessor，流式多处理器），密密麻麻地排布在中间蓝色的 L2 Cache 两侧。

关注 **SM** 这个概念，它在 N 卡架构中非常重要，N 卡的多核并行化就是靠平行布置大量的 SM 来实现的。

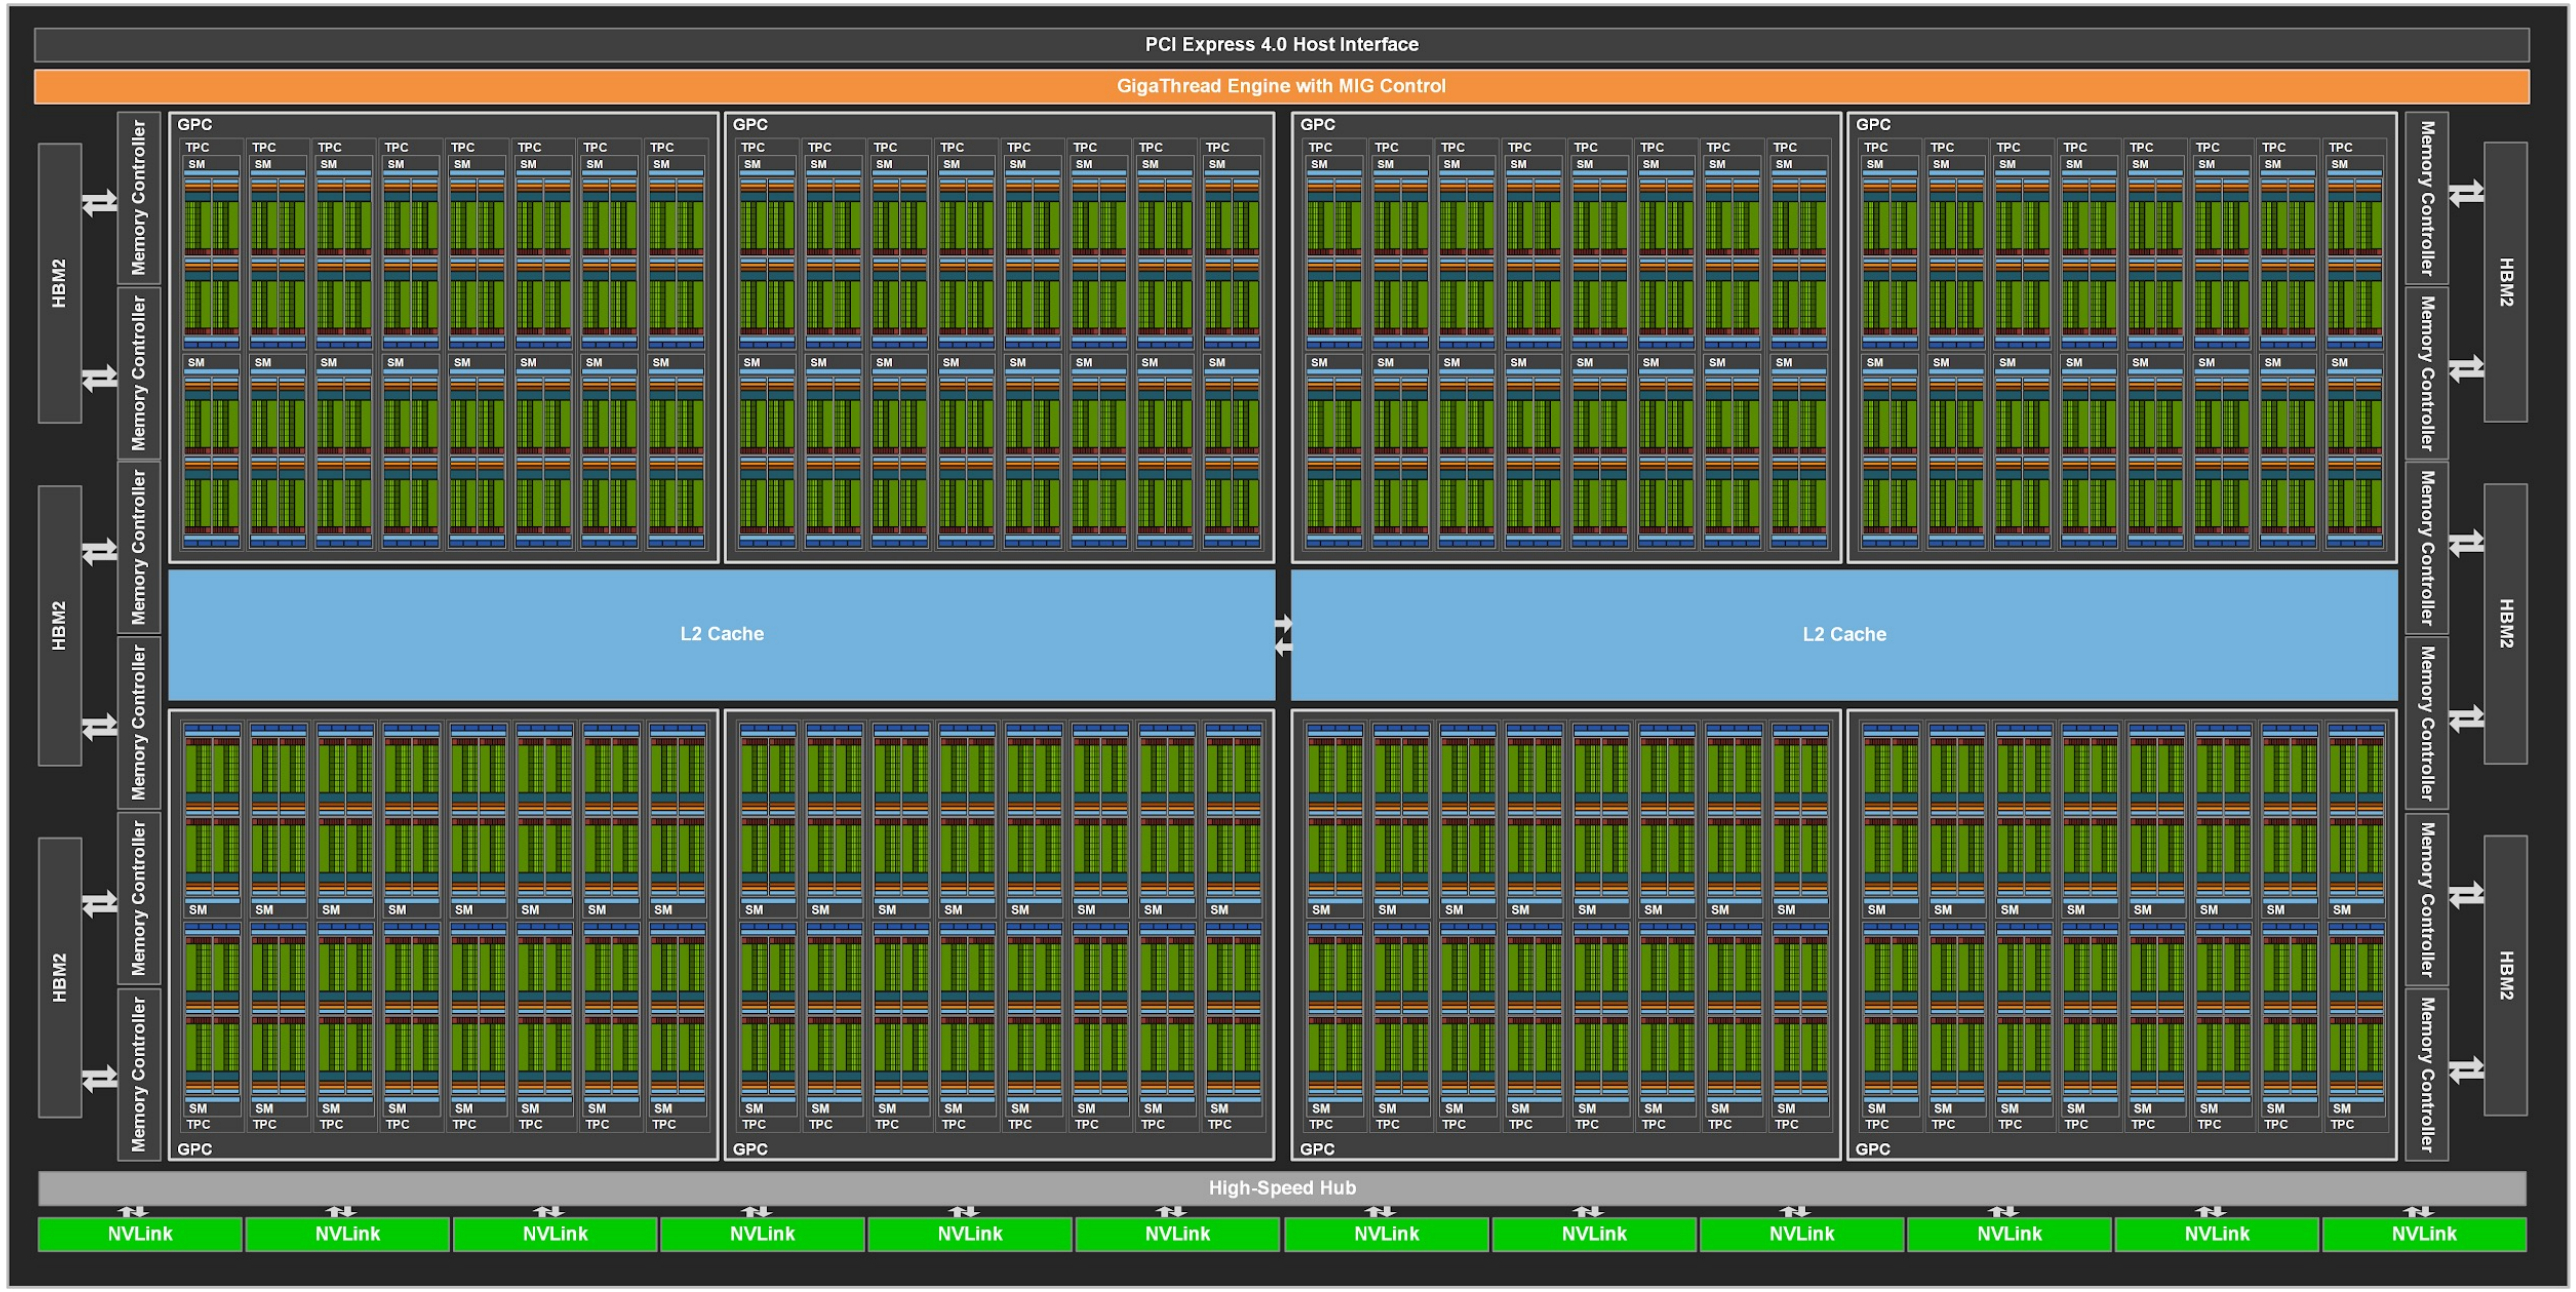

流式多处理器

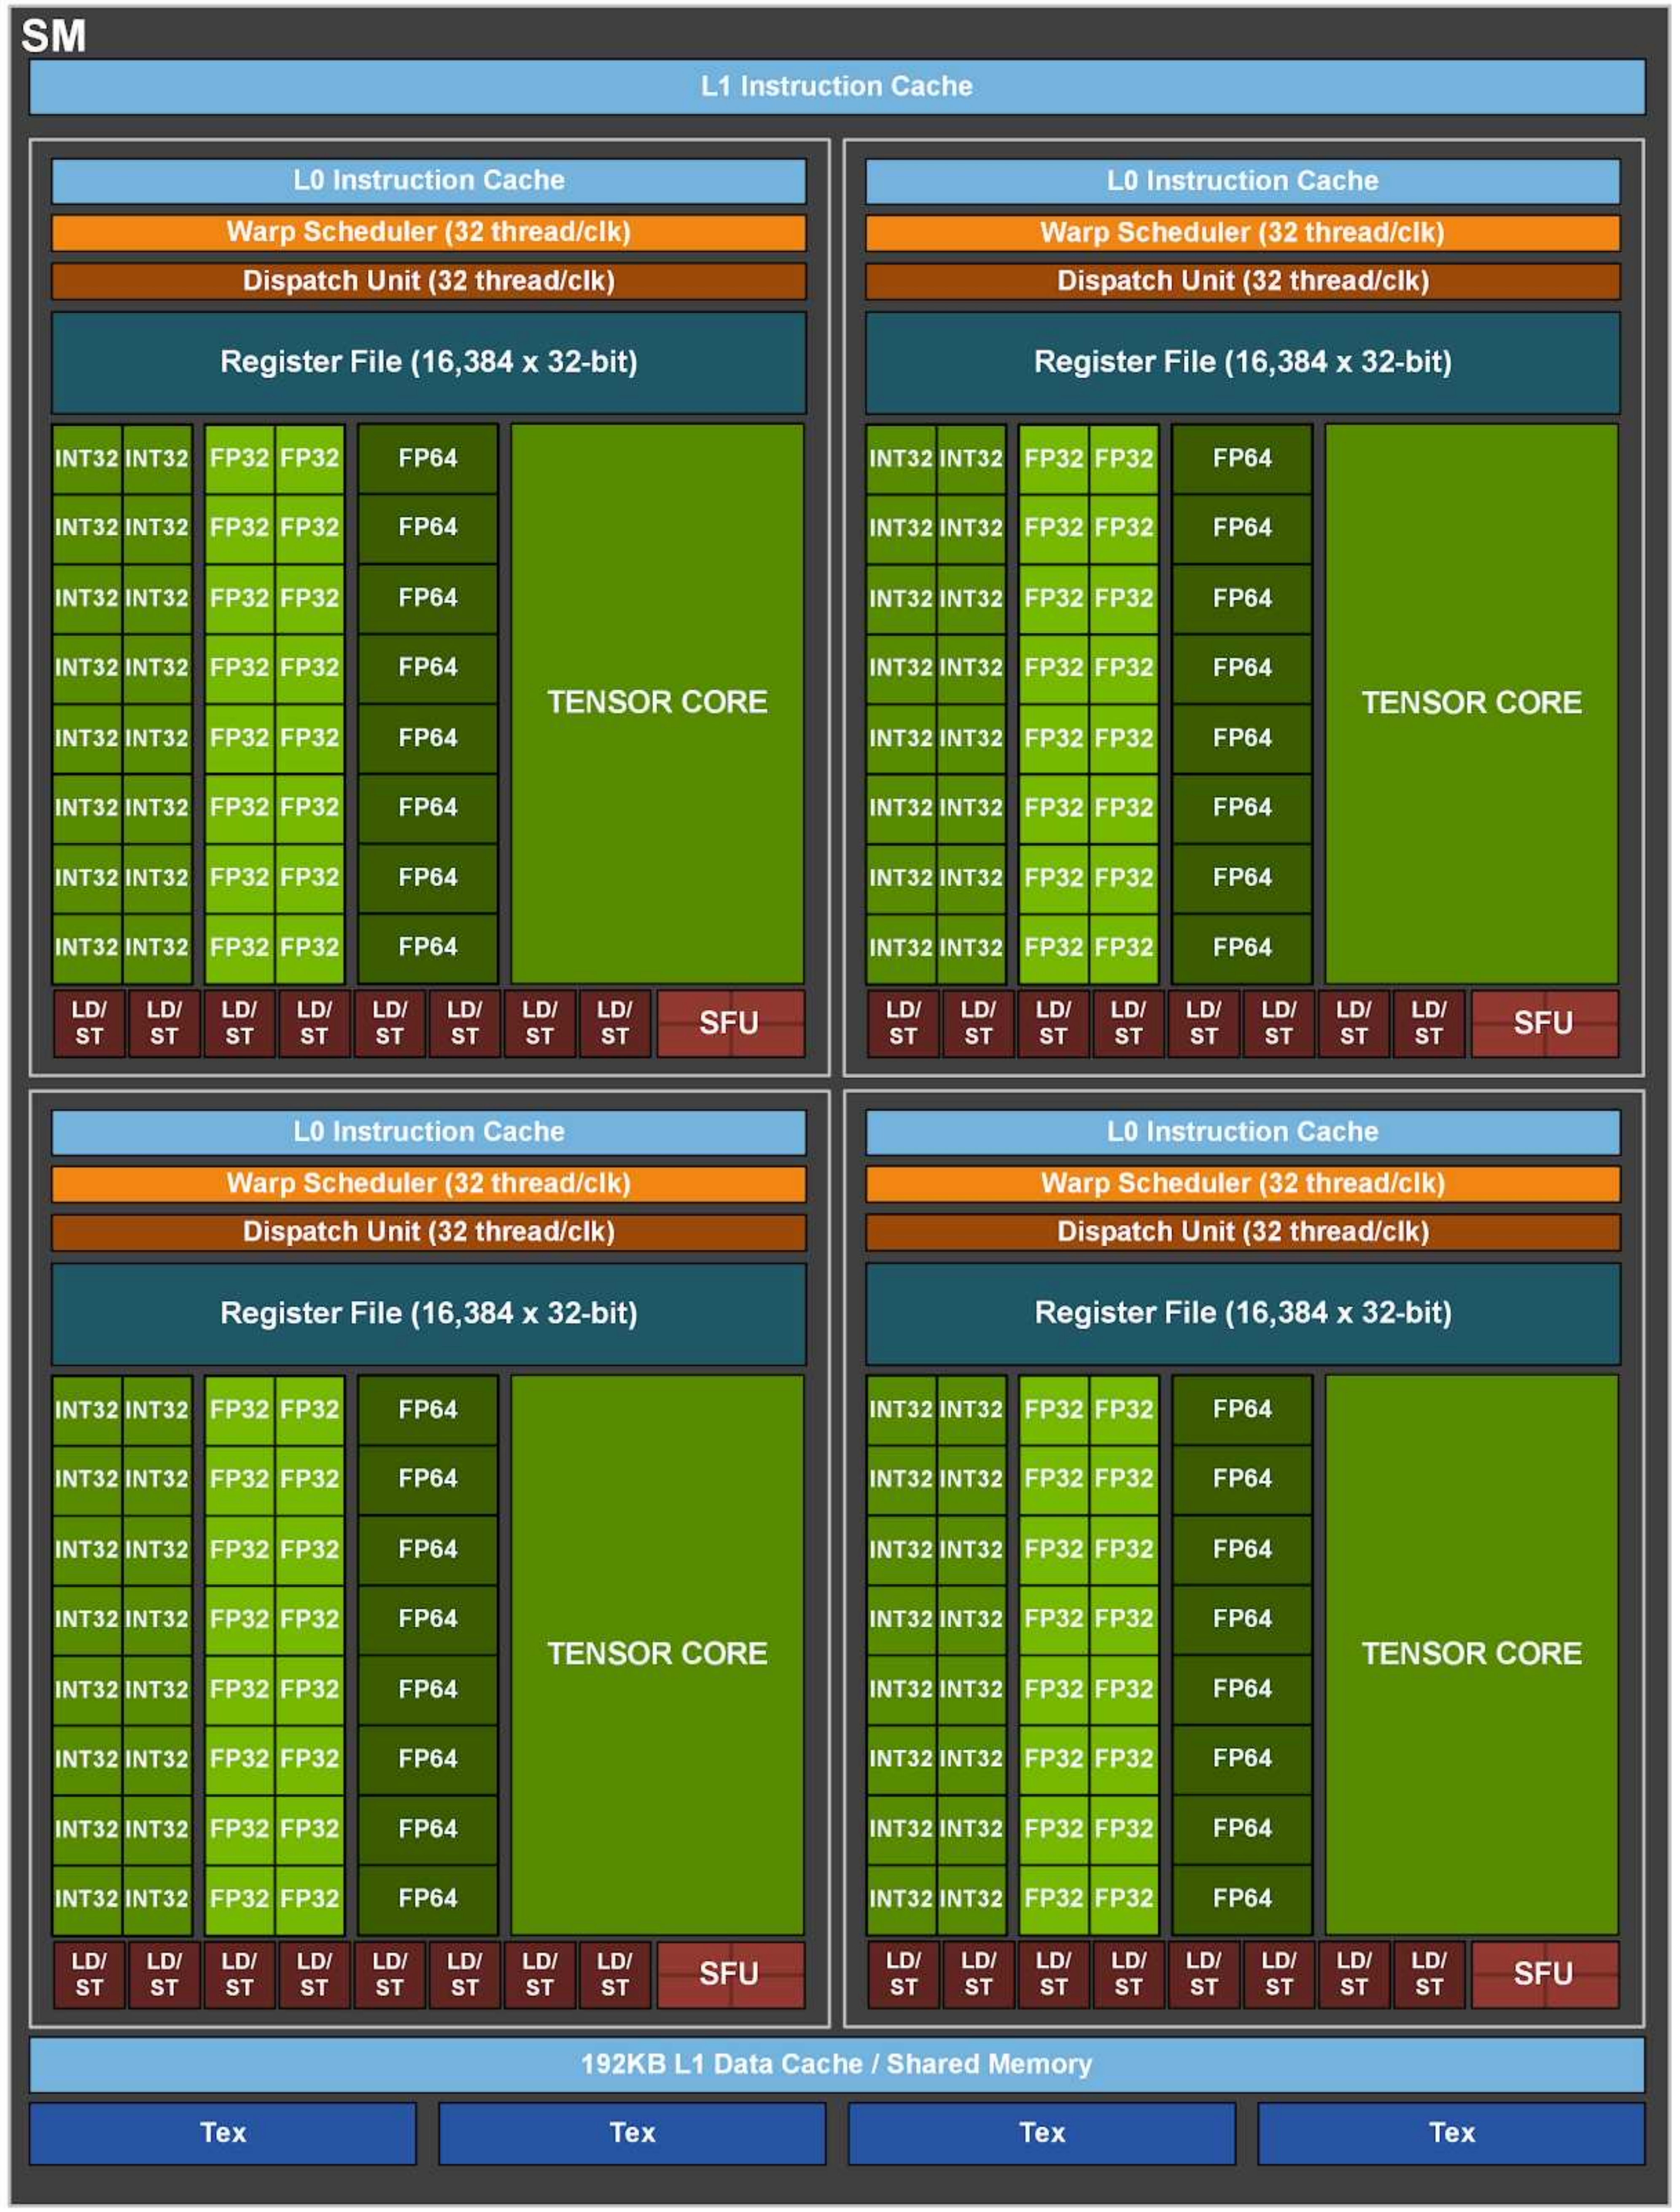
SM
L1 Instruction Cache
L0 Instruction Cache
Warp Scheduler (32 thread/clk)
Dispatch Unit (32 thread/clk)
Register File (16,384 x 32-bit)
INT32 INT32
FP32 FP32
FP64
TENSOR CORE
LD/ ST
SFU
L0 Instruction Cache
Warp Scheduler (32 thread/clk)
Dispatch Unit (32 thread/clk)
Register File (16,384 x 32-bit)
INT32 INT32
FP32 FP32
FP64
TENSOR CORE
LD/ ST
SFU
L0 Instruction Cache
Warp Scheduler (32 thread/clk)
Dispatch Unit (32 thread/clk)
Register File (16,384 x 32-bit)
INT32 INT32
FP32 FP32
FP64
TENSOR CORE
LD/ ST
SFU
L0 Instruction Cache
Warp Scheduler (32 thread/clk)
Dispatch Unit (32 thread/clk)
Register File (16,384 x 32-bit)
INT32 INT32
FP32 FP32
FP64
TENSOR CORE
LD/ ST
SFU
192KB L1 Data Cache / Shared Memory
Tex
Tex
Tex
Tex

Tensor Core

机器学习、神经网络的时代到来了。在这种应用场景下，矩阵运算的计算量非常大......那就干脆......再来个 **Tensor Core**，专门算矩阵

Tensor Core 有着专门设计的硬件结构，可以把整个矩阵都载入寄存器中批量运算，有十几倍的效率提升。这简直是机器学习神器——自 Volta 架构发布以来，奠定了 N 卡在机器学习领域的江湖地位。

Volta 以来的每一代架构，除了制程上的进步，Nvidia 也不遗余力地更新着他们的 Tensor Core：

N 卡架构变迁

计算能力	架构	发布年代	Cores/SM	总 SM 数	CUDA Cores	L1 Cache (KB)	L2 Cache (KB)
1.0	Tesla						
2.0	Fermi	2009	32	16 SM	512	48	768
3.0	Kepler	2012	192	15 SMX	2880	48	1536
4.0	–						
5.0	Maxwell	2014	128	24 SMM	3072	96	2048
6.0	Pascal	2016	64	60 SM	3840	64	4096
7.0	Volta	2018	64 8 个 Tensor Core	80 SM	5120	与共享内存共用 128（最多 96）	6144
7.5	Turing	2018	64 8 个 Tensor Core	72 SM	4608	与共享内存共用 128（最多 96）	6144
8.0	Ampere	2020	64 4 个 Tensor Core	108 SM	6912	与共享内存共用 192（最多 164）	40960
9.0	Hopper	2022	128 4 个 Tensor Core	144 SM	18432	与共享内存共用 256	61440

显卡性能天梯榜

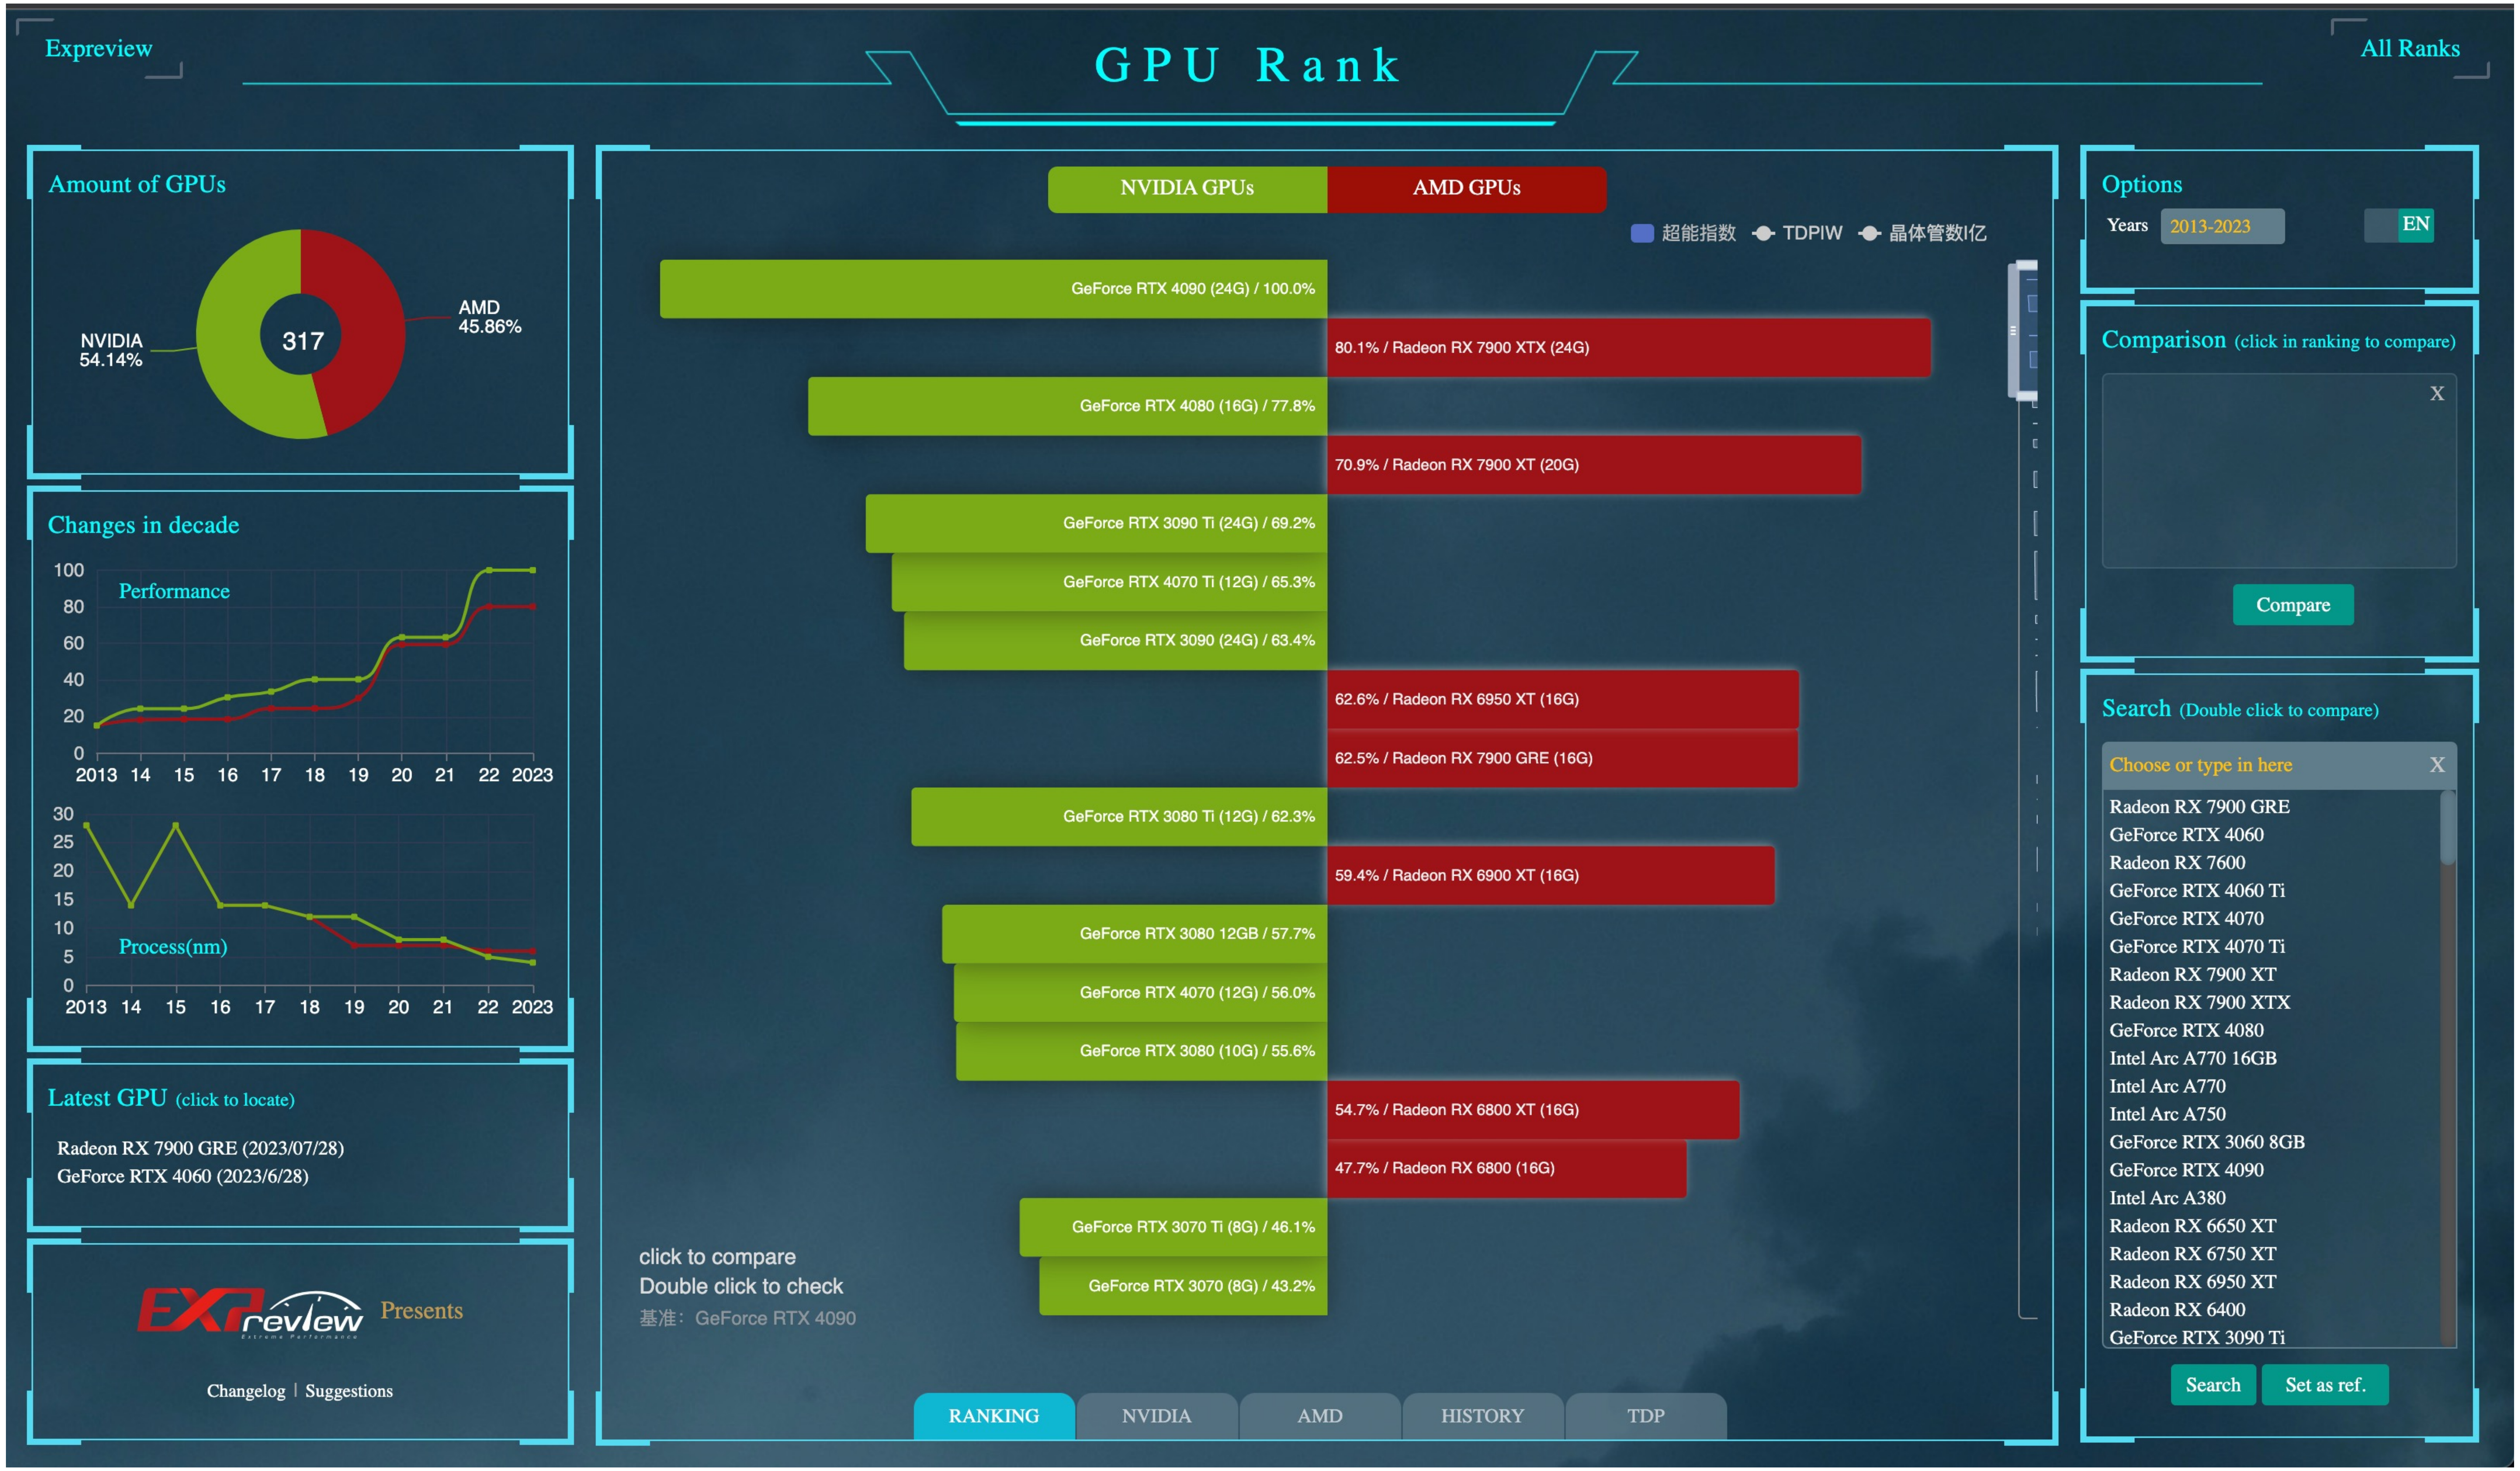

https://topic.expreview.com/GPU/

课程项目：GitHub openai-quickstart

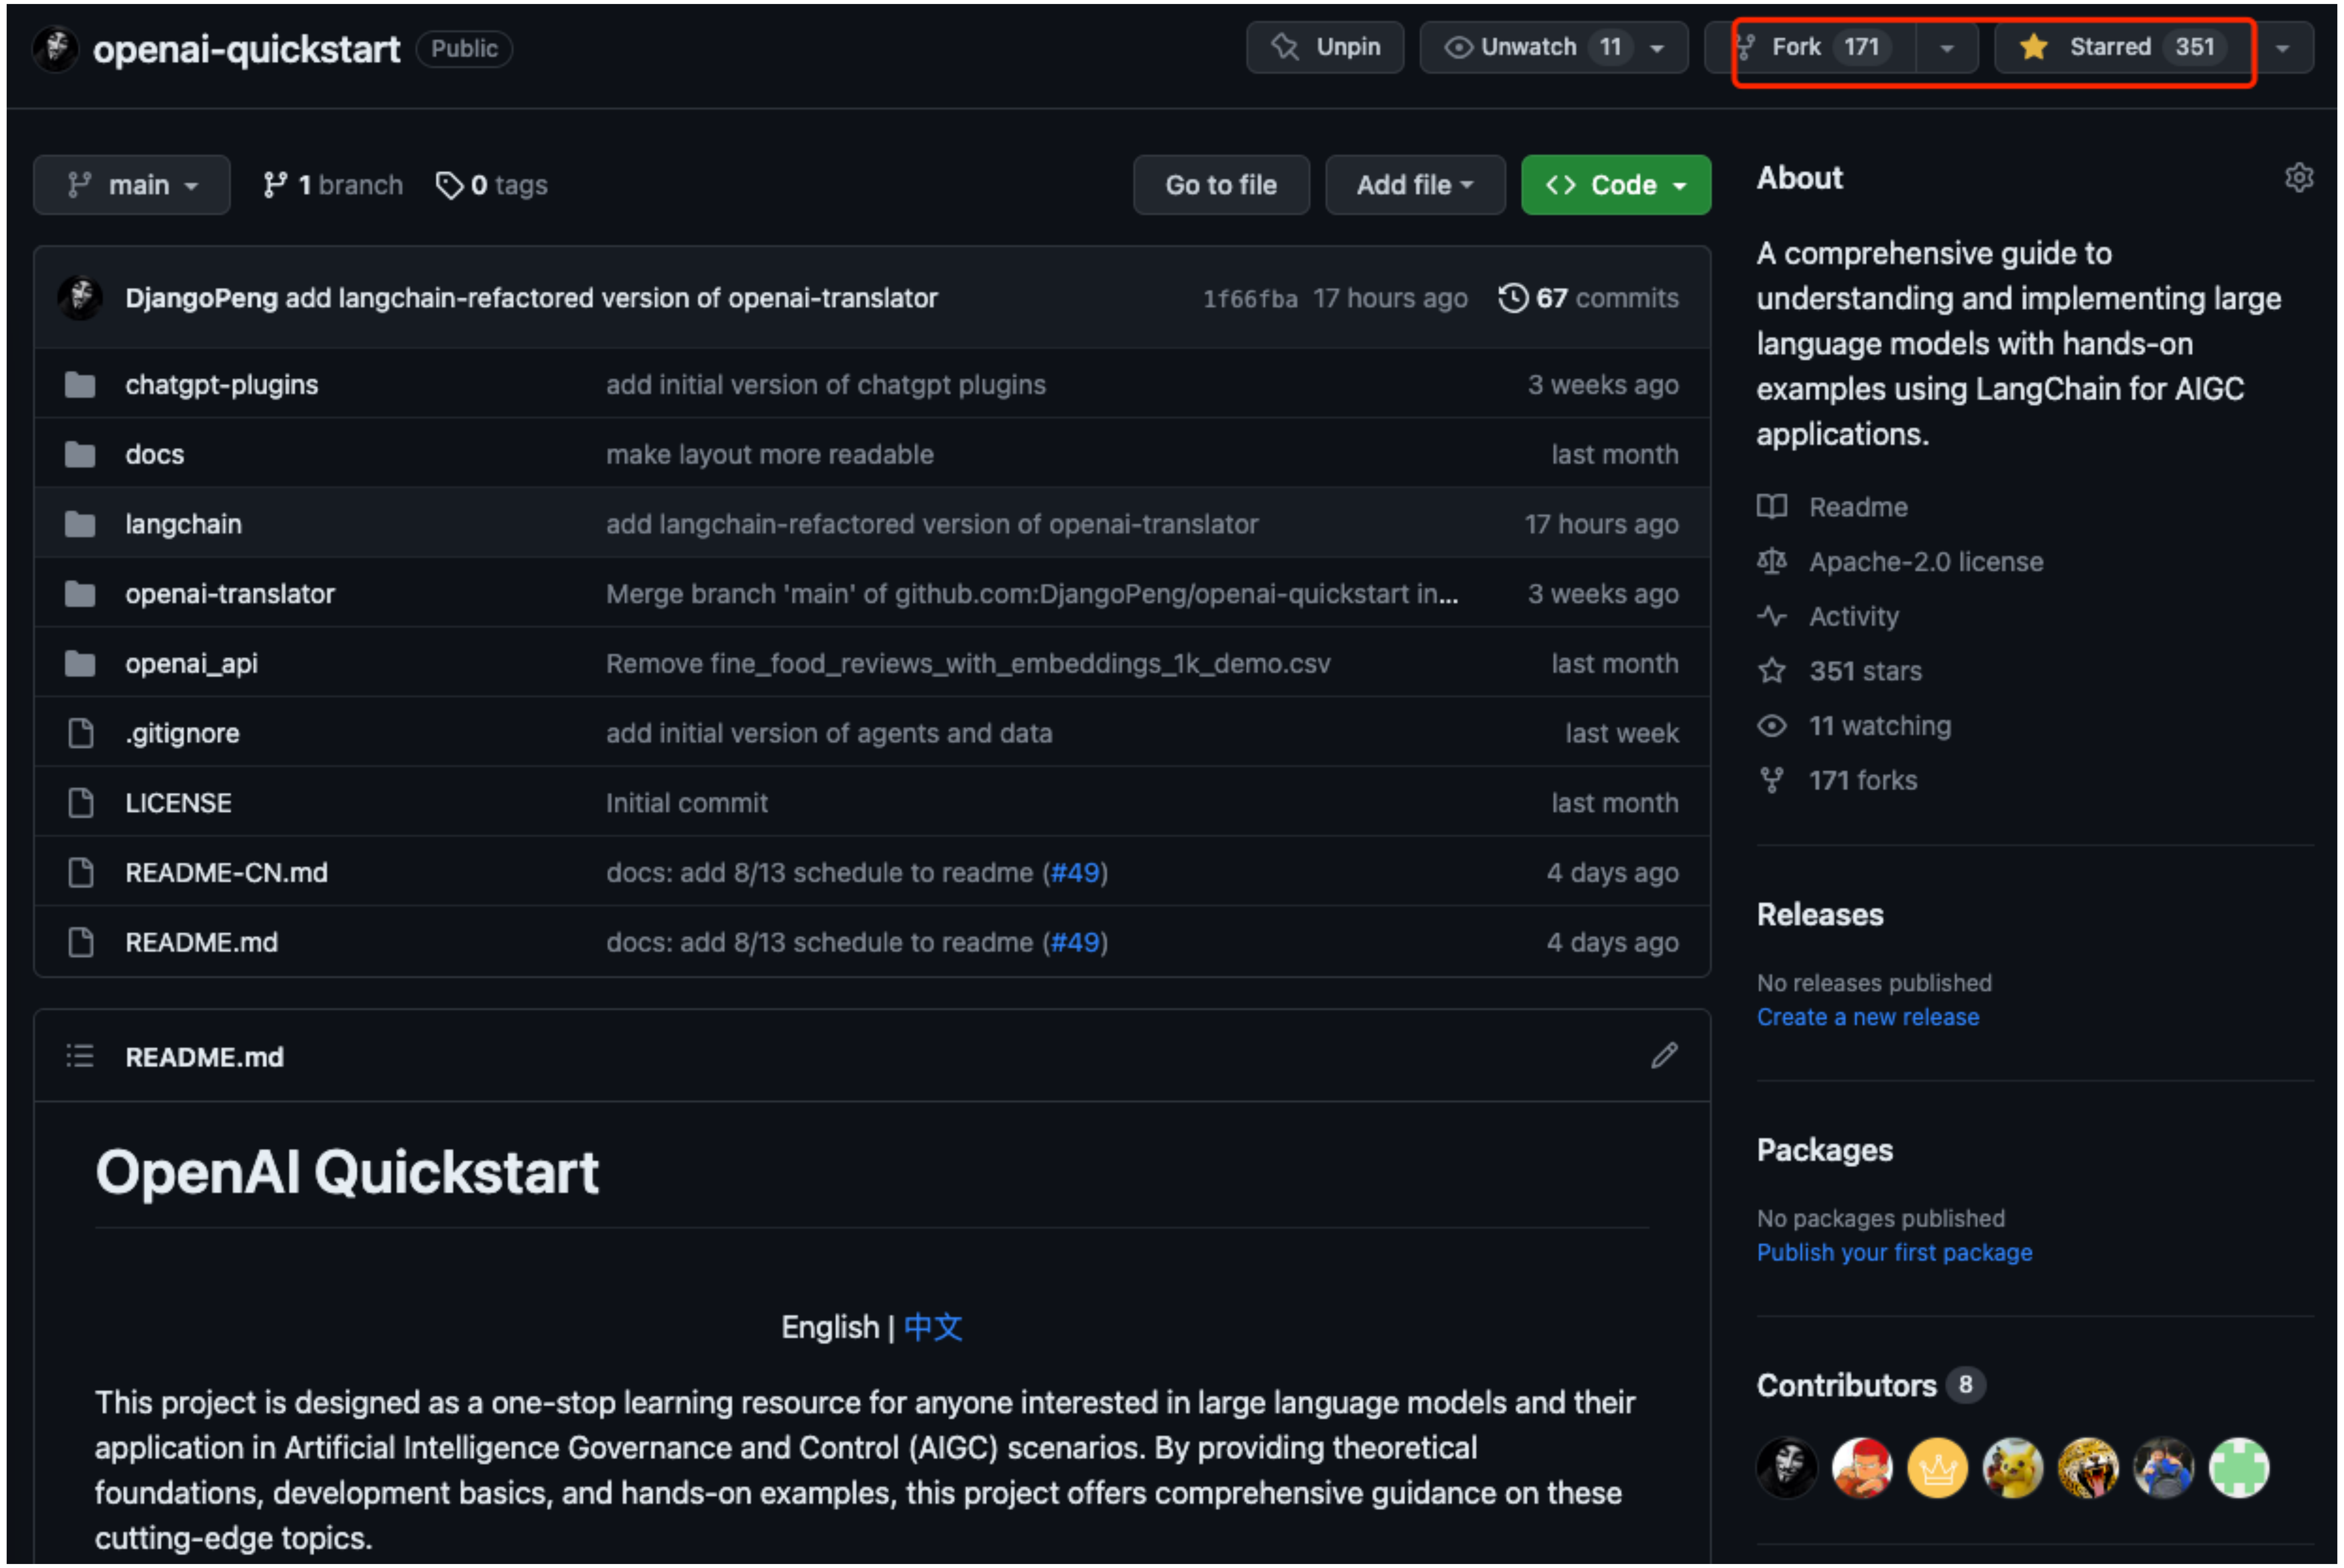

https://github.com/DjangoPeng/openai-quickstart