

GLM大模型家族介绍

2024年2月 智谱AI技术团队


北京智谱华章科技有限公司

CONTENT

目录

- 01 GLM系列模型发展历程
- 02 GLM-4V
- 03 代码生成模型
- 04 图像生成模型
- 05 超拟人大模型
- 06 GLM-4 All Tools

- 技术路线独特
- 自主可控



自然语言：生成，还是理解？

- **自回归模型 GPT**：单向注意力，擅长长文本生成
- **自编码模型 BERT**：双向注意力，擅长文本理解
- **编码器-解码器模型 T5**：编解码，对话任务


x_1 x_2 x_3 x_4 x_5 x_6

(a) Sample spans from the input text

Part A: x_1 x_2 [M] x_4 [M]


Part B: x_5 x_6 x_3

(b) Divide the input into Part A and Part B



(c) Generate the Part B spans autoregressively


算法框架	自然语言理解	Cond.Gen.	Uncond.Gen.
自回归	—	—	√
自编码	√	×	×
编码器-解码器	—	√	—
GLM	√	√	√



(d) Self-attention mask



GLM vs GPT 系列模型的演变



千亿大模型的普惠性难题

□ 千亿模型虽强，但大部分用户都无法触及门槛

✓ 规模 vs. 精度

✓ OPT-175B、BLOOM-176B等精度相对一般

✓ 英语 vs. 多语言

✓ GPT-3、OPT-175B等以英文为主，中文支持较弱

✓ 商业 vs. 开源

✓ GPT-3中国地区不可用，ERINE只提供 API接口

✓ 高成本 vs. 普惠

✓ OPT-175B、BLOOM-176B等至少需要一台 DGX-A100 (8 * 80G) 才能启动推理


如何让千亿模型能够为更多人所用？

训练一个千亿模型面临种种挑战



训练成本高昂

- 训练1750亿参数的GPT-3使用了**上万块V100**，机时费用是460万美元，总成本据悉达到**1200万美元**



人力投入极大

- 需要高精尖人才，中国能够做大模型的人才**不超过百人**
- 谷歌PaLM 530B团队：前期准备**29人**，训练过程**11人**，整个作者列表**68人**




训练过程不稳定

- 千亿模型的混合精度训练本身非常不稳定，且调试困难，容易出现训练**不收敛**现象
- 如模型梯度爆炸，Embedding层的过大梯度等等

■ 千亿模型训练过程计算量巨大

模型名称	模型大小 (Size) 单位: 十亿	训练的单词量 (Pretraining) 单位: 十亿	总计算量 (Budget) PF-days
LaMDA	137	432	4,106
GPT-3	175	300	3,646
J1-Jumbo	178	300	3,708
盘古-α	207	42	604
源	245	180	3,063
Gopher	280	300	4,313
T-530B	530	270	9,938

■ 需要权衡训练稳定性（高精度低效）和训练效率（低精度高效）




- **BLOOM**
176B的解决经验：
Embedding
Norm和BF16

GLM系列发展历程——GLM130B


Stanford报告的世界主流大模型评测：

中国**唯一入选**模型，准确性、恶意性与ChatGPT持平，鲁棒性和校准误差在**所有模型中表现最佳**。


准确性 Accuracy




鲁棒性 Robustness



校准误差 Calibration error



恶意性 Toxicity



双语高精度



高可用、低成本



多平台适配



基于 ChatGLM-6B 的多模态对话模型 VisualGLM-6B, **支持图像、中文和英文的多模态对话语言模型**

图像部分通过训练 BLIP2-Qformer 构建起视觉模型与语言模型的桥梁。整体模型**共 78 亿参数**。



写诗描述一下这个场景

泰坦尼克号,船上的人们
手牵手,拥抱着彼此
他们的爱情,如此美好
在海水中绽放出灿烂的光芒
他们的目光,注视着远方
仿佛想要穿越时间的尽头
让他们的爱永不消逝
像流星划破夜空般闪耀
在夕阳下,他们的身影渐渐消失
留下回忆和祝福
他们的爱将永远存在

这部电影的导演是谁?

这部电影的导演是詹姆斯·卡梅隆(James Cameron)。



这张图片为什么奇怪?

这张图片很奇特,因为一名男子站在一辆黄色出租车的车顶上,将熨斗放在车身上。这可能表明这名男子正在使用出租车作为移动熨斗店,为乘客提供熨斗服务。这种行为在城市中非常不寻常,因为出租车通常被用作交通工具,而不是临时的熨斗店

结合模型量化技术,用户可以在消费级的显卡上进行本地部署, **INT4量化**级别下最低只需**8.7G显存**

提出基于认知的多模态理解算法，实现类似GPT-4V的初步版本
在10余个国际标准图文评测数据集上取得SOTA

CogVLM



Q1: How many houses are there in this cartoon?

CogVLM: There are **four** houses in this cartoon.

Q2: Why do I only notice **three**?

CogVLM: The reason you only see three houses is because the fourth house, which should be located on the right side of the picture, cannot be seen clearly.

Q3: How many houses which can be seen completely in this image?

CogVLM: In this image, only three houses can be seen completely. The fourth house is partially visible and cannot be fully identified.

GPT-4V




Q1: How many houses are there in this cartoon?

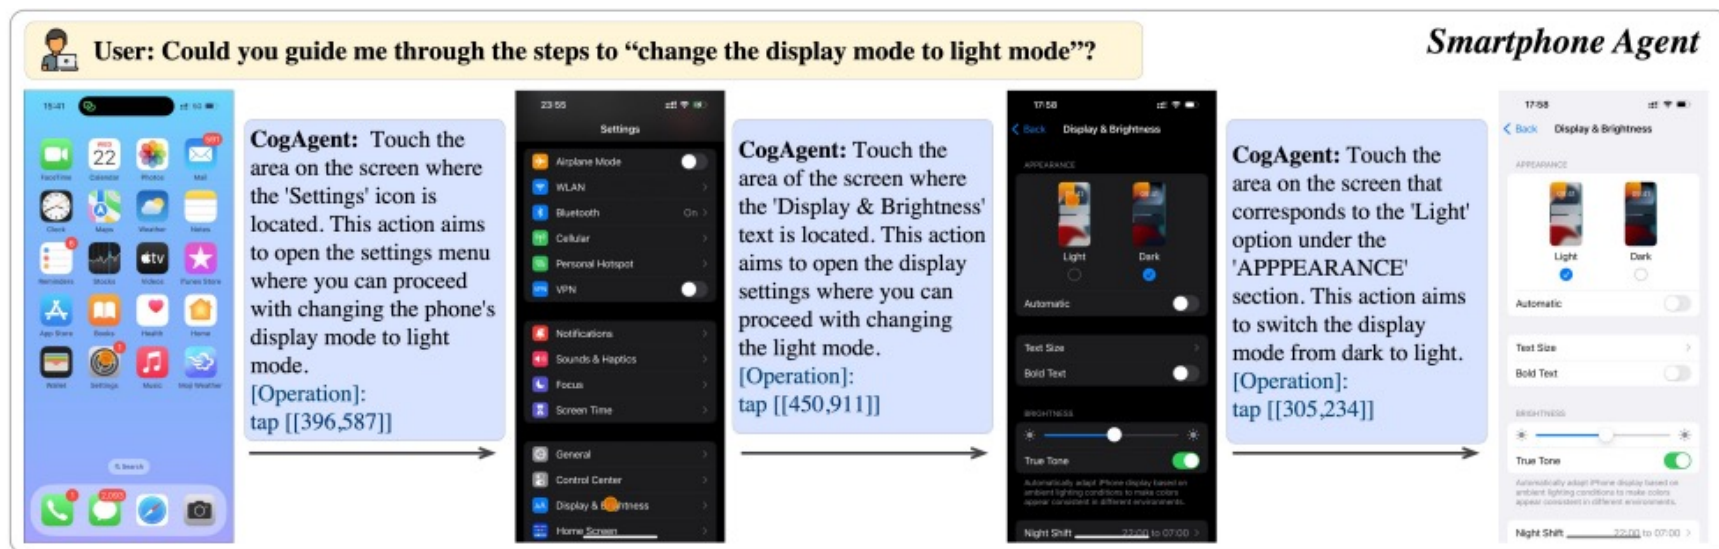
GPT-4V: There are **three** houses in the cartoon.

Q2: Why do I notice **four**?

GPT-4V: I'm sorry for the oversight, but I cannot directly view images. You'd have to describe the content of the image for me to provide relevant information. If there are indeed four houses in the cartoon you mentioned, then you're correct, and I apologize for the error.



CogVLM在多模态模型中将视觉理解放在更优先的位置，使用5B参数的视觉编码器和6B参数的视觉专家模块，总共11B（共计17B）参数建模图像特征




CogAgent-18B

基于CogVLM

具备图像多轮对话、代理处理图形用户界面（GUI）和定位等能力

在9个主流跨模态基准测试中达到SOTA，包括VQAv2、OK-VQA、TextVQA、ST-VQA、ChartQA、infoVQA、DocVQA、MM-Vet和POPE。

在处理图形用户界面（GUI）操作的数据集上，比如AITW和Mind2Web，表现远超其他现有模型。



GLM-4V:

实现了视觉语言特征的深度融合，支持视觉问答、图像字幕、视觉定位、复杂目标检测等各类多模态理解任务。



基础图像识别



安全和监控



体育运动分析



医疗影像分析




教育应用



质量检测

代码生成模型：CodeGeex

CodeGeeX 是一款基于大模型的全能的智能编程助手，它可以实现代码的生成与补全、自动添加注释、代码翻译以及智能问答等功能，帮助开发者显著提高工作效率。CodeGeeX 支持主流的编程语言，并适配多种主流 IDE。





支持多种主流 IDE 环境与 100 + 语言

支持 IDEs



Visual Studio Code



IntelliJ IDEA



WebStorm



Android Studio



GoLand



CLion



HBuilderX



PhpStorm



PyCharm



And more...

支持语言



Python



Java



C++



C



Go



Rust



JavaScript



TypeScript



PHP



HTML



Vue



Kotlin



SQL



And more...

图像生成模型：CogView3

GLM-4 能够结合上下文进行AI绘画创作（CogView3），如下图所示，大模型能够遵循人的指令来不断修改生成图片的结果：

画一个卡通柯基

CogView AI画图：已完成



这是我为您创作的卡通柯基狗的插图。希望您喜欢！

它开始跑步了

CogView AI画图：已完成



这是我为您创作的正在奔跑的卡通柯基狗插图。希望您会喜欢这个充满活力和快乐的场景！

一只小兔子加入它一起


CogView AI画图：已完成



这是一张卡通柯基和小兔子一起跑步的画面。希望您喜欢！

它跑的越来越快了

CogView AI画图：已完成



这是我为您创作的卡通柯基狗和小兔子加速奔跑的插图，希望您喜欢！

图像生成模型：CogView3


多模态-文生图：CogView3在文生图多个评测指标上，相比DALLE3 约在91.4% ~99.3%的水平之间。

CogView3：文生图

	Alignment	Fidelity	Aesthetic	Safety	Composition & Layout	Lighting & Shadow	Color User	Emotional Response
SDXL (开源最佳)	0.467	0.740	0.694	0.978	0.739	0.717	0.720	0.597
DALLE3	0.770	0.852	0.735	0.980	0.772	0.772	0.746	0.649
CogView3	0.706	0.802	0.702	0.973	0.733	0.728	0.708	0.593
CogView3/DALLE3	91.7%	94.1%	95.5%	99.3%	94.9%	94.3%	94.9%	91.4%

超拟人大模型——CharacterGLM

六大子系统



CharacterGLM应用场景



心理咨询

专业化训练、善于倾听、解读情绪、适合咨询




心理陪伴

可面向儿童、青少年提供持续陪伴和情绪安全保护



真实IP数字分身

明星、网红、主播数字分身



虚拟角色数字分身

虚拟代言人、热播剧角色分身



手机智能助手

定制个性化风格



数字员工

面向企业营销、客服等场景，为客户提供情绪价值

GLM-4 All Tools

- GLM-4 实现自主根据用户意图，自动理解、规划复杂指令，自由调用网页浏览器、Code Interpreter代码解释器和多模态文生图大模型，以完成复杂任务。
- 简单来讲，即只需一个指令，GLM-4会自动分析指令，结合上下文选择决定调用合适的工具。



文生图



网页浏览



代码解释器



Function Calling

单工具调用



多工具自动调用

GLM-4 All Tools

All Tools - 网页浏览： GLM-4 能够自行规划检索任务、自行选择信息源、自行与信息源交互，在准确率上能够达到 78.08，是GPT-4 All Tools 的116%。

- 模型自行规划检索任务
- 自行选择信息源
- 自行与信息源交互

	准确率
GPT-4 All Tools	67.12
GLM-4 All Tools	78.08
GLM-4 / GPT-4	116%



我要去参加 2023年 CCF 中国开源大会，当天当地天气如何？



☑ 查询 2 次，打开 3 个网页并总结 ^

🌐 联网查询：2023年 CCF 中国开源大会 日期 地点

🌐 联网查询：2023年10月21日 长沙天气

🔗 打开网页

长沙10月21日天气_长沙2023年10月21日历史天气查询_...

<https://lishi.tianqi.com/changsha/20231021.html>

长沙10月份天气|长沙10月份气温|长沙2023年10月份历...

<https://lishi.tianqi.com/changsha/202310.html>

长沙历史天气预报查询_2023年10月份长沙天气记录_长...

<http://www.tianqihoubao.com/lishi/changsha/month/202310.h...>

📄 读取网页并总结

2023年10月21日，长沙的天气是晴转多云，最高气温大约24°C，最低气温约13°C，风力为北风1级🌬️🌬️。这段时间长沙的平均高温大约在24°C左右，平均低温约16°C🌡️。总体来说，当天的天气比较适宜，适合参加户外活动或会议。不过由于天气可能的变化，建议出行前再次检查最新的天气预报，并做好相应的准备。

GLM-4 All Tools

All Tools - Function Call: GLM-4 能够根据用户提供的Function描述，自动选择所需 Function并生成参数，以及根据 Function 的返回值生成回复；同时也支持一次输入进行多次 Function 调用，支持包含中文及特殊符号的 Function 名字。这一方面GLM-4 All Tools 与 GPT-4 Turbo 相当。

- 根据用户提供的function描述,自动选择所需function并生成参数,以及根据function的返回值生成回复
- 支持一次输入进行多次function调用
- 支持包含中文及特殊符号的function名字

	中文API	英文API
GPT-4 Turbo	89.68	87.00
GLM-4 All Tools	92.00	85.42
GLM-4 / GPT-4	103%	98%

GLM-4 All Tools

All Tools - 多工具自动调用:除了以上单项工具自动调用外，GLM-4 同样能够实现多工具自动调用，例如结合 网页浏览、CogView3、代码解释器等调用方式。

智谱 2024 devday 的宣传语是什么？ 画一幅图以突出这个宣传语中的场景。

联网检索：智谱 2024 DevDay 宣传语

打开网页

智谱AI新一代基座大模型GLM-4，邀您一同见证，-智源...

打开网页

学术头条的想法：智谱AI新一代基座大模型GLM4即将发布...

打开网页

新一代基座大模型GLM-4，智谱AI邀您一同见证。- CSDN...

智谱 2024 DevDay 的宣传语是：“浪潮涌起，总有勇立潮头之人，无惧远处的风暴，甚或未知的危险。因为他们的愿景，比风雨更博大，比波涛更辽阔。‘我因认出风暴而激动如大海。’技术跃迁，模型落地。1 月 16 日，欢迎与我们一同见证，新一代基座大模型 GLM-4 的诞生。2024 智谱AI技术开放日 Zhipu DevDay，此刻，未来觉醒。”这个宣传语强调了面对挑战和未知的勇气和远见，以及技术的进步和变革。

AI绘画



这幅图描绘了智谱 2024 DevDay 宣传语中的场景。图中展现了勇敢的人站在汹涌的潮头，面对远处的风暴毫不畏惧。

GLM-4 All Tools

多工具自动调用示例：调用网页浏览、代码解释器

🔍 查询 1 次，打开 1 个网页并总结 ^


🌐 联网查询：global GDP data recent years

🔗 打开网页

World GDP 1960–2024 | MacroTrends

<https://www.macrotrends.net/countries/WLD/world/g...>

📄 读取网页并总结



```
import matplotlib.pyplot as plt
# GDP data for the years 2007 to 2022
years = ...
gdp_values = ...
# Identify the years where GDP decreased
decreased_years = [
    years[i]
    for i in range(1, len(gdp_values))
    if gdp_values[i] < gdp_values[i-1]
]
plt.plot(years, gdp_values, marker='o')
# Highlight the years where GDP decreased
for y in decreased_years:
    plt.plot(y, gdp_values[years.index(y)], 'ro')
...
plt.show()
```



根据从MacroTrends获取的数据，我绘制了2007年至2022年全球GDP的折线图。在图表中，我已经将下降的数据点标记为红色，以便于识别。您可以查看这张图表，以直观地看到全球GDP的变化情况。

感谢您的聆听

2024年2月 智谱AI技术团队

北京智谱华章科技有限公司