

2026 年 4 月 11 日架构师网络课程纪要

一、本次课程总结

【课堂主题】

《案例特训（架构篇）》+《人工智能》

【重点内容】



Redis 数据类型



类型	特点	示例
String（字符串）	存储二进制，任何类型数据，最大512MB	缓存，计数，共享Session
Hash（字典）	无序字典，数组+链表，适合存对象 Key对应一个HashMap。针对一组数据	存储、读取、修改用户属性
List（列表）	Linked List：双向链表，有序，增删快，查询慢 Array List：数组方式，有序，增删慢，查询快	消息队列，文章列表 记录前N个最新登录的用户ID列表
Set（集合）	键值对无序，唯一 增删查复杂度均为O(1)，支持交/并/差集操作	独立IP，共同爱好，标签
Sorted Set 【Zset】 (有序集合)	键值对有序，唯一，自带按权重排序效果	排行榜

Key	Value				
User:1:name	→ jack				
User:1:age	→ 38				
User:1	<table border="1"> <tr> <th>name</th><th>age</th></tr> <tr> <td>jack</td><td>38</td></tr> </table>	name	age	jack	38
name	age				
jack	38				



Redis 数据淘汰算法

Redis

设置了过期时间



淘汰作用范围	机制名	策略
不淘汰	<u>noeviction</u>	禁止驱逐数据，内存不足以容纳新入数据时，新写入操作就会报错。系统默认的一种淘汰策略。
设置了过期时间的键空间	<u>volatile-random</u>	随机移除某个key
	<u>volatile-lru</u>	优先移除最近未使用的key【局部性原理】
	<u>volatile-ttl</u>	<u>t</u> tl值小的key优先移除
全键空间	<u>allkeys-random</u>	随机移除某个key
	<u>allkeys-lru</u>	优先移除最近未使用的key



Redis的持久化



Redis的持久化主要有两种方式：RDB和AOF。这套机制也用于Redis的主从复制。

RDB：传统数据库中快照的思想。指定时间间隔将数据进行快照存储。

AOF：传统数据库中日志的思想，把每条改变数据集的命令追加到AOF文件末尾，这样出问题了，可以重新执行AOF文件中的命令来重建数据集。


对比维度	RDB持久化	AOF持久化
备份量	重量级的 全量备份 ，保存整个数据库	轻量级 增量备份 ，一次只保存一个修改命令
保存间隔时间	保存 间隔时间长	保存间隔时间短，默认1秒
还原速度	数据还原速度快	数据还原速度慢
阻塞情况	save会阻塞，但bgsave或者自动不会阻塞	无论是平时还是AOF重写，都不会阻塞
数据体积	同等数据体积：小	同等数据体积：大
安全性	数据安全性： 低 ，容易丢数据	数据安全性： 高 ，根据策略决定




Redis主从复制



Redis主从全量复制过程



Redis主从增量复制过程






Redis常见问题



1、缓存雪崩

大部分缓存失效 -> 数据库崩溃



解决方案

- 1、**使用锁或队列**：保证不会有大量的线程对数据库一次性进行读写，从而避免失效时大量的并发请求落到底层存储系统上。
- 2、**为key设置不同的缓存失效时间**：在固定的一个缓存时间的基础上+随机一个时间作为缓存失效时间。
- 3、**二级缓存**：设置一个有时间限制的缓存+一个无时间限制的缓存。避免大规模访问数据库。



Redis常见问题



2、缓存穿透

查询无数据返回 -> 直接查数据库

解决方案


- 1、如果查询结果为空，**直接设置一个默认值存放到缓存**，这样第二次到缓存中获取就有值了。设置一个不超过5分钟的过期时间，以便能正常更新缓存。
- 2、**设置布隆过滤器**，将所有可能存在的数据哈希到一个足够大的bitmap中，一个一定不存在的数据会被这个bitmap拦截掉，从而避免了对底层存储系统的查询压力。



Redis常见问题

【布隆过滤器】布隆过滤器用于快速识别1个元素不在一个集合中。

通过一个长二进制向量和一系列随机映射函数来记录与识别某个数据是否在一个集合中。



优点	缺点
1、占用内存小 2、查询效率高 3、不需要存储元素本身，在某些对保密要求比较严格的场合有很大优势	1、有一定的误判率，即存在假阳性，不能准确判断元素是否在集合中。 2、一般情况下不能从布隆过滤器中删除元素 3、不能获取元素本身




Redis常见问题

6、缓存击穿

某一热点数据过期 -> 大量并发请求直接查数据库

解决方案

- 1、设置热点数据永不过期。
- 2、设置逻辑过期时间：异步线程检查过期键，将其更新为最新数据后再次设置新的过期时间。
- 3、加互斥锁：当一个线程击穿缓存，去数据库访问时，它使用互斥锁将数据库锁住，此时其它线程由于得不到锁而进入短暂休眠，然后重新请求缓存。当击穿缓存的线程获取数据返回时，将数据写入缓存，同时释放锁，之后其他线程就可以直接从缓存获取数据。





分布式系统中的权衡问题——CAP



C (Consistency)：所有节点看到的数据完全一致（就像单机数据库一样）。

A (Availability)：每次请求都能及时得到响应（不管成功还是失败，都不卡死）。

P (Partition Tolerance)：网络可能断连、分区，但系统不能崩溃。

【注意】互联网的世界里，网络分区几乎无可避免，所以就**必须在 C 和 A 之间二选一**。

【典型的CP与AP场景】

CP系统：银行，支付系统，强一致性要求场景。

AP系统：社交平台上的点赞数，商品浏览量，评论数据，购物车内容，实时推荐，缓存，日志，可接受最终一致性要求场景。



分布式系统中的权衡问题——CAP



【单机锁，`synchronized` 或 `ReentrantLock()`】

【主要问题】只能确保本机上线程间的互斥。

【分布式锁，简单实现 `SET NX`】

`SET lock_key XS_ID NX PX 30000`


【主要问题】高并发，`redis`集群下容易出错，业务执行时间 > 锁自动过期时间、解锁时误删别人的锁、没有原子性解锁（`get + del` 分两步）等情况会引发错误。

【使用`Redisson`框架】

比较完备的解决方案，内置了包括`Watchdog`、原子性操作、应对集群的红锁等一系列成熟解决方案。



第四阶段：使用服务集群改善网站并发处理能力



负载均衡技术

传输层负载均衡

1、DNS域名解析负载均衡。DNS域名解析负载均衡就是在用户请求DNS服务器，获取域名对应的IP地址时，DNS服务器直接给出负载均衡后的服务器IP。

特点：效率比HTTP重定向高，减少维护负载均衡服务器成本。但一个应用服务器故障，不能及时通知DNS，而且DNS负载均衡的控制权在域名服务商那里，网站无法做更多的改善和更强大的管理。

2、基于NAT的负载均衡。基于NAT的负载均衡将一个外部IP地址映射为多个IP地址，对每次连接请求动态地转换为一个内部节点的地址。

特点：技术较为成熟，一般在网关位置，可以通过硬件实现。像四层交换机一般就采用了这种技术。



负载均衡技术



◆ 静态算法（不考虑动态负载）

- (1) **轮转**算法：轮流将服务请求（任务）调度给不同的节点（即：服务器）。
- (2) **加权轮转**算法：考虑不同节点处理能力的差异。
- (3) **源地址哈希**散列算法：根据请求的源IP地址，作为散列键从静态分配的散列表找出对应的节点。
- (4) **目标地址哈希**散列算法：根据请求目标IP做散列找出对应节点。
- (5) **随机**算法：随机分配，简单，但不可控。

◆ 动态算法（考虑动态负载）

- (1) **最小连接数**算法：新请求分配给当前活动请求数量最少的节点，每个节点处理能力相同的情况下。
- (2) **加权最小连接数**算法：考虑节点处理能力不同，按最小连接数分配。
- (3) **加权百分比**算法：考虑了节点的利用率、硬盘速率、进程个数等，使用利用率来表现剩余处理能力。

◆ 硬件负载均衡：F5

◆ 软件负载均衡：[LVS](#)、[Nginx](#)、[HAproxy](#)



第五阶段：数据库读写分离



主从数据库结构特点：


- 1、一般：**一主多从**，也可以多主多从。
- 2、**主库**做**写**操作，**从库**做**读**操作。

主从复制步骤：

- 1、主库（Master）更新数据完成前，将操作写**binlog**日志文件。
- 2、从库（Slave）打开I/O线程与主库连接，做**binlog dump process**，并将事件写入中继日志。
- 3、从库执行中继日志事件，保持与主库一致。




第六阶段：使用反向代理和CDN加速网站响应



CDN（内容分发网络）

CDN的全称是Content Delivery Network，即内容分发网络。其基本思路是尽可能避开互联网上有可能影响数据传输速度和稳定性的瓶颈和环节，使内容传输得更快、更稳定。





JWT

JWT (JSON Web Token) 是一种用于身份验证和授权的开放标准。
它是一种轻量级的、基于JSON的令牌，可以在客户端和服务端之间传递信息。

JWT由三部分组成：

- 【头部】包含令牌类型和所使用的算法
- 【载荷】包含用户信息和其他元数据
- 【签名】用于验证令牌的完整性和真实性

JWT的应用场景：【信息交换】 【授权】

不需要服务器端存储状态，安全地传递【非敏感信息】

【载荷】 {
"sub": "1234567890",
"name": "xisaiwang",
"iat": 1516239022
}

eyJhbGciOiJIUzI1NiIsInR5cCI6IkpXVCJ9.eyJzdWIiOiJ1b3R5b3ODkxwibmFtZSI6Inhpc2FpZ2FuZyIsImhhdCI6MTUxNjIzOTAyMn0.Jy5HGj1pIJs_OSc20at5ncMR0elabUUpHWZN-6cenU

【头部】 { "alg": "HS256",
"typ": "JWT" }

【签名】



响应式Web设计

响应式WEB设计是一种网络页面设计布局，其理念是：集中创建页面的图片排版大小，可以智能地根据用户行为以及使用的设备环境进行相对应的布局。



方法与策略

- (1) 采用流式布局和弹性化设计：使用相对单位，设定百分比而非具体值的方式设置页面元素的大小。
- (2) 响应式图片：不仅要同比的缩放图片，还要在小设备上降低图片自身的分辨率。



响应式Web设计



关于中台



【业务中台】：提供重用服务，例如学员中心、课程中心之类的开箱即用可重用能力。

【数据中台】：提供数据整合分析能力，帮助企业从数据中学习改进，调整方向。


【技术中台】：提供技术重用组件能力，帮助解决基础技术平台的复用。如：中间件，分布式存储，AI，负载均衡等基础设施。

【业务中台】 VS 【数据中台】

- ✓ 多个电商渠道使用一个下单服务，一个订单接口同时为多个前台系统提供服务。
- ✓ 多个前台系统，根据一个用户的手机号，获取对应的画像、用户的标签。
- ✓ 将多个支付通道，抽象建立成一个支付API，暴露给前台业务系统。
- ✓ 通过一个订单编号，来获取可能的商品推荐清单，从而做到交叉销售。



常见架构分析





人工智能

人工智能关键技术

关键技术	概念	应用
自然语言处理 NLP	人与计算机之间用 自然语言 进行有效 通信 的各种理论和方法	机器 翻译 、语义理解和 问答系统
计算机视觉 Computer Vision	模仿人类视觉系统的科学，让计算机拥有类似人类提取、处理、 理解 和 分析图像 以及图像序列的能力，将图像分析任务分解为便于管理的小块任务。	自动驾驶 、 机器人 、 智能医疗 等领域均需要通过计算机视觉技术从视觉信号中提取并处理信息。近年来随着深度学习的发展，预处理、特征提取与算法处理渐渐融合，形成 端到端 的人工智能算法技术。
知识图谱 Knowledge Graph	本质上是结构化的语义知识库，是一种 由节点和边组成的图数据结构 ，以符号形式描述物理世界中的概念及其相互关系。知识图谱就是把所有不同种类的信息连接在一起而得到的一个关系网络，提供了从“关系”的角度去分析问题的能力。	知识图谱可用于 反欺诈 、不一致性验证、组团欺诈等对公共安全保障形成威胁的领域，需要用到异常分析、静态分析、动态分析等数据挖掘方法。知识图谱在 搜索引擎 、 可视化展示 和 精准营销 方面有很大的优势，已成为业界的热门工具。



人工智能

人工智能关键技术

关键技术	概念	应用
人机交互 HCI	人机交互主要研究 人和计算机之间的信息交换 ，包括人到计算机和计算机到人的两部分信息交换，是人工智能领域的重要的外围技术。人机交互是与认知心理学、人机工程学、多媒体技术、虚拟现实技术等密切相关的综合学科的交叉。	传统的人与计算机之间的信息交换主要依靠交互设备进行，主要包括 键盘 、 鼠标 、 操纵杆 、 数据服装 、 眼动跟踪器 、 位置跟踪器 、 数据手套 、 压力笔 等输入设备，以及 打印机 、 绘图仪 、 显示器 、 头盔式显示器 、 音箱 等输出设备。人机交互技术除了传统的基本交互和图形交互外，还包括 语音交互 、 情感交互 、 体感交互 及 脑机交互 等技术。
虚拟现实/增强现实 VR/AR	虚拟现实或增强现实是以计算机为核心的新型视听技术。结合相关科学技术，在一定范围内生成与 真实环境 在视觉、听觉等方面 高度近似的数字化环境 。	用户借助必要的装备与数字化环境中的对象进行交互，相互影响，获得近似真实环境的感受和体验，通过 显示设备 、 跟踪定位设备 、 触力觉交互设备 、 数据获取设备 、 专用芯片 等实现。



人工智能



人工智能关键技术

关键技术	概念	应用
机器学习 ML	是一门涉及统计学、系统辨识、逼近理论、神经网络、优化理论、计算机科学、脑科学等诸多领域的交叉学科。其最初的研究动机是为了让计算机系统具有人的学习能力以便实现人工智能。	具体来说， 机器学习是以数据为基础 ，通过研究样本数据寻找规律，并根据所得规律对未来数据进行预测。目前，机器学习广泛应用于 数据挖掘 、计算机视觉、自然语言处理、生物特征识别等领域。



人工智能



【技术与解决方案】

概念	说明
大模型	如基于Transformer的通用语言模型，能解决多任务语言处理问题（ <u>DeepSeek</u> 、 <u>ChatGPT</u> ）。用途：对话、翻译、文本生成、代码生成。
提示词	引导模型输出的指令，解决任务定制和输出控制问题。
智能体(AI Agent)平台	自主决策系统，解决自动化任务和复杂决策问题 <u>Coze</u> 、 <u>Dify</u> 、 <u>FastGPT</u> 、 <u>manus</u> 。
MCP	多模态处理技术，解决跨模态理解和复杂场景推理问题（CLIP、Flamingo）。
模型微调	是指在预训练大模型（如GPT-4、Llama等）的基础上，用特定领域或任务的数据进行二次训练，使模型适应新场景的过程。它是迁移学习的核心方法，解决了通用大模型在垂直领域表现不足的问题。
RAG 检索增强生成引擎	结合检索与生成，解决知识更新和领域特定问答问题（ <u>RAGFlow</u> ）。用途：建立本地知识库，优先用本地知识库解决问题，以解决AI幻觉问题。

【视频回看地址】

希赛网目前提供了两种课程回看的方式：

方式一：课程回放【课程结束后 20 分钟内可立即回看】

APP 观看路径：我的->网络课堂

PC 观看路径：学习中心->网络课堂

回看注意事项：

(1) 首先登录希赛网(<https://www.xisaiwang.com/>)，然后使用以上地址回看。

(2) 回看时如果需要拖放观看,有两种方法进行视频内容定位:方法一是将鼠标移至视频头像位置进行拖放;方法二是直接点击播放界面下方的微缩图,可直接定位到这一页 PPT 的讲解。

方式二：老师端录屏回看【课程结束后 1-2 个工作日发布】

APP 观看路径：我的->视频课程

PC 观看路径：学习中心->视频课程

二、下次课程安排

主题：《论文写作（实战篇）》

时间：2026 年 4 月 13 日【周一】 19: 30 - 21: 30

预习要求：

回顾软件架构设计章节知识内容。

视频地址为：

<https://wangxiao.xisaiwang.com/nstu/sub/course/courseDetail/courseDetail?courseId=13147>

三、课后作业



【你所在的行业情况分析】

关键技术	应用场景
自然语言处理 NLP	
计算机视觉 Computer Vision	
知识图谱 Knowledge Graph	
人机交互 HCI	
虚拟现实/增强现实 VR/AR	
机器学习 ML	



人工智能



【开发的各个阶段，又能使用什么样的AI技术解决问题？】

关键技术	开发各阶段（如：需求、设计、编码、测试、运维）
自然语言处理 NLP	
计算机视觉 Computer Vision	
知识图谱 Knowledge Graph	
人机交互 HCI	
虚拟现实/增强现实 VR/AR	
机器学习 ML	

根据自身情况，填写这两张表。